

ESCUELA SUPERIOR POLITÉCNICA DE CHIMBORAZO (ESPOCH)
Maestría en Estadística con mención en Ciencia de Datos e Inteligencia Artificial

Avance del Proyecto Integrador

Problema, fuentes, arquitectura preliminar y plan de implementación

Título del proyecto

Diseño de una arquitectura híbrida SQL–NoSQL para la integración y
consulta de datos de incendios forestales en el cantón Loja

Integrantes

Malan Mullo, Marco Vinicio
Pujos Culque, Viviana Isabel
Chuncho Morocho, Carlos Guillermo

Grupo 4

Avance 1
2026

Índice

1. Definición del problema	2
1.1. Contexto y situación que motiva el proyecto	2
1.2. Población, sistema o proceso involucrado	2
1.3. Objetivo general	2
1.4. Usuarios o beneficiarios	2
1.5. Pregunta principal y preguntas analíticas derivadas	2
2. Inventario de mínimo tres fuentes de datos	3
2.1. Fuente 1: Malla espacial	3
2.2. Fuente 2: VIIRS (detecciones satelitales de incendio)	3
2.3. Fuente 3: CHIRPS (precipitación)	4
3. Diseño comparativo SQL vs. NoSQL	5
3.1. Entidades	5
3.2. Relaciones	5
3.3. Datos estables y relacionales (SQL) vs. datos flexibles o anidados (NoSQL) . . .	5
3.4. Justificación del uso de cada tecnología	5
3.5. Consultas que se espera resolver	6
4. Modelo preliminar de datos	6
4.1. Tablas principales, claves primarias y foráneas (SQL)	6
4.2. Diccionario de variables principales	7
4.3. Ejemplo de documento JSON (NoSQL)	7
5. Arquitectura preliminar	8
6. Pregunta analítica y unidad de análisis	8
7. Plan preliminar de implementación	9
8. Alcance y limitaciones	9
9. Referencias	9

1. Definición del problema

1.1 Contexto y situación que motiva el proyecto

Los incendios forestales en el cantón Loja se concentran en temporadas secas y afectan ecosistemas, biodiversidad y comunidades rurales cercanas a zonas de bosque y pastizal. La información necesaria para entender estos eventos proviene de fuentes muy distintas entre sí: detecciones satelitales de focos de calor (VIIRS), registros climáticos de precipitación (CHIRPS) y una malla espacial de referencia del territorio. Cada fuente tiene su propio formato, resolución y frecuencia de actualización, y hoy no existe una forma sencilla de integrarlas para responder preguntas conjuntas (por ejemplo, relacionar déficit de lluvia con ocurrencia de incendios en una misma zona y mes).

1.2 Población, sistema o proceso involucrado

El proceso involucrado es el de monitoreo y análisis de riesgo de incendios forestales a nivel territorial, en el que intervienen típicamente actores como los Gobiernos Autónomos Descentralizados (GAD Municipal y GAD Provincial), el Cuerpo de Bomberos y el Ministerio del Ambiente, Agua y Transición Ecológica (MAATE), así como las comunidades rurales asentadas cerca de zonas boscosas del cantón Loja.

Nota: FireForest es un ejercicio académico. No existe actualmente un convenio con estas instituciones; se usan como referencia del tipo de actor que se beneficiaría de una solución de este tipo. El proyecto trabaja únicamente con datos de ejemplo, muestras controladas o simulados.

1.3 Objetivo general

Diseñar una arquitectura híbrida SQL–NoSQL para integrar detecciones satelitales de incendios (VIIRS) y datos climáticos de precipitación (CHIRPS) sobre una malla espacial del cantón Loja, definiendo un dataset analítico por celda espacial y mes que permita, en etapas posteriores, estudiar la relación entre condiciones climáticas y ocurrencia de incendios.

1.4 Usuarios o beneficiarios

- Gestores de riesgo y personal técnico de instituciones ambientales o de emergencia (GAD, Bomberos, MAATE).
- Investigadores y estudiantes que analicen patrones espacio-temporales de incendios forestales.
- Comunidades rurales interesadas en conocer zonas de mayor recurrencia de incendios cerca de sus localidades.

1.5 Pregunta principal y preguntas analíticas derivadas

Pregunta principal (diseño de arquitectura): ¿Cómo diseñar una arquitectura híbrida SQL–NoSQL que permita integrar, almacenar y consultar de forma reproducible datos heterogéneos sobre incendios forestales en el cantón Loja?

Preguntas analíticas derivadas, que podrían responderse una vez integrados los datos:

- ¿Existe relación entre la precipitación acumulada mensual y la ocurrencia de incendios por celda espacial?
- ¿Qué celdas espaciales presentan mayor número o intensidad (FRP) de detecciones de incendio en el periodo analizado?
- ¿En qué meses del año se concentra la mayor cantidad de detecciones de incendio en el cantón Loja?

2. Inventario de mínimo tres fuentes de datos

Se identificaron tres fuentes principales, que combinan datos estructurados, semiestructurados y geospaciales.

2.1 Fuente 1: Malla espacial

- **Origen:** malla regular de 500 m generada sobre el límite oficial del cantón Loja. Fuente institucional oficial del límite pendiente de selección y validación durante la fase de ingesta (candidatas: Instituto Geográfico Militar, GAD Provincial de Loja).
- **Tipo de dato:** geoespacial estructurado.
- **Forma de captura:** no es una captura en tiempo real; se genera una única vez mediante Python o un SIG, a partir del límite oficial del cantón y un sistema de referencia proyectado (EPSG 32717, UTM 17S), y luego se reutiliza para todo el periodo de estudio.
- **Formato:** GeoJSON, GeoPackage o CSV.
- **Metadatos:** resolución espacial (500 m × 500 m), sistema de referencia (EPSG), fecha de generación.
- **Almacenamiento:** PostgreSQL/PostGIS (tabla `dim_celda`).
- **Riesgos:** geometrías inválidas o CRS incorrecto (calidad); se controla validando geometría y EPSG antes de cargar.

2.2 Fuente 2: VIIRS (detecciones satelitales de incendio)

- **Origen:** producto VIIRS Active Fire (resolución nativa ~375 m), distribuido por NASA FIRMS (Fire Information for Resource Management System).
- **Tipo de dato:** observacional, espacio-temporal.
- **Forma de captura:** automática; se prevé consultar la API/descarga de FIRMS por área (bounding box del cantón Loja) y periodo, registrando la versión del producto consultado, la fecha exacta de la consulta y conservando una copia local del archivo original antes de cualquier transformación.
- **Formato:** CSV o JSON.
- **Resolución temporal:** diaria (varios pasos por órbita).
- **Metadatos:** sensor (VIIRS SNPP, 375 m), fecha y hora de detección, unidad de FRP (potencia radiativa del fuego, MW), criterio de calidad (`fire_mask`).
- **Almacenamiento:** MongoDB (detalle de cada detección individual) y PostgreSQL (registro diario agregado por celda, agregable a celda-mes en consulta).
- **Riesgos:** detecciones duplicadas (calidad; se controla con identificador único y fecha); falsos positivos o baja calidad (se filtra por `fire_mask`); cambios en la API o cuotas de descarga de FIRMS (disponibilidad); reprocesamiento del producto tras su publicación (actualización).
- **Fecha de descarga en este avance:** no aplica aún; se trabaja con datos de ejemplo controlados (ver sección 8).

2.3 Fuente 3: CHIRPS (precipitación)

- **Origen:** Climate Hazards Group InfraRed Precipitation with Station data (CHIRPS v2.0), distribuido por el Climate Hazards Center de la Universidad de California, Santa Bárbara (UCSB).
- **Tipo de dato:** climático, espacio-temporal.
- **Forma de captura:** automática (descarga desde el repositorio del Climate Hazards Center).
- **Formato:** CSV, GeoTIFF o Parquet.
- **Resolución espacial nativa:** $\sim 0.05^\circ$ (~ 5 km). Esta resolución **no aumenta** al asociarla a la malla de 500 m del proyecto: cada celda de 500 m simplemente hereda (por asignación espacial) el valor del píxel CHIRPS de ~ 5 km que la contiene, por lo que varias celdas vecinas compartirán el mismo valor de precipitación. Es una armonización de soporte espacial para facilitar la integración, no una mejora real de la resolución climática.
- **Resolución temporal:** diaria, agregable a mensual.
- **Metadatos:** producto y versión (CHIRPS v2.0), unidad de medida (mm), periodo. CHIRPS entrega un valor diario; los agregados acumulado/medio/máximo se calculan al integrar los días de un mes (no se almacenan por separado a grano diario, ver sección 4.1).
- **Almacenamiento:** PostgreSQL (tabla `fact_clima`, un valor diario por celda, para cruzar por JOIN con incendio en consultas integradas por celda y fecha) y Parquet (copia de respaldo y procesamiento por lotes/intercambio con herramientas de análisis, sin pasar por la base de datos).
- **Riesgos:** valores faltantes (calidad; se controla registrando la cobertura temporal disponible por celda); cambios en el repositorio de origen (disponibilidad).
- **Fecha de descarga en este avance:** no aplica aún; se trabaja con datos de ejemplo controlados.

Aclaración: ocurrencia, frecuencia e intensidad no son lo mismo

Para evitar interpretaciones incorrectas de los resultados: `incendio_observado` indica únicamente presencia o ausencia de al menos una detección; `numero_detecciones` mide la frecuencia de detecciones satelitales, no el número de incendios distintos; y el FRP es una medida de intensidad radiativa del fuego, no de energía acumulada ni de potencia continua. En particular, `frp_suma_mw` es una suma *descriptiva* de los valores de FRP de las detecciones de un día (o mes, tras agregarlo), útil para comparar celdas entre sí, pero no debe interpretarse como una cantidad física de energía total liberada. Ninguna de estas variables equivale a superficie quemada, que no forma parte de este dataset.

Riesgos transversales

- **Disponibilidad:** caída del servicio de origen o cambios en las APIs de FIRMS/CHIRPS; se mitiga guardando copia local de cada descarga y registrando versión y fecha de acceso.
- **Actualización:** los productos satelitales pueden reprocesarse después de publicados; se documenta la versión/colección usada.
- **Seguridad:** archivos pesados o credenciales expuestas en el repositorio; se controla con `.gitignore` y sin subir secretos.

- **Privacidad:** no se prevé el uso de datos personales, ya que las fuentes son geoespaciales, satelitales y climáticas; aun así, se mantiene control de acceso sobre los archivos y bases de datos del proyecto.
- **Integración:** desalineación de fecha o celda entre VIIRS, CHIRPS y la malla; se controla validando siempre la clave `celda_id + anio + mes` antes de consolidar el dataset.

3. Diseño comparativo SQL vs. NoSQL

3.1 Entidades

Lado SQL (PostgreSQL/PostGIS): `dim_celda`, `dim_fecha`, `fact_incendio`, `fact_clima`.
Lado NoSQL (MongoDB): colección `detecciones_viirs` (detecciones individuales diarias, antes de resumirlas por celda-mes).

3.2 Relaciones

- `fact_incendio.celda_id` → `dim_celda.celda_id` (FK); `fact_incendio.fecha_id` → `dim_fecha.fecha_id` (FK).
- `fact_clima.celda_id` → `dim_celda.celda_id` (FK); `fact_clima.fecha_id` → `dim_fecha.fecha_id` (FK), con restricción `UNIQUE(celda_id, fecha_id)` (una fila por celda y día; ver la nota de granularidad temporal en la sección 4.1). La misma restricción aplica a `fact_incendio`.
- `fact_incendio` y `fact_clima` se cruzan mediante `JOIN` por `celda_id + fecha_id` (no hay FK directa entre ambas).
- La colección NoSQL `detecciones_viirs` no tiene FK hacia PostgreSQL: cada documento trae `celda_id + fecha` (día), y ese detalle diario se agrega por `celda_id + anio + mes` para poblar `fact_incendio`.
- Esta integración MongoDB → PostgreSQL no es automática ni por FK: se realiza mediante un proceso ETL/ELT (script de transformación) que lee las detecciones individuales de `detecciones_viirs`, las agrupa por `celda_id + fecha` y escribe un registro diario resumido en `fact_incendio`.

3.3 Datos estables y relacionales (SQL) vs. datos flexibles o anidados (NoSQL)

SQL	Malla espacial (geometría fija), calendario, y registros diarios de incendio/clima por celda (agregables a mes vía <code>GROUP BY</code>): estructura homogénea, con integridad referencial (PK/FK).
NoSQL	Detecciones individuales VIIRS: documentos con coordenadas y calidad anidadas, cuyos campos pueden variar según la versión del producto satelital sin romper un esquema fijo.

3.4 Justificación del uso de cada tecnología

¿Por qué PostgreSQL/PostGIS para determinados datos? Porque la malla espacial y los hechos diarios de incendio/clima tienen estructura estable y relaciones claras entre celda, fecha y hecho, lo que se beneficia de PK/FK, restricciones (`CHECK`) y de las capacidades geoespaciales de PostGIS. Las preguntas analíticas del proyecto (comparar incendio y clima por celda-mes) requieren `JOIN` y agregación (`GROUP BY anio, mes`), algo natural en SQL.

¿Por qué MongoDB para otros datos? Porque las detecciones satelitales individuales llegan en JSON semiestructurado y anidado, y su forma puede variar entre versiones del producto

sin obligar a migrar un esquema relacional. MongoDB conserva el detalle crudo y trazable de cada detección diaria y permite agregaciones documentales previas a resumir hacia PostgreSQL.

3.5 Consultas que se espera resolver

En SQL: número de detecciones, FRP total y máxima por celda-mes; precipitación acumulada/media/máxima por celda-mes cruzada con incendio; ranking de celdas con incendio observado y menor precipitación. Ejemplo ilustrativo, cruzando incendio y clima por celda-mes (ver consultas/consulta_01_incendios_clima_mensual.sql para la versión completa):

```
SELECT df.anio, df.mes, fi.celda_id,
       SUM(fi.numero_detecciones) AS detecciones_totales,
       MAX(fi.frp_maxima_mw) AS frp_maxima_mw,
       SUM(fc.precipitacion_diaria_mm) AS precipitacion_mensual_mm
FROM fact_incendio AS fi
JOIN fact_clima AS fc ON fc.celda_id = fi.celda_id
                     AND fc.fecha_id = fi.fecha_id
JOIN dim_fecha AS df ON df.fecha_id = fi.fecha_id
GROUP BY df.anio, df.mes, fi.celda_id;
```

En MongoDB: conteo de detecciones válidas por `celda_id`; FRP promedio/máximo por `celda_id` y mes; filtrado de detecciones por umbral mínimo de `fire_mask`. Ejemplo ilustrativo:

```
db.detecciones_viirs.aggregate([
  { $match: { "calidad.valida": true } },
  { $group: { _id: "$celda_id",
              detecciones: { $sum: 1 },
              frp_promedio: { $avg: "$frp_mw" } } }
]);
```

4. Modelo preliminar de datos

4.1 Tablas principales, claves primarias y foráneas (SQL)

Tabla	Descripción	PK	FK
dim_celda	Malla espacial de referencia (una fila por celda)	celda_id	—
dim_fecha	Calendario diario del periodo analizado	fecha_id	—
fact_incendio	Registro diario de incendio por celda (rollup de las detecciones VIIRS de ese día)	incendio_id	celda_id, fecha_id
fact_clima	Registro diario de precipitación por celda (un único valor de CHIRPS por celda-día)	clima_id	celda_id, fecha_id

Relaciones: dim_celda (1)—(N) fact_incendio; dim_celda (1)—(N) fact_clima; dim_fecha (1)—(N) fact_incendio; dim_fecha (1)—(N) fact_clima. Ambas tablas de hechos tienen además la restricción UNIQUE(celda_id, fecha_id), que impide registrar dos veces la misma celda en el mismo día.

Nota sobre la granularidad temporal (tres niveles):

1. **Detección individual (MongoDB):** cada documento de `detecciones_viirs` trae `celda_id` + `fecha` (día y hora exactos).
2. **Registro diario (PostgreSQL):** `dim_fecha` tiene una fila por fecha exacta (`fecha` DATE, con `anio/mes` derivados); `fact_incendio` y `fact_clima` agregan las detecciones/precipitación de *ese día* por celda, ligadas por `fecha_id`.

3. **Dataset analítico (celda-mes):** la unidad de análisis del proyecto se obtiene agregando los registros diarios por `celda_id` + `anio` + `mes` mediante consultas SQL (`GROUP BY anio, mes`), como en `consultas/consulta_01_incendios_clima_mensual.sql`; no existe como filas pre-agregadas en las tablas base.

4.2 Diccionario de variables principales

Variables almacenadas (grano diario):

Variable	Tabla	Tipo	Descripción / unidad
<code>celda_id</code>	<code>dim_celda</code>	Texto	Identificador único de la celda espacial
<code>anio, mes</code>	<code>dim_fecha</code>	Entero	Año y mes derivados de la fecha diaria
<code>numero_detecciones</code>	<code>fact_incendio</code>	Entero	Detecciones VIIRS de esa celda en el día (frecuencia, no ocurrencia)
<code>frp_suma_mw</code>	<code>fact_incendio</code>	Numérico	Suma descriptiva de FRP de ese día, en MW (no es energía acumulada)
<code>frp_maxima_mw</code>	<code>fact_incendio</code>	Numérico	Máxima FRP registrada ese día, en MW
<code>incendio_observado</code>	<code>fact_incendio</code>	Booleano	Presencia/ausencia de al menos una detección válida ese día
<code>precipitacion_diaria_mm</code>	<code>fact_clima</code>	Numérico	Único valor de precipitación de CHIRPS para esa celda y día, en mm

Variables derivadas (calculadas por consulta, agregación mensual; no se almacenan como columnas):

Variable	Operación	Tipo	Descripción / unidad
<code>precipitacion_acumulada_mensual_mm</code>	SUM	Numérico	Suma mensual de <code>precipitacion_diaria_mm</code> , en mm
<code>precipitacion_media_diaria_mm</code>	AVG	Numérico	Promedio mensual de <code>precipitacion_diaria_mm</code> , en mm
<code>precipitacion_maxima_diaria_mm</code>	MAX	Numérico	Máximo valor diario de precipitación dentro del mes, en mm

Nota: si CHIRPS entrega un único valor por celda-día, no tiene sentido almacenar “acumulada/media/máxima” a ese mismo grano diario (serían prácticamente el mismo valor). Esa distinción solo aparece al agregar los días de un mes, como muestra `consultas/consulta_01_incendios_clima_mensual.sql`.

4.3 Ejemplo de documento JSON (NoSQL)

La colección `detecciones_viirs` conserva el detalle individual de cada detección diaria; posteriormente se agrega a nivel celda-mes hacia `fact_incendio`.

```
{
  "deteccion_id": "V_2023_0001",
  "celda_id": "LJ_04521",
  "fecha": "2023-08-15",
  "hora_utc": "18:42",
  "fuente": "VIIRS",
  "sensor": "VIIRS_SNPP_375m",
  "frp_mw": 18.4,
  "fire_mask": 7,
  "coordenadas": {
    "longitud": -79.241,
    "latitud": -4.082
  }
}
```

```

},
"calidad": {
  "valida": true
}
}

```

5. Arquitectura preliminar

La figura 1 muestra el flujo de datos desde las fuentes hasta el producto analítico, incluyendo los pasos de validación, estandarización temporal y agregación que conectan el detalle diario de VIIRS con el dataset mensual por celda.




Figura 1: Arquitectura preliminar de la solución FireForest.

6. Pregunta analítica y unidad de análisis

Pregunta analítica derivada: ¿Existe relación entre la precipitación acumulada mensual y la ocurrencia de incendios por celda espacial? (La pregunta principal de diseño de arquitectura se presenta en la sección 1.5.)

Unidad de análisis: celda espacial de 500 m × 500 m observada durante un mes (clave `celda_id + año + mes`).

Dataset final esperado: una tabla/archivo (Parquet o CSV) con una fila por celda-mes, que combine: identificador de celda y coordenadas, número de detecciones e intensidad de incendio

(FRP), y precipitación acumulada/media/máxima del mes. Esta tabla será la base para estadística descriptiva, visualización o un modelo de riesgo posterior.

7. Plan preliminar de implementación

Etapas	Actividad	Resultado esperado	Estado
1	Identificación de fuentes	Fuentes disponibles documentadas	Completado
2	Diseño relacional (SQL)	Esquema con PK/FK	Completado
3	Diseño NoSQL	Colección y documento de ejemplo	Completado
4	Ingesta	Archivos y scripts de carga de datos de prueba listos	Preparada
5	Limpieza y validación	Datos consistentes	Pendiente
6	Integración	Dataset consolidado celda-mes	Pendiente
7	Análisis	Indicadores / modelos	Pendiente
8	Producto final	Reporte, dashboard o modelo	Pendiente

Avance 1 (esta entrega): etapas 1 a 3 completadas; etapa 4 preparada mediante archivos y scripts de datos de prueba, con la carga en bases de datos activas pendiente de verificar (aún no se ha realizado la ingesta de datos reales de VIIRS ni CHIRPS).

Avance 2 (siguiente entrega): cerrar etapas 4 y 5, avanzar etapa 6.

Informe final: etapas 7 y 8, con el dataset integrado y el análisis de la pregunta planteada.

Nota: se prioriza una solución sencilla y bien justificada, coherente entre el problema, las fuentes, la arquitectura y el dataset analítico esperado, por sobre una arquitectura compleja sin fundamento.

8. Alcance y limitaciones

- Este avance corresponde a un **prototipo académico**, no a un sistema operativo de alerta temprana de incendios.
- Los datos utilizados en esta entrega son **de ejemplo, controlados o simulados**; aún no se ha realizado la descarga ni ingesta de datos reales de VIIRS o CHIRPS.
- Las consultas y resultados presentados son ilustrativos y no permiten todavía establecer una relación causal entre precipitación e incendios, solo asociaciones descriptivas a explorar en etapas posteriores.
- No se incluye aún ningún modelo predictivo; su desarrollo, de ser pertinente, correspondería a la etapa de análisis (etapa 7 del plan de implementación).

9. Referencias

- NASA EOSDIS FIRMS. *VIIRS 375 m Active Fire and Thermal Anomalies product (VNP14IMG/VJ114IMG)*. Fire Information for Resource Management System. <https://firms.modaps.eosdis.nasa.gov> (consultado por definir en la fase de ingesta, Avance 2).
- Funk, C., Peterson, P., Landsfeld, M. et al. (2015). *The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes*. Scientific Data, 2, 150066. DOI: <https://doi.org/10.1038/sdata.2015.66>. Datos: Climate Hazards Center, UC Santa Bárbara, <https://www.chc.ucsb.edu/data/chirps> (consultado por definir en la fase de ingesta, Avance 2).

- PostgreSQL Global Development Group. *PostgreSQL Documentation*. <https://www.postgresql.org/docs/>
- PostGIS Project Steering Committee. *PostGIS Documentation*. <https://postgis.net/documentation/>
- MongoDB, Inc. *MongoDB Manual*. <https://www.mongodb.com/docs/>