

AVANCE DEL PROYECTO INTEGRADOR

Problema, fuentes, arquitectura preliminar y plan de implementación

Modalidad	Trabajo grupal
Valor	3,00 puntos
Entrega	Un archivo PDF por grupo
Extensión recomendada	5 a 8 páginas, sin contar portada

Este avance conecta las actividades de clase “Inventario de origen de datos” y “Diseño comparativo SQL vs NoSQL” con el desarrollo del proyecto integrador.

1. Propósito de la actividad

En esta primera entrega, cada grupo deberá definir un problema de Ciencia de Datos y diseñar una solución inicial desde la perspectiva de Ingeniería de Datos. El objetivo no es construir todavía toda la solución, sino demostrar que el grupo puede justificar de manera coherente el recorrido de los datos desde su origen hasta un producto analítico reproducible.

Pregunta guía del avance

¿Qué problema quiero resolver → qué datos necesito → de dónde salen → cómo llegan → dónde se almacenan → cómo se relacionan → cómo los integraré → cuál será mi dataset final → qué análisis realizaré con él?

2. Selección y definición del problema

El grupo debe seleccionar un problema aplicado, preferentemente vinculado con salud, educación, admisiones, finanzas, comercio, vivienda, industria, medioambiente, gestión pública u otro ámbito de interés. El problema debe poder ser estudiado mediante datos disponibles o razonablemente obtenibles.

- Contexto y situación que motiva el proyecto.
- Población, institución, proceso o sistema involucrado.
- Objetivo general del proyecto.
- Usuarios o beneficiarios potenciales de la solución.
- Una o más preguntas que podrían responderse utilizando los datos.

Ejemplo: “Integrar información académica y de interacción en plataformas para identificar factores asociados al abandono estudiantil y preparar un dataset que permita estimar el riesgo de deserción.”

3. Inventario de origen de datos

Aplicando la actividad desarrollada en clase, identifique como mínimo tres fuentes de datos. Se recomienda combinar diferentes tipos de información: estructurada, semiestructurada y/o no estructurada.

Fuente	Origen	Tipo	Captura	Formato	Metadatos	Almacenamiento	Riesgos
Sistema académico	Sistema institucional	Estructurado	Automática	Tabla/CSV	fecha, período, diccionario	PostgreSQL	faltantes, duplicados
Encuesta	Formulario	Estructurado	Manual	CSV/Excel	fecha, encuestador	PostgreSQL	digitación, sesgo
Interacciones	Plataforma web	Semi/no estructurado	Automática	JSON/texto	usuario, fecha, fuente	MongoDB	privacidad, heterogeneidad

Para cada fuente, el grupo deberá explicar:

- de dónde nace el dato;
- cómo se estructura;
- si la captura es manual o automática;
- en qué formato se obtiene;
- qué metadatos permiten interpretarlo;
- dónde debería almacenarse;
- qué riesgos de calidad, seguridad, privacidad, disponibilidad o actualización presenta.

4. Diseño comparativo SQL vs NoSQL

El proyecto debe considerar inicialmente al menos una estructura SQL y una estructura NoSQL. La decisión debe justificarse por las características de los datos y por los patrones de consulta esperados; no basta con mencionar una tecnología.

Elemento	Pregunta	Decisión esperada
Entidades	¿Cuáles son los objetos principales del problema?	tablas o colecciones
Relaciones	¿Qué vínculos importan?	claves, joins o grafo
SQL	¿Qué datos son estables y relacionales?	tablas, PK, FK, integridad
NoSQL	¿Qué datos son flexibles o anidados?	documentos, clave-valor, etc.
Consulta	¿Qué preguntas deberá responder el sistema?	SQL o agregación documental
ML	¿Cuál será la unidad de análisis?	dataset final reproducible

La entrega debe responder explícitamente:

- ¿Por qué utilizar SQL para determinados datos?
- ¿Por qué utilizar NoSQL para otros datos?

5. Modelo preliminar de datos

Incluya una representación inicial de las estructuras propuestas. No se requiere todavía un diseño definitivo ni completamente normalizado.

Para la parte SQL, incluir como mínimo:

- tablas principales;
- clave primaria de cada tabla;
- principales claves foráneas;
- relaciones entre tablas.

Para la parte NoSQL, incluir al menos un ejemplo de documento JSON.

```
{
  "estudiante_id": 1025,
  "periodo": "2026-1",
  "interacciones": [
    {"fecha": "2026-08-12", "tipo": "foro", "duracion": 18},
    {"fecha": "2026-08-14", "tipo": "plataforma", "duracion": 35}
  ]
}
```

6. Arquitectura preliminar de la solución

Elabore un diagrama que muestre el flujo de los datos desde el origen hasta su utilización analítica. Puede utilizar draw.io, Lucidchart, Canva, PowerPoint, Mermaid u otra herramienta.

**Fuentes de datos → Captura / APIs / archivos → Ingesta → Almacenamiento inicial
→ PostgreSQL + NoSQL → Limpieza / integración → Dataset analítico → Estadística / ML /
Dashboard**

El diagrama debe identificar claramente: fuentes, mecanismos de captura, almacenamiento, procesamiento, integración y producto analítico.

7. Pregunta analítica y unidad de análisis

Defina al menos una pregunta que pueda ser resuelta posteriormente mediante estadística, visualización o Machine Learning. A continuación, indique cuál será la unidad de análisis del dataset final.

Ejemplo de pregunta: ¿Qué estudiantes presentan mayor probabilidad de abandonar sus estudios durante el siguiente período académico?

Ejemplos de unidad de análisis: estudiante, estudiante-período, transacción, hogar, paciente, empresa, vivienda o producto.

8. Plan preliminar de implementación

Presente una secuencia de trabajo para desarrollar el proyecto durante el curso. El plan es preliminar y podrá ajustarse conforme se conozcan mejor los datos y las restricciones técnicas.

Etapas	Actividad	Resultado esperado
1	Identificación/adquisición	Fuentes disponibles
2	Diseño relacional	Esquema SQL
3	Diseño NoSQL	Colecciones / documentos
4	Ingesta	Datos cargados

5	Limpieza y validación	Datos consistentes
6	Integración	Dataset consolidado
7	Análisis	Indicadores / modelos
8	Producto final	Reporte, dashboard o modelo

9. Producto a entregar

- Un único archivo PDF por grupo.
- Extensión recomendada: 5 a 8 páginas, sin contar portada.
- Nombre del archivo: GrupoXX_AvanceProyectoIntegrador.pdf.
- Se recomienda utilizar tablas, diagramas y esquemas, evitando un documento compuesto únicamente por texto.
- La entrega debe contener: portada, problema, inventario de fuentes, diseño SQL/NoSQL, modelo preliminar, arquitectura, pregunta analítica, unidad de análisis y plan de implementación.

10. Criterios de evaluación

Criterio	Puntaje
Definición y justificación del problema	0,40
Inventario y caracterización de fuentes de datos	0,60
Diseño y justificación SQL vs NoSQL	0,60
Modelo y arquitectura preliminar de datos	0,60
Pregunta analítica, unidad de análisis y dataset esperado	0,40
Plan de implementación, coherencia y presentación	0,40
TOTAL	3,00

11. Lista de comprobación antes de enviar

- ☐ El problema está definido con claridad y es abordable con datos.
- ☐ Se identificaron al menos tres fuentes y se describió su origen, tipo, captura, formato, metadatos, almacenamiento y riesgos.
- ☐ Se justificó qué información será gestionada en SQL y cuál en NoSQL.
- ☐ Se incluyó un esquema relacional preliminar y un ejemplo JSON.
- ☐ La arquitectura muestra el flujo completo desde las fuentes hasta el producto analítico.
- ☐ Se definió una pregunta analítica y una unidad de análisis coherente.
- ☐ El plan de implementación presenta etapas y resultados esperados.
- ☐ El archivo final está en PDF y utiliza el nombre solicitado.

Importante: se evaluará principalmente la coherencia entre el problema, las fuentes, la arquitectura y el dataset analítico esperado. Una solución sencilla pero bien justificada es preferible a una arquitectura compleja sin fundamento.