

ESCUELA SUPERIOR POLITÉCNICA DE CHIMBORAZO (ESPOCH)
Maestría en Estadística con mención en Ciencia de Datos e Inteligencia Artificial

Avance del Proyecto Integrador

Problema, fuentes, arquitectura preliminar y plan de implementación

Título del proyecto

Diseño de una arquitectura híbrida SQL–NoSQL para la integración y consulta
de datos de incendios forestales en el cantón Loja

Integrantes

Malan Mullo, Marco Vinicio
Pujos Culque, Viviana Isabel
Chuncho Morocho, Carlos Guillermo

Grupo 4

Avance 1
2026

1. Definición y justificación del problema

El análisis de los incendios forestales en el cantón Loja requiere considerar su heterogeneidad territorial, climática y altitudinal. En tres zonas de estudio del sur del Ecuador —Malacatos, Punzara y San Lucas— se han documentado condiciones ambientales contrastantes asociadas con variaciones en el comportamiento del fuego (Balaguer-Beser et al., 2026). Estos resultados permiten contextualizar el problema, pero no describen por sí solos la totalidad del cantón.

La información necesaria para estudiar espacial y temporalmente las detecciones de fuego activo procede de fuentes heterogéneas: detecciones satelitales VIIRS, precipitación CHIRPS y una malla espacial de referencia. Cada fuente posee formatos, resoluciones y frecuencias de actualización diferentes, por lo que su integración requiere definir mecanismos coherentes de captura, almacenamiento, transformación y consolidación. Este es, en esencia, un problema de **Ingeniería de Datos**: diseñar el recorrido completo de los datos — captura, almacenamiento, integración y consolidación — antes de poder analizarlos.

El sistema involucrado es el de monitoreo y análisis de riesgo de incendios forestales a nivel territorial, en el que intervienen típicamente actores como los Gobiernos Autónomos Descentralizados (GAD Municipal y GAD Provincial), el Cuerpo de Bomberos y el Ministerio del Ambiente, Agua y Transición Ecológica (MAATE), así como las comunidades rurales asentadas cerca de zonas boscosas del cantón. FireForest es un ejercicio académico: no existe un convenio con estas instituciones, se mencionan como referencia del tipo de actor que se beneficiaría de una solución de este tipo, y el proyecto trabaja únicamente con datos de ejemplo, muestras controladas o simulados. Los usuarios o beneficiarios potenciales son gestores de riesgo y personal técnico de instituciones ambientales o de emergencia, investigadores y estudiantes que analicen patrones espacio-temporales de incendios forestales, y comunidades rurales interesadas en conocer zonas de mayor recurrencia cerca de sus localidades.

Objetivo general: diseñar una arquitectura híbrida SQL–NoSQL para integrar datos de detecciones VIIRS, precipitación CHIRPS y una malla espacial del cantón Loja, con el propósito de construir un dataset analítico reproducible por celda y mes.

Pregunta principal: ¿cómo diseñar una arquitectura híbrida SQL–NoSQL que permita integrar, almacenar y consultar de forma reproducible datos heterogéneos de incendios forestales en el cantón Loja?

Preguntas analíticas futuras, que podrían responderse una vez integrados los datos (no se responden en este avance):

- ¿qué asociación existe entre la precipitación acumulada mensual y la presencia o frecuencia de detecciones VIIRS por celda espacial?
- ¿qué celdas espaciales presentan mayor número o intensidad (FRP) de detecciones en el periodo analizado?
- ¿en qué meses del año se concentra la mayor cantidad de detecciones en el cantón Loja?

2. Inventario de fuentes

Se identificaron tres fuentes principales, que combinan datos geoespaciales, observacionales y climáticos.

Fuente	Origen	Tipo	Captura	Formato	Metadatos	Almacenamiento	Riesgos
Límite y malla espacial	INEC, Marco Geostadístico Nacional	Geoespacial estructurado	Única vez; disolución de zonas por código DPA	GeoPackage / GeoJSON	Capa zon_a; CRS EPSG:31992→32717; malla 500×500 m	PostgreSQL / PostGIS (dim_celda)	Geometría inválida o CRS incorrecto; se valida antes de cargar
VIIRS (detecciones de incendio)	NASA FIRMS	Observacional espacio-temporal	Automática (API o descarga por área y periodo)	CSV / JSON	Sensor, fecha/hora, FRP (MW), indicador de calidad	MongoDB (detalle) y PostgreSQL (agregado diario)	Duplicados, falsos positivos, cambios de API/cuota; producto y campo de calidad definitivos aún por confirmar
CHIRPS (precipitación)	Climate Hazards Center, UC Santa Bárbara	Climático espacio-temporal	Automática (descarga directa)	CSV / GeoTIFF / Parquet	Producto CHIRPS v2.0; resolución ~0,05°; unidad mm	PostgreSQL (fact_clima) y Parquet (respaldo)	Valores faltantes; cambios en el repositorio de origen

La malla espacial se ancla sobre el límite geoestadístico de trabajo del cantón Loja, reconstruido mediante la disolución de zonas censales del INEC por código DPA (división político-administrativa); no es un límite jurídico descargado directamente, sino una reconstrucción propia a partir de datos estadísticos oficiales. Sobre ese límite reconstruido se ancla una malla sistemática de 500×500 m. El CRS de trabajo del proyecto es EPSG:32717 (WGS84 / UTM 17S); las coordenadas se re proyectan a ese sistema antes de construir cada celda. La arquitectura no utiliza Google Earth Engine. Para VIIRS, el producto/colección definitivo y el campo de calidad (**fire_mask** frente a **confidence**) todavía deben confirmarse con datos reales. Para CHIRPS, asociar su píxel nativo (~5 km) a la malla de 500 m no aumenta su resolución real: cada celda hereda por asignación espacial el valor del píxel que la contiene.

Celdas controladas utilizadas en el prototipo

Para demostrar la carga y la consulta del modelo se utilizan dos celdas controladas, verificadas espacialmente contra la capa oficial del INEC:

Celda	Longitud	Latitud	Parroquia	Distancia al límite
LJ_TEST_001	-79,520851	-3,805328	El Cisne	1085,00 m
LJ_TEST_002	-79,516342	-3,809842	El Cisne	1066,01 m

Las dos celdas están completamente contenidas dentro del cantón Loja y de la parroquia El Cisne. Fueron seleccionadas determinísticamente para validar el prototipo y no constituyen una muestra representativa del territorio cantonal.

3. Diseño comparativo SQL vs. NoSQL

3.1 Entidades

Lado SQL (PostgreSQL/PostGIS): `dim_celda`, `dim_fecha`, `fact_incendio`, `fact_clima`.

Lado NoSQL (MongoDB): colección `detecciones_viirs`, con el detalle individual de cada detección (fecha y hora exactas).

3.2 Relaciones

Tabla con FK	Columnas	Referencia
<code>fact_incendio</code>	<code>celda_id</code> , <code>fecha_id</code>	<code>dim_celda</code> , <code>dim_fecha</code>
<code>fact_clima</code>	<code>celda_id</code> , <code>fecha_id</code>	<code>dim_celda</code> , <code>dim_fecha</code>

- Ambas tablas de hechos tienen `UNIQUE(celda_id, fecha_id)`: una fila por celda y día.
- `fact_incendio` y `fact_clima` no tienen FK entre sí: se cruzan mediante JOIN por `celda_id` y `fecha_id`.
- La relación entre MongoDB y PostgreSQL es **lógica**, no una clave foránea física: se resuelve mediante un proceso ETL/ELT que agrupa las detecciones de `detecciones_viirs` por `celda_id` y `fecha` para poblar `fact_incendio` a grano diario; no existe FK entre ambas bases.

3.3 Datos estables y relacionales (SQL) vs. datos flexibles o anidados (NoSQL)

SQL	Malla espacial (geometría fija), calendario, y registros diarios de incendio/clima por celda: estructura homogénea, con integridad referencial (PK/FK) y consultas espaciales de PostGIS.
NoSQL	Detecciones individuales VIIRS: documentos con coordenadas y calidad anidadas, cuyos campos pueden variar según la versión del producto satelital sin romper un esquema fijo.

3.4 Justificación del uso de cada tecnología

¿Por qué PostgreSQL/PostGIS? Porque la malla espacial y los hechos diarios de incendio/clima tienen estructura estable y relaciones claras entre celda, fecha y hecho, lo que se beneficia de PK/FK, restricciones y de las capacidades geoespaciales de PostGIS. PostgreSQL resuelve las consultas de agregación por celda-mes (JOIN + GROUP BY).

¿Por qué MongoDB? Porque las detecciones satelitales individuales llegan en JSON semiestructurado y anidado, y su forma puede variar entre versiones del producto sin obligar a migrar un esquema relacional. MongoDB resuelve consultas de agregación documental sobre el detalle crudo de cada detección (conteo, FRP promedio o máximo por celda).

3.5 Consultas que se espera resolver

En SQL: número de detecciones, FRP total y máxima por celda-mes; precipitación acumulada, media y máxima por celda-mes, conservando los meses con clima aunque no haya incendio. El procedimiento agrega primero incendio y clima por separado en dos CTE (incendio_mes, clima_mes) y luego los combina con un LEFT JOIN desde clima hacia incendio por celda_id + anio + mes:

```
WITH incendio_mes AS (
    -- agrega detecciones por celda-mes
    SELECT anio, mes, celda_id, SUM(numero_detecciones) AS detecciones,
           SUM(frp_suma_mw) AS frp_total_mw, MAX(frp_maxima_mw) AS frp_maxima_mw
    FROM fact_incendio JOIN dim_fecha USING (fecha_id) GROUP BY anio, mes, celda_id
),
clima_mes AS (
    -- agrega precipitacion por celda-mes
    SELECT anio, mes, celda_id, SUM(precipitacion_diaria_mm) AS precip_acumulada_mm
    FROM fact_clima JOIN dim_fecha USING (fecha_id) GROUP BY anio, mes, celda_id
)
SELECT c.anio, c.mes, c.celda_id,
       COALESCE(i.detecciones, 0) AS detecciones, -- valido solo si se
       COALESCE(i.frp_total_mw, 0) AS frp_total_mw, -- verifico cobertura VIIRS
       c.precip_acumulada_mm
FROM clima_mes AS c LEFT JOIN incendio_mes AS i USING (anio, mes, celda_id);
```

En MongoDB: conteo y FRP promedio/máximo de detecciones por celda_id, filtrando por el indicador de calidad validada de cada documento (calidad.valida), mediante una canalización de agregación con \$match y \$group.

4. Modelo preliminar de datos

4.1 Tablas principales, claves y granularidad

Tabla	Descripción	PK	FK
dim_celda	Malla espacial de referencia (una fila por celda)	celda_id	—
dim_fecha	Calendario diario del periodo analizado	fecha_id	—
fact_incendio	Registro diario de incendio por celda	incendio_id	celda_id, fecha_id
fact_clima	Registro diario de precipitación por celda	clima_id	celda_id, fecha_id

Granularidad: las tablas de hechos son siempre diarias (UNIQUE(celda_id, fecha_id)); la unidad de análisis final, celda-mes, se obtiene agregando esos registros diarios por celda_id + anio + mes mediante consultas SQL; no existe como filas pre-agregadas en las tablas base.

4.2 Esquema relacional




Figura 1: Modelo relacional preliminar: `dim_celda` y `dim_fecha` se relacionan con `fact_incendio` y `fact_clima` mediante claves foráneas; estas dos últimas se cruzan por `celda_id` + `fecha_id` sin FK directa entre ellas.

4.3 Ejemplo de documento JSON (NoSQL)

La colección `detecciones_viirs` conserva el detalle individual de cada detección, con fecha y hora exactas; estas detecciones se agregan por `celda_id` + `fecha` para poblar `fact_incendio` a grano diario.

```

{
  "deteccion_id": "V_2023_TEST_001",
  "celda_id": "LJ_TEST_001",
  "fecha": "2023-08-15",
  "hora_utc": "18:42",
  "fuente": "VIIRS",
  "sensor": "VIIRS_SNPP_375m",
  "frp_mw": 18.4,
  "fire_mask": 7,
  "coordenadas": {
    "longitud": -79.520851,
    "latitud": -3.805328
  },
  "calidad": {
    "valida": true
  }
}

```

4.4 Validación controlada del prototipo

La carga y consulta descritas se verificaron con las dos celdas controladas de la sección 2:

Celda	Detecciones	FRP total / máxima	Precipitación
LJ_TEST_001	1	18,4 / 18,4 MW	12,5 mm
LJ_TEST_002	1	9,7 / 9,7 MW	8,7 mm

Se trata de datos controlados: comprueban el funcionamiento del flujo de carga e integración, no son resultados ambientales representativos y no permiten inferencia alguna para el cantón.

5. Arquitectura preliminar

La figura 2 muestra el flujo de datos desde las fuentes hasta el producto analítico.



Figura 2: Arquitectura preliminar de la solución FireForest: la integración ocurre a grano celda-día en PostgreSQL/PostGIS y solo después se agrega a celda-mes; no existe una integración directa a nivel mensual.

La orquestación de la ingesta, validación, carga e integración se prevé mediante Airflow; actualmente se encuentra en fase de validación, no operativa por completo.

6. Pregunta analítica, unidad de análisis y dataset esperado

Pregunta analítica: ¿qué asociación existe entre la precipitación acumulada mensual y la presencia o frecuencia de detecciones VIIRS por celda espacial? Esta pregunta no se responde en este avance; requiere el dataset celda-mes consolidado (sección 7).

Unidad de análisis: celda espacial de 500×500 m observada durante un mes, con clave *celda_id* + *año* + *mes*. Las tablas de hechos permanecen a grano diario; la unidad celda-mes se construye por agregación.

Dataset final esperado: una tabla con una fila por celda-mes, que combine identificador de celda y coordenadas, número de detecciones e intensidad de incendio (FRP), y precipitación acumulada/media/máxima del mes.

Cero frente a dato faltante: un valor 0 en detecciones o FRP no equivale automáticamente a cobertura VIIRS comprobada; solo puede leerse como ausencia real de detecciones si se verificó de forma independiente que la cobertura e ingesta VIIRS de ese mes fueron correctas. NULL representa información faltante o no procesada. La prueba de LEFT JOIN con COALESCE descrita en la sección 3.5 valida el comportamiento de la consulta, no constituye evidencia de cobertura satelital real.

7. Plan preliminar de implementación

#	Actividad	Resultado esperado	Estado
1	Identificación de fuentes y validación territorial de las dos celdas controladas	Fuentes documentadas; celdas verificadas dentro del cantón Loja	Completada
2	Diseño relacional (SQL)	Esquema con PK/FK	Completado
3	Diseño NoSQL	Colección y documento de ejemplo	Completado
4	Carga controlada	Datos cargados en PostgreSQL/PostGIS y MongoDB	Completada
5	Migración territorial de las celdas controladas	Identificadores y coordenadas actualizados en ambas bases	Completada
6	Adquisición de series reales (VIIRS, CHIRPS)	Datos reales incorporados	Pendiente
7	Malla completa de producción	Malla de 500 m para todo el cantón	Pendiente
8	Cobertura VIIRS	Bandera de cobertura verificada por celda-mes	Pendiente
9	Panel completo celda-mes	Dataset consolidado	Pendiente
10	Automatización	Orquestación de ingesta e integración (Airflow)	En validación
11	Análisis y producto final	Indicadores, modelo o reporte	Pendiente

8. Alcance y limitaciones

- **Dominio previsto:** cantón Loja.
- **Cobertura actual:** dos celdas controladas verificadas dentro de la parroquia El Cisne, utilizadas exclusivamente para validación técnica del prototipo (almacenamiento, reproyección, agregación temporal, consultas de integración SQL/NoSQL).
- Este avance corresponde a un **prototipo académico**, no a un sistema operativo de alerta temprana de incendios.
- Dos celdas dentro de una sola parroquia **no constituyen una muestra representativa** de la variabilidad ambiental, altitudinal o climática del cantón; los resultados presentados no describen el comportamiento de los incendios del cantón Loja.
- Las consultas mostradas son ilustrativas: no permiten aún análisis inferencial ni predictivo, ni establecer relación causal entre precipitación e incendios.
- Queda pendiente incorporar series reales completas de VIIRS y CHIRPS, la malla completa de producción y la bandera de cobertura VIIRS.

9. Referencias

- Balaguer-Beser, A., González, F., Chuncho, C. G., Carrión-Paladines, V., & Juela-Sivisaca, O. (2026). Altitudinal variation in fire behavior in Andean ecosystems in southern Ecuador. *Fire Ecology*, 22, Article 46. <https://doi.org/10.1186/s42408-026-00470-y>
- Instituto Nacional de Estadística y Censos (INEC). *Marco Geoestadístico Nacional*. https://www.ecuadorencifras.gob.ec/documentos/web-inec/Geografia_Estadistica/Micrositio_geoportal/descargas.html
- NASA EOSDIS FIRMS. *VIIRS 375 m Active Fire and Thermal Anomalies (VNP14IMG/VJ114IMG)*. <https://firms.modaps.eosdis.nasa.gov>
- Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Shukla, S., Husak, G., Rowland, J., Harrison, L., Hoell, A., & Michaelsen, J. (2015). The climate hazards infrared precipitation with stations – a new environmental record for monitoring extremes. *Scientific Data*, 2, 150066. <https://www.chc.ucsb.edu/data/chirps>
- PostgreSQL Global Development Group. *PostgreSQL Documentation*. <https://www.postgresql.org/docs/>
- PostGIS Project Steering Committee. *PostGIS Documentation*. <https://postgis.net/documentation/>
- MongoDB, Inc. *MongoDB Manual*. <https://www.mongodb.com/docs/>