

ESCUELA SUPERIOR POLITÉCNICA DE CHIMBORAZO (ESPOCH)
Maestría en Estadística con mención en Ciencia de Datos e Inteligencia Artificial

Avance del Proyecto Integrador

Problema, fuentes, arquitectura preliminar y plan de implementación

Título del proyecto

Diseño de una arquitectura híbrida SQL–NoSQL para la integración y consulta de datos de incendios forestales en el cantón Loja

Integrantes

Malan Mullo, Marco Vinicio
Pujos Culque, Viviana Isabel
Chuncho Morocho, Carlos Guillermo

Grupo 4

Avance 1
2026

1. Definición y justificación del problema

Los incendios forestales en el cantón Loja se concentran en temporadas secas y afectan ecosistemas, biodiversidad y comunidades rurales cercanas a zonas de bosque y pastizal. El cantón se ubica en los Andes tropicales del sur de Ecuador, donde el relieve montañoso genera transiciones ambientales pronunciadas: temperatura, precipitación, humedad, vegetación y combustibles cambian con la altitud. Balaguer-Beser et al. (2026) documentan esta heterogeneidad en tres zonas de estudio del sur de Ecuador (Malacatos, Punzara y San Lucas, entre aproximadamente 1549 y 2757 m s.n.m.), con condiciones contrastantes de comportamiento del fuego entre ellas; estos resultados corresponden específicamente a esas tres zonas y se utilizan aquí para contextualizar la heterogeneidad ambiental y altitudinal del sur del Ecuador, no como una descripción generalizable a la totalidad del cantón Loja.

La información necesaria para estudiar estos eventos proviene de fuentes muy distintas entre sí: detecciones satelitales de focos de calor (VIIRS), registros climáticos de precipitación (CHIRPS) y una malla espacial de referencia del territorio. Cada fuente tiene su propio formato, resolución y frecuencia de actualización, y hoy no existe una forma sencilla de integrarlas para responder preguntas conjuntas. Este es, en esencia, un problema de **Ingeniería de Datos**: diseñar el recorrido completo de los datos — captura, almacenamiento, integración y consolidación — antes de poder analizarlos.

El sistema involucrado es el de monitoreo y análisis de riesgo de incendios forestales a nivel territorial, en el que intervienen típicamente actores como los Gobiernos Autónomos Descentralizados (GAD Municipal y GAD Provincial), el Cuerpo de Bomberos y el Ministerio del Ambiente, Agua y Transición Ecológica (MAATE), así como las comunidades rurales asentadas cerca de zonas boscosas del cantón. FireForest es un ejercicio académico: no existe un convenio con estas instituciones, se mencionan como referencia del tipo de actor que se beneficiaría de una solución de este tipo, y el proyecto trabaja únicamente con datos de ejemplo, muestras controladas o simulados. Los usuarios o beneficiarios potenciales son gestores de riesgo y personal técnico de instituciones ambientales o de emergencia, investigadores y estudiantes que analicen patrones espacio-temporales de incendios forestales, y comunidades rurales interesadas en conocer zonas de mayor recurrencia cerca de sus localidades.

Objetivo general: diseñar una arquitectura híbrida SQL–NoSQL para integrar datos de detecciones VIIRS, precipitación CHIRPS y una malla espacial del cantón Loja, con el propósito de construir un dataset analítico reproducible por celda y mes.

Pregunta principal: ¿cómo diseñar una arquitectura híbrida SQL–NoSQL que permita integrar, almacenar y consultar de forma reproducible datos heterogéneos de incendios forestales en el cantón Loja?

Preguntas analíticas futuras, que podrían responderse una vez integrados los datos (no se responden en este avance):

- ¿qué asociación existe entre la precipitación acumulada mensual y la presencia o frecuencia de detecciones VIIRS por celda espacial?
- ¿qué celdas espaciales presentan mayor número o intensidad (FRP) de detecciones en el periodo analizado?
- ¿en qué meses del año se concentra la mayor cantidad de detecciones en el cantón Loja?

2. Inventario de fuentes

Se identificaron tres fuentes principales, que combinan datos geoespaciales, observacionales y climáticos.

Fuente	Origen	Tipo	Captura	Formato	Metadatos	Almacenamiento	Riesgos
Límite y malla espacial	INEC, Marco Geoestadístico Nacional	Geoespacial estructurado	Única vez; disolución de zonas por código DPA	GeoPackage / GeoJSON	Capa <code>zon_a</code> ; CRS EPSG:31992→32717; malla 500×500 m	PostgreSQL / PostGIS (<code>dim_celda</code>)	Geometría inválida o CRS incorrecto; se valida antes de cargar
VIIRS (detecciones de incendio)	NASA FIRMS	Observacional espacio-temporal	Automática (API o descarga por área y periodo)	CSV / JSON	Sensor, fecha/hora, FRP (MW), indicador de calidad	MongoDB (detalle) y PostgreSQL (agregado diario)	Duplicados, falsos positivos, cambios de API/cuota; producto y campo de calidad definitivos aún por confirmar
CHIRPS (precipitación)	Climate Hazards Center, UC Santa Bárbara	Climático espacio-temporal	Automática (descarga directa)	CSV / GeoTIFF / Parquet	Producto CHIRPS v2.0; resolución ~0,05°; unidad mm	PostgreSQL (<code>fact_clima</code>) y Parquet (respaldo)	Valores faltantes; cambios en el repositorio de origen

La malla espacial se reconstruye disolviendo las zonas censales del INEC por su código de división político-administrativa (DPA) para obtener el límite cantonal, sobre el cual se ancla una malla sistemática de 500×500 m. El CRS de trabajo del proyecto es **EPSG:32717** (WGS84 / UTM 17S); las coordenadas se re proyectan a ese sistema antes de construir cada celda. La arquitectura no utiliza Google Earth Engine. Para VIIRS, el producto/colección definitivo y el campo de calidad (`fire_mask` frente a `confidence`) todavía deben confirmarse con datos reales. Para CHIRPS, asociar su píxel nativo (~5 km) a la malla de 500 m no aumenta su resolución real: cada celda hereda por asignación espacial el valor del píxel que la contiene.

Celdas controladas utilizadas en el prototipo

Para demostrar la carga y la consulta del modelo se utilizan dos celdas controladas, verificadas espacialmente contra la capa oficial del INEC:

Celda	Longitud	Latitud	Parroquia	Distancia al límite
LJ_TEST_001	-79,520851	-3,805328	El Cisne	1085,00 m
LJ_TEST_002	-79,516342	-3,809842	El Cisne	1066,01 m

Las dos celdas están completamente contenidas dentro del cantón Loja y de la parroquia El Cisne. Fueron seleccionadas determinísticamente para validar el prototipo y no constituyen una muestra representativa del territorio cantonal.

3. Diseño comparativo SQL vs. NoSQL

3.1 Entidades

Lado SQL (PostgreSQL/PostGIS): `dim_celda`, `dim_fecha`, `fact_incendio`, `fact_clima`.
Lado NoSQL (MongoDB): colección `detecciones_viirs`, con el detalle individual de cada detección (fecha y hora exactas).

3.2 Relaciones

Tabla con FK	Columnas	Referencia
<code>fact_incendio</code>	<code>celda_id</code> , <code>fecha_id</code>	<code>dim_celda</code> , <code>dim_fecha</code>
<code>fact_clima</code>	<code>celda_id</code> , <code>fecha_id</code>	<code>dim_celda</code> , <code>dim_fecha</code>

- Ambas tablas de hechos tienen `UNIQUE(celda_id, fecha_id)`: una fila por celda y día.
- `fact_incendio` y `fact_clima` no tienen FK entre sí: se cruzan mediante `JOIN` por `celda_id` y `fecha_id`.
- La relación entre MongoDB y PostgreSQL es **lógica**, no una clave foránea física: se resuelve mediante un proceso ETL/ELT que agrupa las detecciones de `detecciones_viirs` por `celda_id` y `fecha` para poblar `fact_incendio` a grano diario; no existe FK entre ambas bases.

3.3 Datos estables y relacionales (SQL) vs. datos flexibles o anidados (NoSQL)

SQL	Malla espacial (geometría fija), calendario, y registros diarios de incendio/clima por celda: estructura homogénea, con integridad referencial (PK/FK) y consultas espaciales de PostGIS.
NoSQL	Detecciones individuales VIIRS: documentos con coordenadas y calidad anidadas, cuyos campos pueden variar según la versión del producto satelital sin romper un esquema fijo.

3.4 Justificación del uso de cada tecnología

¿Por qué PostgreSQL/PostGIS? Porque la malla espacial y los hechos diarios de incendio/clima tienen estructura estable y relaciones claras entre celda, fecha y hecho, lo que se beneficia de PK/FK, restricciones y de las capacidades geospaciales de PostGIS. PostgreSQL resuelve las consultas de agregación por celda-mes (JOIN + GROUP BY).

¿Por qué MongoDB? Porque las detecciones satelitales individuales llegan en JSON semiestructurado y anidado, y su forma puede variar entre versiones del producto sin obligar a migrar un esquema relacional. MongoDB resuelve consultas de agregación documental sobre el detalle crudo de cada detección (conteo, FRP promedio o máximo por celda).

3.5 Consultas que se espera resolver

En SQL: número de detecciones, FRP total y máxima por celda-mes; precipitación acumulada, media y máxima por celda-mes, conservando los meses con clima aunque no haya incendio. El procedimiento agrega primero incendio y clima por separado en dos CTE (incendio_mes, clima_mes) y luego los combina con un LEFT JOIN desde clima hacia incendio por celda_id + anio + mes:

```
WITH incendio_mes AS (
    -- agrega detecciones por celda-mes
    SELECT anio, mes, celda_id, SUM(numero_detecciones) AS detecciones,
           SUM(frp_suma_mw) AS frp_total_mw, MAX(frp_maxima_mw) AS frp_maxima_mw
    FROM fact_incendio JOIN dim_fecha USING (fecha_id) GROUP BY anio, mes, celda_id
),
clima_mes AS (
    -- agrega precipitacion por celda-mes
    SELECT anio, mes, celda_id, SUM(precipitacion_diaria_mm) AS precip_acumulada_mm
    FROM fact_clima JOIN dim_fecha USING (fecha_id) GROUP BY anio, mes, celda_id
)
SELECT c.anio, c.mes, c.celda_id,
       COALESCE(i.detecciones, 0) AS detecciones, -- valido solo si se
       COALESCE(i.frp_total_mw, 0) AS frp_total_mw, -- verifico cobertura VIIRS
       c.precip_acumulada_mm
FROM clima_mes AS c LEFT JOIN incendio_mes AS i USING (anio, mes, celda_id);
```

En MongoDB: conteo y FRP promedio/máximo de detecciones por celda_id, filtrando por el indicador de calidad validada de cada documento (calidad.valida), mediante una canalización de agregación con \$match y \$group.

4. Modelo preliminar de datos

4.1 Tablas principales, claves y granularidad

Tabla	Descripción	PK	FK
dim_celda	Malla espacial de referencia (una fila por celda)	celda_id	—
dim_fecha	Calendario diario del periodo analizado	fecha_id	—
fact_incendio	Registro diario de incendio por celda	incendio_id	celda_id, fecha_id
fact_clima	Registro diario de precipitación por celda	clima_id	celda_id, fecha_id

Granularidad: las tablas de hechos son siempre diarias (`UNIQUE(celda_id, fecha_id)`); la unidad de análisis final, celda-mes, se obtiene agregando esos registros diarios por `celda_id + año + mes` mediante consultas SQL; no existe como filas pre-agregadas en las tablas base.

4.2 Esquema relacional




Figura 1: Modelo relacional preliminar: `dim_celda` y `dim_fecha` se relacionan con `fact_incendio` y `fact_clima` mediante claves foráneas; estas dos últimas se cruzan por `celda_id + fecha_id` sin FK directa entre ellas.

4.3 Ejemplo de documento JSON (NoSQL)

La colección `detecciones_viirs` conserva el detalle individual de cada detección, con fecha y hora exactas; estas detecciones se agregan por `celda_id + fecha` para poblar `fact_incendio` a grano diario.

```

{
  "deteccion_id": "V_2023_TEST_001",
  "celda_id": "LJ_TEST_001",
  "fecha": "2023-08-15",
  "hora_utc": "18:42",
  "fuente": "VIIRS",
  "sensor": "VIIRS_SNPP_375m",
  "frp_mw": 18.4,
  "fire_mask": 7,
  "coordenadas": {
    "longitud": -79.520851,
    "latitud": -3.805328
  },
  "calidad": {
    "valida": true
  }
}

```

4.4 Validación controlada del prototipo

La carga y consulta descritas se verificaron con las dos celdas controladas de la sección 2:

Celda	Detecciones	FRP total / máxima	Precipitación
LJ_TEST_001	1	18,4 / 18,4 MW	12,5 mm
LJ_TEST_002	1	9,7 / 9,7 MW	8,7 mm

Se trata de datos controlados: comprueban el funcionamiento del flujo de carga e integración, no son resultados ambientales representativos y no permiten inferencia alguna para el cantón.

5. Arquitectura preliminar

La figura 2 muestra el flujo de datos desde las fuentes hasta el producto analítico.



Figura 2: Arquitectura preliminar de la solución FireForest.

La orquestación de la ingesta, validación, carga e integración se prevé mediante Airflow; actualmente se encuentra en fase de validación, no operativa por completo.

6. Pregunta analítica, unidad de análisis y dataset esperado

Pregunta analítica: ¿qué asociación existe entre la precipitación acumulada mensual y la presencia o frecuencia de detecciones VIIRS por celda espacial? Esta pregunta no se responde en este avance; requiere el dataset celda-mes consolidado (sección 7).

Unidad de análisis: celda espacial de 500×500 m observada durante un mes, con clave `celda_id` + `año` + `mes`. Las tablas de hechos permanecen a grano diario; la unidad celda-mes se construye por agregación.

Dataset final esperado: una tabla con una fila por celda-mes, que combine identificador de celda y coordenadas, número de detecciones e intensidad de incendio (FRP), y precipitación acumulada/media/máxima del mes.

Cero frente a dato faltante: un valor 0 en detecciones o FRP no equivale automáticamente a cobertura VIIRS comprobada; solo puede leerse como ausencia real de detecciones si se verificó de forma independiente que la cobertura e ingesta VIIRS de ese mes fueron correctas. NULL representa información faltante o no procesada. La prueba de `LEFT JOIN` con `COALESCE` descrita en la sección 3.5 valida el comportamiento de la consulta, no constituye evidencia de cobertura satelital real.

7. Plan preliminar de implementación

#	Actividad	Resultado esperado	Estado
1	Identificación de fuentes y validación territorial de las dos celdas controladas	Fuentes documentadas; celdas verificadas dentro del cantón Loja	Completada
2	Diseño relacional (SQL)	Esquema con PK/FK	Completado
3	Diseño NoSQL	Colección y documento de ejemplo	Completado
4	Carga controlada	Datos cargados en PostgreSQL/PostGIS y MongoDB	Completada
5	Migración territorial de las celdas controladas	Identificadores y coordenadas actualizados en ambas bases	Completada
6	Adquisición de series reales (VIIRS, CHIRPS)	Datos reales incorporados	Pendiente
7	Malla completa de producción	Malla de 500 m para todo el cantón	Pendiente
8	Cobertura VIIRS	Bandera de cobertura verificada por celda-mes	Pendiente
9	Panel completo celda-mes	Dataset consolidado	Pendiente
10	Automatización	Orquestación de ingesta e integración (Airflow)	En validación
11	Análisis y producto final	Indicadores, modelo o reporte	Pendiente

8. Alcance y limitaciones

- **Dominio previsto:** cantón Loja.
- **Cobertura actual:** dos celdas controladas verificadas dentro de la parroquia El Cisne, utilizadas exclusivamente para validación técnica del prototipo (almacenamiento, reproyección, agregación temporal, consultas de integración SQL/NoSQL).
- Este avance corresponde a un **prototipo académico**, no a un sistema operativo de alerta temprana de incendios.
- Dos celdas dentro de una sola parroquia **no constituyen una muestra representativa** de la variabilidad ambiental, altitudinal o climática del cantón; los resultados presentados no describen el comportamiento de los incendios del cantón Loja.
- Las consultas mostradas son ilustrativas: no permiten aún análisis inferencial ni predictivo, ni establecer relación causal entre precipitación e incendios.
- Queda pendiente incorporar series reales completas de VIIRS y CHIRPS, la malla completa de producción y la bandera de cobertura VIIRS.

9. Referencias

- Balaguer-Beser, A., González, F., Chuncho, C. G., Carrión-Paladines, V., & Juela-Sivisaca, O. (2026). Altitudinal variation in fire behavior in Andean ecosystems in southern Ecuador. *Fire Ecology*, 22, Article 46. <https://doi.org/10.1186/s42408-026-00470-y>
- Instituto Nacional de Estadística y Censos (INEC). *Marco Geoestadístico Nacional*. https://www.ecuadorencifras.gob.ec/documentos/web-inec/Geografia_Estadistica/Micrositio_geoportal/descargas.html
- NASA EOSDIS FIRMS. *VIIRS 375 m Active Fire and Thermal Anomalies (VNP14IMG/VJ114IMG)*. <https://firms.modaps.eosdis.nasa.gov>
- Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Shukla, S., Husak, G., Rowland, J., Harrison, L., Hoell, A., & Michaelsen, J. (2015). The climate hazards infrared precipitation with stations – a new environmental record for monitoring extremes. *Scientific Data*, 2, 150066. <https://www.chc.ucsb.edu/data/chirps>
- PostgreSQL Global Development Group. *PostgreSQL Documentation*. <https://www.postgresql.org/docs/>
- PostGIS Project Steering Committee. *PostGIS Documentation*. <https://postgis.net/documentation/>
- MongoDB, Inc. *MongoDB Manual*. <https://www.mongodb.com/docs/>