

ESCUELA SUPERIOR POLITÉCNICA DE CHIMBORAZO (ESPOCH)

DIRECCIÓN DE POSGRADO

Maestría en Estadística con mención en Ciencia de Datos e Inteligencia Artificial

PROYECTO INTEGRADOR

Pipeline de Ingeniería de Datos, Arquitectura Híbrida Multimodelo
y Modelado Predictivo para Incendios Forestales

Aplicación Cantonal Integral: Malla Espacial 500 m × 500 m (7.997 celdas)

Título del Trabajo:

Diseño e Implementación de una Arquitectura Híbrida (SQL, NoSQL, Data Lakehouse y Apache Spark) para la Integración, Monitoreo y Predicción del Riesgo de Incendios Forestales en el Cantón Loja

Autores (Grupo 4):

Malan Mullo, Marco Vinicio
Pujos Culque, Viviana Isabel
Chuncho Morocho, Carlos Guillermo

Docente / Evaluador:

Maestría en Ciencia de Datos e Inteligencia Artificial

Riobamba – Ecuador
Septiembre, 2026

Resumen Ejecutivo

El presente documento constituye la entrega final y sustentación del Proyecto Integrador **FireForest**. El trabajo supera la fase preliminar de dos celdas abordada en el Avance 1 y materializa un pipeline end-to-end de Ingeniería de Datos sobre la totalidad territorial del cantón Loja, compuesto por **7.997 celdas espaciales de 500 m × 500 m** observadas mensualmente a lo largo del año 2023, consolidando un dataset analítico curado de **95.964 registros celda-mes**.

La arquitectura de datos implementada articula una solución híbrida multimodelo justificada caso por caso: (1) **Ingesta controlada y Raw Lake** inmutable con trazabilidad criptográfica SHA-256; (2) Procesamiento distribuido en memoria mediante **Apache Spark (PySpark 4.2.0)** para ejecutar uniones espaciales y transformaciones de series temporales mediante funciones de ventana (lags climáticos de 1 y 2 meses, medias móviles de 3 meses y acumulación de días secos); (3) Almacenamiento relacional y geoespacial en **PostgreSQL 18 / PostGIS** con modelo en estrella e indexación espacial GiST; (4) Repositorio documental NoSQL en **MongoDB 8** para el almacenamiento semiestructurado de telemetría satelital VIIRS y ejecución de pipelines de agregación BSON; (5) **Data Lakehouse en formato columnar Parquet** particionado con compresión Snappy; (6) Entrenamiento de un modelo de Machine Learning supervisado (**Random Forest Classifier**) para clasificación del riesgo de incendio, alcanzando un **ROC-AUC de 0,9912** y un **Recall del 95,97 %**; y (7) Una interfaz interactiva en **Streamlit y Plotly** que incorpora un explorador cartográfico de alta resolución con mapas satelitales tipo Google Earth, perfil vectorial cantonal oficial del INEC y un motor dual de consultas SQL/NoSQL de alta disponibilidad.

Palabras clave: Ingeniería de datos, arquitectura híbrida, PostgreSQL/PostGIS, MongoDB, Apache Spark, incendios forestales, cantón Loja, Machine Learning, Streamlit.

Abstract

This document presents the final delivery of the **FireForest** Integrative Project. Expanding beyond the two-cell proof-of-concept from Milestone 1, this work implements a full end-to-end Data Engineering pipeline across the entire territory of Loja Canton, Ecuador, encompassing **7,997 spatial cells (500 m × 500 m)** tracked monthly throughout 2023, producing a curated analytical dataset of **95,964 cell-month records**.

The hybrid multi-model data architecture features: (1) Immutable controlled ingestion and Raw Lake with SHA-256 cryptographic verification; (2) Distributed in-memory data processing using **Apache Spark (PySpark 4.2.0)** to execute spatial joins and time-series transformations through distributed window functions (1-month and 2-month precipitation lags, 3-month rolling averages, and accumulated dry days); (3) Spatial relational storage in **PostgreSQL 18 / PostGIS** implementing a star schema and GiST indexing; (4) NoSQL document store in **MongoDB 8** for semi-structured VIIRS satellite telemetry and BSON aggregation pipelines; (5) **Columnar Data Lakehouse in Apache Parquet** with Snappy compression; (6) Supervised Machine Learning with a **Random Forest Classifier** achieving a **ROC-AUC of 0.9912** and **Recall of 95.97 %**; and (7) An interactive **Streamlit / Plotly Dashboard** featuring high-definition satellite basemaps, official cantonal boundary overlays, and a dual-engine SQL/NoSQL query runner.

Keywords: Data engineering, hybrid architecture, PostgreSQL/PostGIS, MongoDB, Apache Spark, forest fires, Loja Canton, Machine Learning, Streamlit.

1. Definición y justificación del problema

1.1 Contexto territorial y problemática de los incendios forestales

El cantón Loja, situado en el callejón interandino del sur del Ecuador, se caracteriza por una marcada heterogeneidad topográfica, ecológica y climática. Su relieve abarca desde valles secos y estribaciones premontanas a menos de 1.000 m.s.n.m. hasta crestas andinas y ecosistemas de páramo por encima de los 3.400 m.s.n.m. Investigaciones ecológicas recientes en la región (Balaguer-Beser et al., 2026) demuestran que las variaciones altitudinales y los regímenes de precipitación condicionan fuertemente la dinámica del combustible vegetal, la humedad del suelo y la susceptibilidad del territorio ante el fuego. Durante la temporada seca (mayo a noviembre), las quemas agrícolas no controladas y los periodos prolongados de déficit hídrico desencadenan siniestros forestales recurrentes que destruyen la cobertura vegetal autóctona, degradan fuentes hídricas críticas y ponen en riesgo asentamientos rurales.

1.2 El desafío central de Ingeniería de Datos

A pesar de la disponibilidad de múltiples fuentes abiertas de observación de la Tierra y monitoreo ambiental, el estudio sistemático de los incendios forestales enfrenta severos obstáculos tecnológicos derivados de la dispersión y heterogeneidad de los datos:

1. **Disparidad de formatos y esquemas:** Los focos de calor satelitales (NASA FIRMS VIIRS) se distribuyen como registros puntuales semiestructurados o en tablas CSV/JSON con geometrías flotantes y campos de calidad variables; la climatología (CHIRPS) se presenta como mallas matriciales regulares (GeoTIFF) o tablas periódicas; y la cartografía límite cantonal del INEC se almacena en vectores poligonales (GeoPackage/Shapefile).
2. **Desalineación espacial y temporal:** Las detecciones satelitales se producen con cadencia diaria e irregular según los sobrevuelos orbitales (grano evento-día), mientras que el análisis territorial y la gestión ambiental requieren una agregación sistemática y continua a grano celda-mes.
3. **Limitaciones de arquitecturas tradicionales monomodelos:** Un sistema puramente relacional clásico carece de flexibilidad para almacenar esquemas satelitales cambiantes sin costosas migraciones de DDL, mientras que una base de datos puramente documental NoSQL es ineficiente para ejecutar consultas espaciales topológicas y agregaciones analíticas masivas con garantías de integridad referencial.

Por tanto, el problema fundamental a resolver no radica inicialmente en el entrenamiento de algoritmos estadísticos, sino en la **Ingeniería de Datos**: concebir, implementar y sustentar un pipeline reproducible que capture, limpie, transforme, almacene y cruce de manera eficiente y escalable estas fuentes dispares.

1.3 Actores institucionales y beneficiarios

En el ecosistema territorial del cantón Loja, los beneficiarios y usuarios directos de una solución de datos integrada comprenden:

- **Cuerpo de Bomberos del Cantón Loja:** Receptores de alertas preventivas para orientar el patrullaje territorial y optimizar los tiempos de despacho hacia celdas de alto déficit hídrico acumulado.
- **Gobierno Autónomo Descentralizado (GAD) Municipal de Loja:** Planificadores territoriales encargados de regular el uso del suelo rural y definir políticas de protección de microcuencas.
- **Ministerio del Ambiente, Agua y Transición Ecológica (MAATE):** Gestores de áreas protegidas (Parque Nacional Podocarpus) que requieren trazabilidad cuantitativa de eventos históricos.

- **Comunidades campesinas y comités de gestión de riesgos:** Poblaciones rurales que demandan señalización temprana de temporadas críticas para evitar el uso del fuego agrícola.

2. Pregunta de investigación y objetivos

2.1 Pregunta principal

¿Cómo diseñar e implementar un pipeline completo de ingeniería de datos basado en una arquitectura híbrida multimodelo (SQL, NoSQL, Data Lakehouse y Apache Spark) que integre de forma escalable, reproducible y eficiente series espacio-temporales de detecciones satelitales VIIRS, precipitación CHIRPS y cartografía vectorial del INEC sobre una malla cantonal regular de 500 m × 500 m, permitiendo alimentar simultáneamente consultas analíticas, un dashboard cartográfico y un modelo predictivo de riesgo de incendios en el cantón Loja?

2.2 Preguntas analíticas complementarias resueltas

- **P1 (Asociación lluvia-fuego):** ¿Qué correlación y comportamiento de retardo (lags de 1, 2 y 3 meses) existe entre el déficit acumulado de precipitación y la presencia efectiva de detecciones satelitales de fuego?
- **P2 (Estacionalidad cantonal):** ¿En cuáles meses del año se concentra la máxima radiación térmica (FRP) y cuántas celdas territoriales resultan impactadas de forma simultánea?
- **P3 (Focalización espacial):** ¿Cuáles celdas espaciales de la malla cantonal exhiben mayor recurrencia y severidad de fuego frente a periodos críticos de sequía?
- **P4 (Capacidad predictiva):** ¿Es posible discriminar el riesgo de ocurrencia de incendio en una celda espacial mediante algoritmos de aprendizaje supervisado alimentados con variables de ventana climática generadas en el pipeline?

2.3 Objetivos

Objetivo General: Diseñar, implementar y validar un pipeline end-to-end de ingeniería de datos fundamentado en una arquitectura híbrida (PostgreSQL/PostGIS, MongoDB, Apache Spark y Parquet) para procesar la totalidad de la malla espacial cantonal de Loja (7.997 celdas × 12 meses), entregando un dataset consolidado de 95.964 observaciones apto para analítica avanzada, visualización cartográfica interactiva y clasificación del riesgo de incendios mediante Machine Learning.

Objetivos Específicos:

1. Estructurar e ingerir de manera inmutable las fuentes oficiales y satelitales (malla INEC 500 m, detecciones NASA VIIRS 375 m y precipitación diaria CHIRPS v2.0) garantizando trazabilidad y control criptográfico (SHA-256).
2. Implementar un motor de procesamiento distribuido en **Apache Spark (PySpark)** para calcular transformaciones complejas de series temporales (lags climáticos, medias móviles y matrices de contingencia) y exportar un Data Lakehouse particionado en Parquet.
3. Desplegar una base de datos relacional y geoespacial en **PostgreSQL 18 / PostGIS** con modelo en estrella ('dim_celda', 'dim_fecha', 'fact_celda_mes') optimizado con índices GiST.
4. Configurar una base de datos documental en **MongoDB 8** para el resguardo de telemetría semiestructurada BSON ('evidencia_viirs_celda_mes') y ejecución de pipelines de agregación nativos.
5. Entrenar y evaluar un clasificador de Machine Learning (**Random Forest**) para estimar la probabilidad de incendio celda-mes, cuantificando la importancia relativa de las variables ambientales.

6. Construir un **Dashboard interactivo en Streamlit** con basemaps satelitales de alta definición (estilo Google Earth), contorno cantonal vectorizado y ejecutor dual de tablas SQL/NoSQL para consulta en vivo.

3. Metodología y arquitectura del pipeline

3.1 Flujo de datos end-to-end

La figura 1 ilustra la arquitectura de datos implementada. El pipeline garantiza la transición fluida desde datos crudos inmutables hasta la analítica y visualización en tiempo real.




Figura 1: Arquitectura integral del pipeline de ingeniería de datos FireForest.

3.2 Justificación técnica de motores multimodelo

En concordancia con las buenas prácticas de ingeniería de datos, la selección de tecnologías responde a criterios específicos de rendimiento, estructura de datos y patrones de acceso:

Tabla 1: Matriz de justificación técnica de motores y formatos de almacenamiento.

Tecnología	Paradigma	Componente Asignado	Justificación Técnica y Rol Operacional
PostgreSQL 18 + PostGIS 3.4	Relacional Objeto-Espacial (SQL)	Malla cantonal (<code>dim_celda</code>), calendario (<code>dim_fecha</code>) y hechos (<code>fact_celda_mes</code>)	Garantiza integridad referencial mediante claves primarias y foráneas; implementa polígonos espaciales en proyección UTM 17S con indexación GiST para consultas topológicas eficientes (<code>ST_Area</code> , <code>ST_Intersects</code>).
MongoDB 8.0	Documental NoSQL (BSON)	Colección de telemetría (<code>evidencia_viirs_celda_mes</code>)	Almacena documentos jerárquicos y semi-estructurados con metadatos anidados de <code>bandas</code> (bandas radiométricas, geometrías GeoJSON de puntos). Permite pipelines de agregación rápidos sin costo de esquemas rígidos.
Apache Spark 4.2 (PySpark)	Motor Distribuido en Memoria	Transformaciones pesadas de series de tiempo e integración	Computa uniones espaciales sobre millones de combinaciones celda-día. Ejecuta funciones de ventana temporal sobre particiones distribuidas (<code>Window.partitionBy(cell_id)</code>) sin estrangular la memoria RAM.
Data Lake (Parquet)	Archivo Columnar Inmutable	Capas Clean y Curated del Data Lakehouse	Formato abierto con compresión Snappy (>90 % de reducción respecto a CSV). Su disposición columnar optimiza la lectura analítica (escaneo selectivo de atributos climáticos y de fuego).

4. Inventario de fuentes, variables y unidades de medida

4.1 Fuentes de datos primarias

El pipeline se nutre de tres fuentes consolidadas en el periodo 2023:

- **Malla Espacial Cantonal (INEC):** Marco Geoestadístico Nacional. Se reconstruyó el límite del cantón Loja por disolución de sectores censales bajo código DPA 1101 y se sobrepuso una grilla ortogonal regular con paso de 500 m × 500 m. Todos los vectores se re proyectaron formalmente a EPSG:32717 (WGS84 / UTM Zona 17 Sur).
- **NASA FIRMS VIIRS (Active Fire):** Sensor VIIRS montado sobre la plataforma Suomi-NPP y NOAA-20, con resolución espacial nativa de 375 m en el canal térmico I4 (3,95 μm) e I5 (11,45 μm). Proporciona coordenadas de anomalías térmicas, Potencia Radiativa del Fuego (FRP) y máscara de calidad.
- **CHIRPS v2.0 (Climate Hazards Group):** Estimación de precipitación cuasi-global generada a partir de imágenes infrarrojas de satélites geoestacionarios combinadas con registros pluviométricos de estaciones meteorológicas terrestres (resolución nativa de 0,05°, asignada espacialmente a cada celda de 500 m).

Volumen aproximado: 7.997 celdas × 12 meses = 95.964 combinaciones celda-mes por fuente (VIIRS y CHIRPS), más la malla base de 7.997 polígonos; el Raw Lake ingerido suma 191.928 registros fuente antes de la integración (Tabla 4).

4.2 Restricciones, permisos y riesgos de las fuentes

Licenciamiento y acceso. La malla del Marco Geoestadístico Nacional (INEC) es información pública oficial. NASA FIRMS VIIRS y CHIRPS v2.0 son productos satelitales de acceso abierto (NASA EOSDIS y UCSB Climate Hazards Group, respectivamente), sin restricciones de uso académico.

Procedencia controlada desde FIRELAB_Loja. Para este proyecto en particular, la malla de 500 m ya delimitada al cantón y los extractos VIIRS/CHIRPS agregados a grano celda-mes (2019–2025) se tomaron como **copia de solo lectura** del proyecto científico independiente **FIRELAB_Loja**, autorizada por decisión del equipo del 2026-09-19 y restringida al subconjunto estrictamente necesario para este trabajo (nunca el dataset completo). La copia se ejecutó con un script de ingesta controlada que verifica hash **SHA-256** de cada archivo de origen y deja un manifiesto de procedencia (`05_ingesta/metadatos/manifiesto_firelab_loja.json`) con la ruta de origen, el tamaño en bytes y la fecha de modificación de cada archivo. FIRELAB_Loja nunca se modifica, mueve, renombra ni se ejecutan comandos de escritura dentro de él; FireForest opera únicamente sobre las copias locales versionadas en este repositorio.

Riesgos de calidad identificados. (i) Cobertura VIIRS incompleta: 900 de 95.964 celdas-mes (0,94 %) carecen de soporte observacional del sensor, tratado explícitamente como se detalla en la Sección 5.1; (ii) valores extremos de precipitación y FRP, cuantificados y marcados sin eliminar (Sección 5.3); (iii) celdas con intersección parcial del límite cantonal (828 celdas), conservadas con bandera de completitud en lugar de excluirse silenciosamente (decisión DEC-005, Tabla 3).

Riesgos de seguridad y privacidad. Las tres fuentes son observaciones ambientales agregadas a nivel de celda geográfica de 500 m; no contienen datos personales identificables ni información sensible de individuos, por lo que no aplican restricciones de privacidad de datos personales. El único control de acceso relevante es el de solo lectura sobre FIRELAB_Loja descrito arriba.

4.3 Diccionario formal de variables analíticas

La tabla 2 detalla las variables que estructuran el dataset final curado (`fact_celda_mes`), indicando su significado, fuente, mecanismo de transformación y su unidad de medida estandarizada.

Tabla 2: Diccionario formal de variables del dataset analítico celda-mes.

Variable	Descripción Conceptual	Fuente Origen	Método de Obtención / Transformación	Unidad de Medida
id_celda_mes	Clave compuesta única del grano analítico	Derivada	Concatenación: cell_id_AAAAMM	Texto (ID)
cell_id	Identificador unívoco de la celda de 500m	INEC Malla	Asignación matricial: LJ500_Rxxx_Cyyy	Texto (Código)
longitud	Coordenada horizontal del centroide	INEC Malla	Reproyección de centroide UTM a WGS84	Grados decimales (°)
latitud	Coordenada vertical del centroide	INEC Malla	Reproyección de centroide UTM a WGS84	Grados decimales (°)
area_km2	Superficie geográfica de la celda	INEC Malla	Cálculo vectorial euclidiano: 500 m × 500 m	Kilómetros cuad. (km ²)
area_dentro_loja_ha	Área efectiva de la celda en Loja	INEC Malla	Intersección geográfica con polígono cantonal	Hectáreas (ha)
es_celda_completa	Bandera de integridad perimetral	INEC Malla	Condición booleana: área ≥ 24,9 ha	Booleano (True/False)
anio	Año calendario de la observación	Calendario	Extracción temporal de fecha	Año (entero)
mes	Mes calendario de la observación	Calendario	Extracción temporal (1 a 12)	Mes (entero 1–12)
precipitacion_acumulada_1mm	Lluvia total registrada en el mes	CHIRPS v2.0	Sumatoria de lluvia diaria asignada a la celda	Milímetros (mm)
precip_media_diaria_mm	Precipitación promedio diaria	CHIRPS v2.0	Promedio diario mensual: Acum/Días	Milímetros/día (mm/d)
precip_maxima_diaria_mm	Pico máximo de lluvia en 24 horas	CHIRPS v2.0	Función máxima sobre registros diarios	Milímetros (mm)
dias_secos_lt1mm	Cantidad de días con lluvia < 1 mm	CHIRPS v2.0	Conteo de días con precipitación marginal	Días (d)
dias_humedos_ge1mm	Cantidad de días con lluvia ≥ 1 mm	CHIRPS v2.0	Conteo de días con precipitación efectiva	Días (d)
precip_lag_1m	Precipitación acumulada mes previo	Spark Window	Función lag(precip, 1) sobre celda	Milímetros (mm)
precip_lag_2m	Precipitación acumulada 2 meses atrás	Spark Window	Función lag(precip, 2) sobre celda	Milímetros (mm)
precip_media_movil_3m	Lluvia media de los últimos 3 meses	Spark Window	Media móvil de ventana deslizante: 3 meses	Milímetros (mm)
dias_secos_acumulados_3m	Días secos en el trimestre móvil	Spark Window	Suma de días secos en ventana deslizante 3m	Días (d)
detecciones_incendio	Número de detecciones VIIRS en celda	NASA FIRMS	Conteo espacial de puntos de calor en el mes	Conteo adim. (N)
frp_total_mw	Potencia Radiativa del Fuego acumulada	NASA FIRMS	Suma de radiación térmica de los píxeles	Megavatios (MW)
frp_maxima_mw	Pico máximo de radiación observada	NASA FIRMS	Máximo FRP detectado en la celda-mes	Megavatios (MW)
incendio_observado	Variable objetivo (presencia de fuego)	Derivada	Condición: detecciones > 0 ∨ FRP > 0	Booleano / Clase {0, 1}
probabilidad_riesgo_ml	Probabilidad predictiva de incendio	Random Forest	Inferencia del modelo sobre vector de atributos	Probabilidad [0, 1]
apto_analisis	Control de calidad e integridad	Derivada	Verificación de completitud y soporte satelital	Booleano (True/False)

5. Calidad de datos, proceso ETL y escalabilidad

5.1 Diagnóstico y reglas de limpieza (capa Clean)

El diagnóstico inicial sobre el Raw Lake (191.928 registros fuente: 95.964 VIIRS + 95.964 CHIRPS antes de tipar) identificó cuatro problemas de calidad a resolver antes de integrar: (i) tipos mixtos en identificadores, fechas y booleanos provenientes de CSV/JSON heterogéneos; (ii) 900 celdas-mes sin cobertura observacional del sensor VIIRS; (iii) ruido de punto flotante en fracciones y acumulados de precipitación; y (iv) valores extremos de FRP y precipitación de plausibilidad incierta. Cada problema se resolvió con una regla explícita y documentada en la bitácora de decisiones (Tabla 3), nunca de forma implícita o silenciosa.

Tabla 3: Bitácora de decisiones de limpieza y transformación (extracto).

ID	Problema	Decisión aplicada	Filas
DEC-001	Alcance temporal amplio en los archivos Raw	Filtrar 2023 mediante código, sin modificar Raw	191.928
DEC-002	Fuentes ya agregadas mensualmente	Construir el ETL directamente a grano celda-mes (no inventar granularidad diaria)	191.928
DEC-003	VIIRS no trae <code>cell_id</code>	Integrar por <code>cell_index + anio + mes</code> ; obtener <code>cell_id</code> desde la malla	95.964
DEC-004	900 filas sin observación VIIRS	Conservar nulos (no convertir a cero); marcar <code>observacion_viirs_disponible = false</code>	900
DEC-005	828 celdas con intersección parcial del cantón	Conservar con bandera <code>es_celda_completa</code> , no eliminar	828
DEC-006	Ruido de punto flotante en fracciones/precipitación	Tolerancia 10^{-5} (fracciones) y 10^{-4} mm (precipitación); no redondear Raw	0
DEC-007	Riesgo de deduplicación automática oculta	Detener el flujo ante claves duplicadas; nunca deduplicar en silencio	0
DEC-008	Extremos de FRP y precipitación	Marcar con bandera IQR, no eliminar (pueden ser eventos reales)	15.610
DEC-009	Necesidad de trazabilidad y reuso	Publicar Clean/Curated en CSV y Parquet, con diccionario y manifiesto SHA-256	—

Sobre esa base se aplicaron 16 controles de calidad automáticos a la capa Clean, cubriendo reconciliación de conteos, unicidad de claves, integridad referencial contra la malla, consistencia interna y tratamiento de rechazos críticos; los 16 controles se cumplieron sin incumplimientos (Tabla 4).

5.2 Integración y control de calidad (capa Curated)

La unión uno a uno de VIIRS y CHIRPS Clean por `cell_id + anio + mes` se validó con 11 controles adicionales sobre la capa Curated (cardinalidad previa a la unión, integridad referencial de la unión, reconciliación de conteos, unicidad de la clave final, completitud de la bandera `apto_analisis` y documentación completa del diccionario de variables), también con 11 de 11 controles cumplidos.

Tabla 4: Resumen de controles de calidad automáticos aplicados al pipeline.

Capa	Dimensiones cubiertas	Controles	Cumplidos
Clean	Reconciliación, unicidad, integridad referencial, consistencia, completitud, atípicos, rechazos	16	16 (100%)
Curated	Cardinalidad, integridad referencial, reconciliación, unicidad, completitud, documentación	11	11 (100%)

Evidencia completa: `tarea_ETL/evidencias/controles_clean.csv` y `controles_curated.csv` (27 controles individuales, ver Sección 7.5).

5.3 Tratamiento de valores atípicos

Los extremos de FRP y precipitación se detectaron con el método IQR estándar (límites $Q1 - 1,5 \cdot IQR$ y $Q3 + 1,5 \cdot IQR$) y se marcaron con banderas booleanas dedicadas, sin eliminarlos del dataset: un incendio de alta intensidad o una lluvia extrema son observaciones científicamente válidas, no errores de captura (decisión DEC-008).

Tabla 5: Detección de valores atípicos por método IQR.

Fuente	Variable	Atípicos	%
VIIRS	FRP suma / FRP máxima observada	747	0,79 %
CHIRPS	Precipitación acumulada mensual	13.731	14,31 %
CHIRPS	Precipitación máxima diaria	9.224	9,61 %

5.4 Proceso ETL: Extract, Transform, Load

El pipeline `tarea_ETL/codigo/etl_fireforest.py` implementa las tres fases de forma explícita y reproducible desde un único punto de entrada (`main(desde_cero)`):

- **Extract:** ingesta de los archivos Raw inmutables (malla INEC, VIIRS y CHIRPS copiados de FIRELAB_Loja según el manifiesto SHA-256 de la Sección 4.2) mediante `cargar_malla` y `cargar_csv_periodo`, sin alterar los archivos de origen.
- **Transform:** tipado estricto (`convertir_numericas`, `entero_nullable`, `booleano_nullable`), cálculo de banderas de cobertura y atipicidad (`bandera_atipico`), preparación independiente de cada fuente (`preparar_viirs`, `preparar_chirps`) y unión final a grano celda-mes (`construir_curated`).
- **Load:** escritura determinista en CSV y Parquet (`escribir_csv_dict`, `escribir_dataframe`), generación del diccionario de variables (`construir_diccionario_curated`) y cálculo de hash **SHA-256** de cada archivo de salida (`sha256`) para el manifiesto de procedencia.

La reproducibilidad se garantiza porque el proceso completo se dispara con una única llamada (`python etl_fireforest.py`), es determinista (mismas entradas producen los mismos hashes de salida) y dejan evidencia verificable en `tarea_ETL/evidencias/manifiesto_salidas_clean.csv` y `manifiesto_salidas_curated.csv`.

5.5 Escalabilidad: análisis y justificación de Apache Spark

El dataset consolidado (95.964 filas $\times$ 59 columnas tras las transformaciones de ventana) ocupa del orden de 2 MB en Parquet comprimido y cabe cómodamente en la memoria de un solo nodo: en sentido estricto, **este volumen no exige procesamiento distribuido**. La decisión de incorporar **Apache Spark** respondió a tres criterios técnicos, no al volumen actual: (i) las transformaciones de ventana temporal (*lags* de precipitación, medias móviles, déficit hídrico acumulado) se calculan de forma independiente para cada una de las 7.997 series de tiempo por celda, un patrón que se paraleliza naturalmente mediante `Window.partitionBy(celda_id)` y escala sin cambios de código si el número de celdas o el horizonte temporal crecen; (ii) el trabajo futuro de este proyecto (Sección 7.4) contempla extender la serie histórica a una década completa (2015–2025) y potencialmente a cantones adicionales, escenario en el que el volumen sí justificaría un motor distribuido, por lo que Spark se adopta ahora como base arquitectónica reutilizable; y (iii) permite demostrar, dentro del alcance de la asignatura, el patrón de procesamiento distribuido en memoria como alternativa validada frente a la reimplementación equivalente en `pandas` de la capa Curated.

6. Resultados de la ejecución del pipeline

6.1 Escalado territorial: De 2 celdas a la totalidad cantonal

A diferencia del Avance 1, que ejecutó una prueba de concepto restringida a dos celdas de control en la parroquia El Cisne (`LJ_TEST_001` y `LJ_TEST_002`), la versión final opera de forma integral sobre las **7.997 celdas que conforman el cantón Loja**. Al expandirse a lo largo de los 12 meses de 2023, el pipeline generó y pobló **95.964 filas analíticas**, capturando 747 eventos históricos de fuego activo.




Figura 2: Malla territorial cantonal completa de Loja (7.997 celdas de 500 m × 500 m) procesada en el pipeline.

6.2 Resultados tabulares de Apache Spark (PySpark)

El motor de cómputo distribuido procesó las ventanas temporales en memoria y exportó el Data Lakehouse particionado. La tabla 6 muestra el balance cantonal consolidado mensual resultante de las transformaciones Spark.

Tabla 6: Balance cantonal mensual procesado por Apache Spark (Cantón Loja, 2023).

Mes	Celdas	Precip. Media (mm)	Lag 1m (mm)	Media Móvil 3m	Días Secos 3m	Celdas Fuego	FRP Total (MW)
1	7.997	64,80	n/d	64,80	21,0	7	17,71
2	7.997	92,35	64,80	78,57	42,7	0	0,00
3	7.997	312,28	92,35	156,47	61,7	0	0,00
4	7.997	325,82	312,28	243,48	58,5	0	0,00
5	7.997	29,03	325,82	222,38	65,5	0	0,00
6	7.997	16,73	29,03	123,86	73,8	16	424,52
7	7.997	16,73	16,73	20,83	85,8	26	191,17
8	7.997	24,05	16,73	19,17	85,6	143	2.512,57
9	7.997	16,61	24,05	19,13	85,8	306	6.295,15
10	7.997	78,31	16,61	39,65	76,0	201	6.910,86
11	7.997	68,18	78,31	54,37	69,5	42	347,58
12	7.997	76,65	68,18	74,38	65,9	6	24,77

Hallazgo hidrológico fundamental: Como se aprecia en la tabla 6 y la figura 3, los incendios no ocurren de forma inmediata al comenzar la disminución de lluvia. Requieren un **tiempo de latencia de 2 a 3 meses de déficit hídrico continuado**: la precipitación cayó abruptamente en mayo (29mm), pero el pico catastrófico de incendios se concentró en septiembre (306 celdas afectadas y 6,295 MW de FRP) tras acumularse cerca de 86 días secos en el trimestre antecedente.




Figura 3: Evolución temporal 2023: Dinámica de precipitación vs. potencia radiativa del fuego (FRP).

6.3 Resultados de consultas en PostgreSQL / PostGIS

En la base de datos relacional **fireforest**, las consultas SQL permitieron auditar las relaciones dimensionales y ejecutar filtros espaciales. La tabla 7 presenta las celdas con mayor intensidad de fuego detectadas mediante uniones relacionales y funciones PostGIS.

Tabla 7: Top celdas con mayor liberación térmica (FRP) registradas en PostgreSQL/PostGIS.

Celda ID	Mes	Longitud (°)	Latitud (°)	Precip (mm)	FRP (MW)	Geometría PostGIS	Área (m ²)
LJ500_R031_C075	Octubre	-79,2090	-4,3699	97,95	327,90	ST_Polygon	250.000
LJ500_R031_C076	Octubre	-79,2045	-4,3699	97,95	246,57	ST_Polygon	250.000
LJ500_R121_C056	Septiembre	-79,2955	-3,9632	13,91	242,80	ST_Polygon	250.000
LJ500_R032_C075	Octubre	-79,2090	-4,3654	97,95	224,25	ST_Polygon	250.000
LJ500_R031_C077	Octubre	-79,2000	-4,3699	99,17	205,90	ST_Polygon	250.000
LJ500_R030_C075	Octubre	-79,2090	-4,3744	97,95	196,74	ST_Polygon	250.000
LJ500_R121_C057	Septiembre	-79,2910	-3,9632	13,91	194,80	ST_Polygon	250.000
LJ500_R033_C075	Octubre	-79,2090	-4,3608	97,95	189,70	ST_Polygon	250.000

6.4 Resultados de agregaciones NoSQL en MongoDB

El cluster MongoDB ejecutó canalizaciones documentales (*aggregation pipelines*) sobre la colección **evidencia_viirs_celda_mes**. El código 4 ilustra la agregación mensual y la tabla 8 resume su ejecución nativa:

```
[
  { "$group": {
    "_id": "$periodo.anio_mes",
    "total_documentos": { "$sum": 1 },
    "fuegos_observados": { "$sum": { "$cond": ["$telemetry.evidencia_fuego", 1, 0] } },
    "frp_acumulado_mw": { "$sum": "$telemetry.frp_suma_mw" },
    "precip_promedio_mm": { "$avg": "$clima_asociado.precipitacion_mm" }
  } },
  { "$sort": { "_id": 1 } }
]
```


Figura 4: Pipeline de agregación BSON ejecutado en MongoDB 8.

Tabla 8: Resultados de la canalización de agregación en MongoDB (`evidencia_viirs_celda_mes`).


Periodo (<code>_id</code>)	Total Documentos BSON	Fuegos Confirmados	FRP Suma (MW)	Precip. Media (mm)
2023-01	46	7	17,71	60,89
2023-02	37	0	0,00	92,86
2023-03	35	0	0,00	297,88
2023-04	29	0	0,00	339,47
2023-05	33	0	0,00	29,02
2023-06	53	16	424,52	14,98
2023-07	61	26	191,17	13,80
2023-08	188	143	2.512,57	13,98
2023-09	348	306	6.295,15	15,44
2023-10	246	201	6.910,86	84,41
2023-11	75	42	347,58	66,85
2023-12	49	6	24,77	75,92

6.5 Modelo de Machine Learning: Clasificación de Riesgo de Incendio

Del dataset consolidado `celda-mes` (95.964 filas) se excluyeron las 900 filas sin cobertura VIIRS (`apto_analisis = False`; véase la Sección 7.2) y se particionó el subconjunto `apto` restante (**95.064 filas**) en un 80 % para entrenamiento (76,051 observaciones) y un 20 % para evaluación independiente (19,013 observaciones), estratificando por la variable binaria `incendio_observado`. Se entrenó un clasificador **Random Forest** balanceando los pesos de clase para contrarrestar el desbalance natural de eventos (0,79 % de presencia de fuego, 747 casos positivos).



(a) Matriz de confusión (Test Set: 19.013 celdas-mes).



(b) Importancia relativa de características (Gini Importance).

Figura 5: Evaluación cuantitativa del modelo predictivo Random Forest, reentrenado tras excluir las filas no aptas.

Las métricas obtenidas en el conjunto de prueba, tras la corrección descrita en la Sección 7.2, son las siguientes:

- **Área bajo la Curva ROC (ROC-AUC): 0,9912.** Mantiene una separabilidad casi perfecta entre clases.
- **Sensibilidad / Exhaustividad (Recall): 95,97 %** (143 de 149 incendios reales detectados en el test set). En gestión de emergencias ambientales, minimizar los falsos negativos es el objetivo primordial para evitar incendios desatendidos.
- **Precisión: 15,61 % y Puntuación F1: 0,2685.**
- **Variables determinantes (Figura 5b):** 1. `dias_secos_acumulados_3m` (20,16 %): El déficit hídrico acumulado en tres meses sigue siendo el principal detonante. 2. `precip_lag_2m` (18,04 %) y `precip_media_movil_3m` (13,10 %): La memoria hídrica antecedente. 3. `fila` (11,50 %):

variable de índice espacial de la malla; su alta importancia evidencia que los incendios no se distribuyen uniformemente en el territorio sino que se agrupan en determinadas franjas cantonales, patrón a profundizar en trabajo futuro con covariables topográficas explícitas (pendiente, orientación).

Nota técnica sobre el cambio de métricas: La precisión y el F1-Score descienden de forma notoria respecto a la versión del modelo entrenada antes de la corrección (55,27 % y 0,7029, respectivamente, con las 900 filas no aptas incluidas como clase negativa). Esta caída no refleja un modelo peor, sino una estimación más honesta: las 900 filas excluidas actuaban como negativos artificialmente “limpios” que el clasificador aprovechaba para inflar su precisión aparente, sin que existiera evidencia satelital real que respaldara esa etiqueta. Al eliminarlas, el modelo se evalúa únicamente sobre las 95.064 celdas-mes con observación VIIRS confirmada, exponiendo la dificultad real de discriminar el 0,79 % de eventos positivos dentro de un dataset severamente desbalanceado. El Recall se mantiene prácticamente inalterado (95,97 % frente a 96,64 %), lo que confirma que la capacidad del modelo para detectar incendios reales no depende del sesgo de etiqueta corregido.

6.6 Dashboard interactivo de consumo y motor dual

Como entregable final de explotación analítica, se desarrolló una aplicación web interactiva en **Streamlit / Plotly** estructurada en seis secciones temáticas:

1. **Arquitectura y Motores:** Diagrama visual interactivo y matriz comparativa de roles tecnológicos.
2. **Explorador Geoespacial (7.997 celdas):** Mapeo cartográfico que integra **imágenes satelitales de alta definición (estilo Google Earth / Esri World Imagery)**, el trazado vectorial del **límite cantonal oficial del INEC** (línea cian de alto contraste) y capas selectivas de focos de calor o precipitación por mes.
3. **Consultas y Tablas de Resultados (SQL / NoSQL / Spark):** Módulo con pestañas independientes que ejecutan y descargan en CSV las tablas de PostgreSQL/PostGIS, MongoDB BSON, Apache Spark y el Data Mart Curated (95.964 filas con búsqueda de celda).
4. **Análisis Clima vs. Incendios:** Gráficos de series temporales sincronizadas y matrices de dispersión.
5. **Predictor de Riesgo (ML):** Simulador en tiempo real que permite ajustar precipitación y días secos para clasificar el nivel de riesgo territorial y su probabilidad asociada.
6. **Auditoría y Trazabilidad:** Verificación de metadatos, hashes de ingesta y política de protección científica.

Innovación del Motor Dual de Consultas: Para garantizar que el dashboard sea 100 % funcional tanto en servidores con motores de base de datos instalados como en computadores de evaluación docente o plataformas en la nube (Streamlit Cloud), se implementó un **Motor Dual Inteligente**: si detecta conexión a PostgreSQL o MongoDB, corre en vivo; de lo contrario, conmuta automáticamente a un motor local embebido (SQLite con funciones PostGIS emuladas y agregador JSON en memoria), asegurando que todas las tablas y consultas se generen de inmediato sin errores.

7. Discusión, conclusiones y trabajo futuro

7.1 Discusión de hallazgos científicos y de ingeniería

Alcance, población de referencia y utilidad de los resultados. Todos los indicadores, tablas y métricas presentados en la Sección 6 describen una única población de referencia bien acotada: las **7.997 celdas espaciales de 500 m × 500 m del cantón Loja, observadas mensualmente durante el año calendario 2023** (95.964 combinaciones celda-mes, 95.064 con observación VIIRS válida). Su utilidad práctica es doble: (i) para los actores institucionales identificados en la Sección 1.3 (Cuerpo de Bomberos, GAD Municipal, MAATE, comités de gestión de riesgos), permite priorizar

patrullaje y alertas tempranas por celda y mes con base en déficit hídrico acumulado; (ii) para el propio pipeline, sirve como prueba de concepto reproducible antes de escalarlo a otros periodos o cantones. Estos resultados **no deben generalizarse automáticamente** fuera de ese alcance: no se ha validado el comportamiento del modelo en otros años (con regímenes de precipitación distintos a 2023), en otros cantones con cobertura vegetal o relieve diferentes, ni bajo cambios en la resolución o disponibilidad futura de los sensores VIIRS/CHIRPS. La Sección 7.2 documenta además una limitación específica de cobertura observacional dentro de esta misma población de referencia.

La integración de datos demostró empíricamente que la ocurrencia de incendios en el cantón Loja no responde únicamente a la ausencia puntual de precipitación en un mes determinado, sino al **agotamiento acumulado de la reserva hídrica durante al menos 60 a 90 días continuos**. En términos de ingeniería de datos, intentar modelar este fenómeno únicamente con una base de datos relacional hubiera requerido complejas y lentas consultas recursivas para calcular los retardos temporales; la incorporación de **Apache Spark** resolvió este cuello de botella al permitir el cálculo particionado de funciones de ventana en cuestión de segundos sobre decenas de miles de registros.

Asimismo, la coexistencia de **MongoDB** para el almacenamiento del detalle crudo de eventos satelitales y de **PostgreSQL/PostGIS** para el análisis topológico y relacional de la malla cantonal validó las ventajas del paradigma multimodelo: máxima flexibilidad en la captura de telemetría y máxima consistencia e indexación espacial en la consolidación territorial.

7.2 Limitación detectada y corregida: pérdida de la semántica de no-observación VIIRS en la capa de cómputo distribuido

Durante el desarrollo del motor de cómputo distribuido se identificó una inconsistencia entre el contrato de calidad definido en la capa Curated y el comportamiento efectivo de las transformaciones ejecutadas en Apache Spark, con implicaciones directas sobre la variable objetivo del modelo predictivo. La inconsistencia fue corregida antes de esta entrega; esta sección documenta el defecto, su causa técnica y la corrección aplicada.

Descripción técnica del defecto. La capa Curated construida en **pandas** define la bandera booleana `apto_analisis` como la conjunción `observacion_viirs_disponible & observado_mes_chirps & cobertura_chirps_valida`, y los controles de calidad internos CLE-06 y CUR-06 verifican explícitamente que las **900 filas celda-mes sin cobertura del sensor VIIRS (0,94 % de las 95.964 filas)** se conserven con valores nulos y se marquen como `apto_analisis = False`, en lugar de interpretarse como ausencia confirmada de incendio. Este subconjunto válido documentado es de **95.064 filas**. Sin embargo, el motor **Apache Spark** (`spark_etl_pipeline.py`) ingiere directamente los Parquet de la capa Clean (`viirs_2023.parquet`, `chirps_2023.parquet`) y, en su versión original, no calculaba la bandera `apto_analisis`: la variable objetivo se construía como `F.when(col("viirs_evidencia_fuego").isNull(), col(...)).otherwise(False)`, colapsando el valor nulo (sin observación satelital) al mismo símbolo que representa la ausencia confirmada de fuego. Como el clasificador **Random Forest** (`entrenar_modelo_riesgo.py`) se entrena tomando `incendio_observado` directamente desde la salida de Spark, las 95.964 filas usadas en la partición 80/20 original (76,771 + 19,193) incluían las 900 filas que la propia capa Curated había declarado no aptas.

Causa raíz. La discrepancia obedeció a tres factores concurrentes: (1) el contrato de calidad `apto_analisis` se diseñó y validó únicamente dentro del prototipo de ingeniería en **pandas** (capas Clean/Curated), mientras que el motor Spark se implementó como una reintegración independiente de malla, clima e incendios a partir de las mismas fuentes crudas Clean, sin recalcular explícitamente esa bandera; (2) las funciones de ventana distribuidas (`Window.partitionBy(celld_id").orderBy("mes"), lag, medias móviles`) requieren series numéricas continuas, y `coalesce(..., 0)` es el idiom estándar en PySpark para evitar la propagación de nulos a través de esas ventanas; este patrón, válido para las variables de soporte numérico, se aplicó por extensión a la variable objetivo sin distinguir “sin observación” de “cero confirmado”; y (3) no existía, al momento del desarrollo inicial, un control de calidad equivalente a CLE-06/CUR-06 sobre la salida de Spark ni sobre el dataset de entrenamiento, por lo que la ausencia de la bandera no fue capturada

por las verificaciones automáticas existentes, que auditan Clean y Curated pero no el Data Lakehouse distribuido ni el conjunto de entrenamiento del modelo.

Corrección aplicada. Se modificó `spark_etl_pipeline.py` para calcular `apto_analisis` directamente en la capa Clean, replicando la misma fórmula que Curated (`observacion_viirs_disponible` $\wedge$ `observado_mes` $\wedge$ `cobertura_chirps_valida`, columnas ya disponibles en los Parquet de `mallá`, `chirps` y `viirs`), sin acoplar el motor distribuido a un artefacto previo calculado en `pandas` sobre un único nodo. La variable `incendio_observado` se dejó nula cuando no hay observación VIIRS, en lugar de coalescerse a `False`. En `entrenar_modelo_riesgo.py` se reemplazó el filtro previo (`cobertura_chirps_valida`, que en la práctica no excluía ninguna fila) por un filtro explícito `apto_analisis == True`, y se reentrenó el clasificador Random Forest únicamente sobre las 95.064 filas aptas. El pipeline Spark y el reentrenamiento se ejecutaron de extremo a extremo para esta entrega; los resultados actualizados se reportan en la Tabla 6 (Sección 6.2) y en la Figura 5 (Sección 6.5).

Impacto verificado sobre el modelo. El Recall se mantuvo prácticamente inalterado (95,97 % frente al 96,64 % original), confirmando que la capacidad de detección de incendios reales no dependía del sesgo de etiqueta. En cambio, la Precisión y el F1-Score cayeron de forma notoria (55,27 % $\rightarrow$ 15,61 % y 0,7029 $\rightarrow$ 0,2685): las 900 filas excluidas actuaban como negativos artificialmente “limpios” que el clasificador original aprovechaba para inflar su precisión aparente, sin evidencia satelital real que respaldara esa etiqueta. Las métricas corregidas constituyen, por tanto, una estimación más honesta del desempeño del modelo sobre el 0,79 % de eventos positivos realmente observados, y se detallan en la Sección 6.5.

Hallazgo adicional durante la corrección. Al reejecutar el pipeline Spark se detectó que la Tabla 6 (balance mensual) de la versión previa de este informe contenía valores de agosto a diciembre que no correspondían a ninguna salida real del pipeline (ni la histórica ni la reejecutada), aunque sí coincidían con los meses de enero a julio. Se verificó además, consultando directamente las instancias vivas de **PostgreSQL** y **MongoDB**, que ambos motores ya contenían datos correctos y consistentes entre sí (cargados de forma independiente desde la capa Curated en `pandas`, no afectada por el defecto de Spark), y que la desviación estaba únicamente en el texto estático de este informe: la Tabla 7 (PostgreSQL) y la Tabla 8 (MongoDB) se corrigieron con los resultados verificados de sendas consultas en vivo.

7.3 Conclusiones

1. Se completó con éxito el pipeline end-to-end de ingeniería de datos para el cantón Loja, superando la fase prototipo del Avance 1 y alcanzando la **cobertura cantonal total con 7.997 celdas y 95.964 observaciones celda-mes analizadas**.
2. La arquitectura híbrida (SQL, NoSQL, Data Lakehouse y Spark) satisfizo plenamente los requerimientos de modularidad, trazabilidad criptográfica (SHA-256) y escalabilidad computacional.
3. Las consultas analíticas respondieron rigurosamente a las preguntas de investigación, identificando el trimestre agosto–octubre como la ventana crítica de mayor severidad térmica ($> 15,700$ MW acumulados).
4. El modelo de Machine Learning alcanzó un **ROC-AUC de 0,9912** y un **Recall de 95,97 %** tras excluir del entrenamiento las celdas-mes sin observación VIIRS (Sección 7.2), demostrando que el pipeline de ingeniería suministró características de alta relevancia física para la prevención del fuego.
5. El dashboard interactivo en Streamlit cumple como interfaz unificada de visualización cartográfica satelital y generación instantánea de tablas analíticas con tolerancia a fallos mediante su motor dual.

7.4 Recomendaciones y trabajo futuro

- Extender la serie histórica procesada por el pipeline a una década completa (2015–2025) aprovechando la capacidad de procesamiento paralelo de Apache Spark.

- Incorporar variables biogeofísicas complementarias en futuras versiones, tales como el Índice de Vegetación de Diferencia Normalizada (NDVI) de Sentinel-2 y modelos digitales de elevación (DEM ALOS PALSAR).
- Operacionalizar la orquestación mediante flujos de trabajo programados (Apache Airflow) para ejecución automática mensual conforme se publiquen nuevas imágenes satelitales.

7.5 Evidencias técnicas y reproducibilidad

El proyecto completo (código, datos Clean/Curated, evidencias de calidad y el propio informe) está versionado en el repositorio <https://github.com/cguillermo79/FireForest.git>. Los artefactos clave para revisar y reproducir este trabajo son:

- **ETL:** `tarea_ETL/codigo/etl_fireforest.py` (Extract/Transform/Load, Sección 5.4) y `evaluar_calidad_raw.py`; evidencias en `tarea_ETL/evidencias/` (`controles_clean.csv`, `controles_curated.csv`, `bitacora_decisiones.csv`, `estadisticas_atipicos.csv`, `manifiesto_salidas_clean.csv`, `manifiesto_salidas_curated.csv`).
- **Procesamiento distribuido:** `pipeline/spark_etl_pipeline.py`; salida particionada en `pipeline/curated_spark_parquet/`.
- **Carga en bases de datos de producción:** `bases_datos/sql_postgis/cargar_produccion_postgres.py` y `bases_datos/nosql_mongodb/cargar_produccion_mongodb.py`.
- **Modelo predictivo:** `machine_learning/entrenar_modelo_riesgo.py`; artefactos entrenados `modelo_random_forest_fireforest.joblib` y `metricas_ml.json`.
- **Dashboard:** `dashboard/app.py`, publicado en <https://fireforest-loja.streamlit.app/>.
- **Procedencia de datos de terceros:** `05_ingesta/metadatos/manifiesto_firelab_loja.json` (hashes SHA-256 y rutas de origen de los archivos copiados de FIRELAB_Loja, Sección 4.2).

Cada capa (Clean, Curated, Spark, ML) se ejecuta de forma independiente con un único comando por script, sobre las mismas fuentes versionadas, y produce salidas deterministas verificables por hash SHA-256, lo que permite a un tercero reproducir cualquier resultado reportado en este documento sin acceso a información adicional no versionada.

8. Referencias bibliográficas

- Balaguer-Beser, A., González, F., Chunchu, C. G., Carrión-Paladines, V., & Juela-Sivisaca, O. (2026). Altitudinal variation in fire behavior in Andean ecosystems in southern Ecuador. *Fire Ecology*, 22, Article 46. <https://doi.org/10.1186/s42408-026-00470-y>
- Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Shukla, S., Husak, G., Rowland, J., Harrison, L., Hoell, A., & Michaelsen, J. (2015). The climate hazards infrared precipitation with stations – a new environmental record for monitoring extremes. *Scientific Data*, 2, 150066. <https://doi.org/10.1038/sdata.2015.66>
- Instituto Nacional de Estadística y Censos (INEC). (2022). *Marco Geoestadístico Nacional: División Político-Administrativa y Zonas Censales*. INEC Ecuador.
- NASA EOSDIS FIRMS. (2023). *VIIRS 375 m Active Fire and Thermal Anomalies (VNP14IMG / VJ114IMG)*. National Aeronautics and Space Administration. <https://firms.modaps.eosdis.nasa.gov>
- PostgreSQL Global Development Group. (2024). *PostgreSQL 16/18 Documentation: Spatial Object-Relational Database System*. <https://www.postgresql.org/docs/>
- PostGIS Project Steering Committee. (2024). *PostGIS 3.4 Spatial Database Extender for PostgreSQL*. <https://postgis.net/documentation/>
- MongoDB, Inc. (2024). *MongoDB Documentation: The Developer Data Platform and Document Store*. <https://www.mongodb.com/docs/>
- Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., Meng, X., Rosen, J., Venkataraman, S., Franklin, M. J., Ghodsi, A., Gonzalez, J., Shenker, S., & Stoica, I. (2016). Apache Spark: A unified engine for big data processing. *Communications of the ACM*, 59(11), 56–65.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.