



**Autores (Grupo 4):**

Marco Vinicio Malan Mullo

Viviana Isabel Pujos Culque  
Morocho

Carlos Guillermo Chuncho

Escuela Superior Politécnica de Chimborazo (ESPOCH)  
Maestría en Estadística con mención en Ciencia de Datos e Inteligencia Artificial

Septiembre, 2026

# Estructura de la Sustentación

## I. Fundamentación & Datos

- Problema territorial y pregunta de investigación.
- Objetivos del proyecto integrador.
- Fuentes primarias y diccionario de variables.
- Salto de escala: De 2 celdas a la malla cantonal (7.997 celdas  $\times$  12 meses).

## II. Arquitectura de Ingeniería

- Arquitectura multimodelo (SQL, NoSQL, Lakehouse).
- Procesamiento distribuido con Apache Spark.

## III. Resultados & Evidencias Tabulares

- Resultados en Spark SQL (Lags y Días Secos).
- Resultados en PostgreSQL / PostGIS (Polígonos).
- Resultados en MongoDB 8 (Pipelines BSON).

## IV. Explotación, Modelado & Cierre

- Modelo Machine Learning (Random Forest ROC 0,9912).
- Dashboard Streamlit (Mapas Satelitales y Tablas).
- Conclusiones, trazabilidad y gobernanza.

# Definición del Problema y Pregunta de Investigación

## Contexto Territorial (Cantón Loja)

- Topografía andina contrastante ( $< 1,000$  a  $> 3,400$  m.s.n.m.).
- Déficit hídrico estacional severo (mayo–noviembre) que incrementa la inflamabilidad vegetal (Balaguer-Beser et al., 2026).
- Impacto directo en fuentes de agua, biodiversidad y poblaciones rurales.

## El Desafío de Ingeniería de Datos

- Fuentes dispersas, no alineadas y multiformato (INEC, NASA VIIRS 375m, UCSB CHIRPS).
- Desfase temporal: Detecciones satelitales a grano diario vs. análisis territorial a grano

## Pregunta Central de Investigación

*¿Cómo estructurar e implementar una arquitectura híbrida (SQL, NoSQL, Data Lakehouse y Spark) que permita integrar, validar y consultar de forma escalable datos heterogéneos de incendios forestales sobre toda la malla cantonal de Loja para alimentar simultáneamente consultas analíticas, un dashboard cartográfico y modelos predictivos?*

**Beneficiarios:** Bomberos Loja, MAATE, GAD Loja y comunidades rurales.

# Objetivos del Proyecto Integrador

## Objetivo General

**Diseñar, implementar y validar un pipeline end-to-end de ingeniería de datos** basado en una arquitectura multimodelo (PostgreSQL/PostGIS, MongoDB, Apache Spark y Parquet) para procesar las **7.997 celdas del cantón Loja durante los 12 meses de 2023 (95.964 registros)**, habilitando analítica avanzada, exploración interactiva y predicción de riesgo con Machine Learning.

### 1. Ingesta & Spark

Captura inmutable con hashes SHA-256; transformaciones de ventana en PySpark (lags y días secos).

### 2. Bases Híbridas

Esquema relacional estrella en PostgreSQL/PostGIS y repositorio documental semiestructurado en MongoDB 8.

### 3. ML & Dashboard

Clasificador Random Forest (ROC 0,9912) y Dashboard Streamlit con mapas satelitales y tablas duales.

# Inventario de Fuentes y Diccionario de Variables

| Variable            | Concepto                     | Fuente       | Transformación               | Unidad       |
|---------------------|------------------------------|--------------|------------------------------|--------------|
| cell_id             | ID único celda 500m          | INEC Malla   | Malla ortogonal (EPSG:32717) | Texto        |
| longitud/latitud    | Coordenadas centroide        | INEC Malla   | Reproyección a WGS84         | Grados (°)   |
| precip_acumulada_mm | Lluvia mensual acumulada     | CHIRPS v2.0  | Suma diaria mensual          | mm           |
| dias_secos_lt1mm    | Días con lluvia < 1 mm       | CHIRPS v2.0  | Conteo mensual               | Días         |
| precip_lag_1m       | Lluvia mes anterior          | Spark Window | lag(precip,1) por celda      | mm           |
| dias_secos_acum_3m  | Días secos en 3 meses        | Spark Window | Suma ventana deslizante 3m   | Días         |
| frp_total_mw        | Potencia radiativa del fuego | NASA FIRMS   | Suma FRP de píxeles térmicos | MW           |
| incendio_observado  | Presencia real de fuego      | Derivada     | detecciones > 0 ∨ FRP > 0    | Clase {0, 1} |

# Salto de Escala: De 2 Celdas a la Malla Cantonal Completa

## Avance 1 (Fase Prototipo)

- Solo 2 celdas de prueba (LJ\_TEST\_001 y 002) en El Cisne.
- 2 registros para validar conectividad.
- Sin inferencia territorial ni estacional.

## Entrega Final (Malla Cantonal Completa)

- **7.997 celdas espaciales de 500m × 500m.**
- **12 meses** completos del año 2023.
- **95.964 observaciones celda-mes.**
- **747 eventos históricos de fuego activo** registrados y procesados.




Figura: Cobertura cantonal total en CRS EPSG:32717 (Loja, Ecuador).

# Arquitectura de Datos Híbrida Multimodelo

**Fuentes Inmutables:** Malla INEC (GPKG) · NASA VIIRS (CSV) · CHIRPS (Parquet)

**Raw Data Lake:** Verificación SHA-256 · Ingesta Controlada

**Apache Spark 4.2 (PySpark):** Window Functions (Lags 1m, 2m, Días Secos 3m)

**Parquet**  
Data Lakehouse  
Particionado

**MongoDB 8**  
Telemetría BSON  
GeoJSON 2dsphere

**PostgreSQL 18**  
PostGIS GiST  
dim / fact

## Justificación por Caso de Uso

- **PostgreSQL / PostGIS:** Integridad referencial (PK/FK), topología espacial de celdas con índices GiST.
- **MongoDB 8:** Esquema flexible para telemetría satelital anidada BSON y agregaciones rápidas.
- **Apache Spark:** Procesamiento masivo de series de tiempo sin saturar memoria.
- **Data Lake Parquet:** Compresión Snappy (>90 %) y acceso columnar OLAP.

# Procesamiento Distribuido en Apache Spark (PySpark)

## Funciones de Ventana Temporal (Window Functions)

Transformaciones computadas en memoria sobre particiones por celda:


- `lag(col("precip"), 1)`: Precipitación mes previo.
- `lag(col("precip"), 2)`: Precipitación 2 meses atrás.
- `avg(col("precip")).rowsBetween(-2, 0)`: Media móvil trimestral.
- `sum(col("dias_secos")).rowsBetween(-2, 0)`: Días secos acumulados en el trimestre.

## Exportación Optimizada

Data Lakehouse particionado físicamente por año y mes en formato columnar Parquet.

## Descubrimiento Analítico de la Dinámica

**El fuego tiene memoria hídrica:** La lluvia disminuye en mayo (29 mm), pero los incendios no estallan hasta agosto–octubre (> 15,700 MW acumulados) tras acumular cerca de **86 días secos consecutivos**.



# Resultados Tabulares: Balance Cantonal en Apache Spark

| Mes               | Celdas Activas | Precip. Media (mm) | Lag 1m (mm)  | Días Secos 3m | Celdas Fuego | FRP Total (MW)  |
|-------------------|----------------|--------------------|--------------|---------------|--------------|-----------------|
| Enero             | 7.997          | 64,80              | n/d          | 21,0 d        | 7            | 17,71           |
| Febrero           | 7.997          | 92,35              | 64,80        | 42,7 d        | 0            | 0,00            |
| Marzo             | 7.997          | 312,28             | 92,35        | 61,7 d        | 0            | 0,00            |
| Abril             | 7.997          | 325,82             | 312,28       | 58,5 d        | 0            | 0,00            |
| Mayo              | 7.997          | 29,03              | 325,82       | 65,5 d        | 0            | 0,00            |
| Junio             | 7.997          | 16,73              | 29,03        | 73,8 d        | 16           | 424,52          |
| Julio             | 7.997          | 16,73              | 16,73        | 85,8 d        | 26           | 191,17          |
| <b>Agosto</b>     | <b>7.997</b>   | <b>24,05</b>       | <b>16,73</b> | <b>85,6 d</b> | <b>143</b>   | <b>2.512,57</b> |
| <b>Septiembre</b> | <b>7.997</b>   | <b>16,61</b>       | <b>24,05</b> | <b>85,8 d</b> | <b>306</b>   | <b>6.295,15</b> |
| <b>Octubre</b>    | <b>7.997</b>   | <b>78,31</b>       | <b>16,61</b> | <b>76,0 d</b> | <b>201</b>   | <b>6.910,86</b> |
| Noviembre         | 7.997          | 68,18              | 78,31        | 69,5 d        | 42           | 347,58          |
| Diciembre         | 7.997          | 76,65              | 68,18        | 65,9 d        | 6            | 24,77           |

Total acumulado 2023: 747 celdas-mes con fuego | 16.724,33 MW de FRP total liberada en el cantón.

# Resultados en PostgreSQL / PostGIS (Modelo Estrella)

## Esquema Dimensional

- dim\_celda: 7.997 polígonos (ST\_MakeEnvelope, SRID 32717, índice GiST).
- dim\_fecha: Calendario mensual 2023.
- fact\_celda\_mes: 95.964 filas con PK/FK.

## Consulta de Auditoría SQL

```
SELECT count(*) FROM fact_celda_mes f JOIN dim_celda c ON  
f.cell_id = c.celda_id WHERE f.incendio_observado = true; → 747  
eventos.
```

## Top 5 Celdas con Mayor Radiación FRP (PostGIS):

| Celda ID        | Mes | Precip  | FRP      | Geom    | Área  |
|-----------------|-----|---------|----------|---------|-------|
| LJ500_R031_C075 | Oct | 98,0 mm | 327,9 MW | Polygon | 25 ha |
| LJ500_R031_C076 | Oct | 98,0 mm | 246,6 MW | Polygon | 25 ha |
| LJ500_R121_C056 | Sep | 13,9 mm | 242,8 MW | Polygon | 25 ha |
| LJ500_R032_C075 | Oct | 98,0 mm | 224,3 MW | Polygon | 25 ha |
| LJ500_R031_C077 | Oct | 99,2 mm | 205,9 MW | Polygon | 25 ha |

# Resultados NoSQL en MongoDB 8 (Telemetría BSON)

## Colección Documental (evidencia\_viirs)

- Estructura semiestructurada BSON con coordenadas GeoJSON ("Point").
- Indexación espacial geoespacial 2dsphere sobre coordenadas satelitales.
- Preserva metadatos anidados de calidad satelital y bandas espectrales.


## Pipeline de Agregación BSON

```
[{"$group": {"_id": "$periodo.anio_mes", "fuegos": {"$sum": {"$cond": [{"$telemetria.evidencia_fuego", 1, 0]}}, "frp": {"$sum": {"$telemetria.frp_suma_mw"}}}]}
```


## Ejecución de la Agregación en MongoDB:

| Periodo        | Docs BSON  | Fuegos Confirmados | FRP Suma (MW)   |
|----------------|------------|--------------------|-----------------|
| 2023-01        | 46         | 7                  | 17,71           |
| 2023-06        | 53         | 16                 | 424,52          |
| 2023-07        | 61         | 26                 | 191,17          |
| 2023-08        | 188        | 143                | 2.512,57        |
| <b>2023-09</b> | <b>348</b> | <b>306</b>         | <b>6.295,15</b> |
| <b>2023-10</b> | <b>246</b> | <b>201</b>         | <b>6.910,86</b> |
| 2023-11        | 75         | 42                 | 347,58          |

# Modelo Predictivo de Machine Learning (Random Forest)



Matriz de Confusión (19.013 celdas-mes en Test Set).



Importancia Relativa de Variables (Gini Importance).

## Métricas en Evaluación Independiente

- ROC-AUC: 0,9912 (Excelente separabilidad).
- Recall: 95,97 % (143/149 fuegos capturados).
- F1-Score: 0,2685.

## Variables Clave

1. dias\_secos\_acumulados\_3m (20,16 %)
2. precip\_lag\_2m (18,04 %)
3. precip\_media\_movil\_3m (13,10 %)

## Capacidades Visuales & Cartográficas

- **Mapeo Satelital HD:** Fondo fotográfico satelital de alta definición (Google Earth / Esri World Imagery).
- **Perímetro Cantonal INEC:** Trazado vectorial del límite oficial de Loja en color cian de alto contraste.
- **Filtros dinámicos:** Selección de mes (1–12) y exploración de las 7.997 celdas.

## Innovación: Motor Dual de Consultas

Funciona en vivo contra **PostgreSQL** y **MongoDB**, pero conmuta automáticamente a un **motor embebido SQLite/JSON** en modo offline o en la nube para garantizar que las tablas siempre se generen sin caídas.

## Módulo de Consultas y Tablas (Sección 3)

- Pestaña SQL: Consultas predefinidas y modo libre.
- Pestaña NoSQL: Agregaciones BSON e inspección JSON.
- Pestaña Spark: Balances temporales con lags.
- Pestaña Curated: Explorador interactivo de las 95.964 filas con descarga en CSV.

## Simulador de Riesgo ML

Predicción en tiempo real al ingresar lluvia y días secos.

# Gobernanza, Trazabilidad y Estructura para GitHub

## Trazabilidad Criptográfica (SHA-256)

- Cada archivo de entrada posee hash verificado en `manifiesto_firelab_loja.json`.
- Protección total del repositorio fuente FIRELAB\_Loja: política estricta de solo lectura sin sobreescrituras.
- Procedencia documentada de la malla INEC y telemetría NASA.

## Autonomía de Ejecución

Cero dependencias absolutas: el proyecto utiliza rutas relativas (`Path(__file__)`), permitiendo que el docente o evaluador lo clone y ejecute directamente.

## Estructura Limpia del Repositorio

- `datos/`: Raw, Clean y Curated Parquet.
- `bases_datos/`: DDL PostgreSQL, MongoDB y standalone DB.
- `pipeline/`: Scripts ETL y Apache Spark.
- `machine_learning/`: Modelo predictivo y métricas.
- `dashboard/`: Código de la aplicación Streamlit.
- `entrega_final/`: Informe PDF, presentación Beamer y LaTeX fuente.

# Conclusiones y Trabajo Futuro

## Conclusiones Principales

- ➊ **Pipeline Cantonal End-to-End:** Se procesó con éxito la totalidad de la malla espacial cantonal de Loja ( $7.997 \text{ celdas} \times 12 \text{ meses} = 95.964 \text{ observaciones}$ ), superando plenamente la prueba preliminar del Avance 1.
- ➋ **Eficacia del Modelo Híbrido:** La sinergia entre SQL (PostgreSQL/PostGIS), NoSQL (MongoDB), Data Lakehouse (Parquet) y Apache Spark resolvió eficazmente la heterogeneidad de fuentes y el cálculo masivo de series de tiempo.
- ➌ **Descubrimiento Ambiental:** El estiaje acumulado ( $\sim 86$  días secos en 3 meses) es el principal detonante del fuego, concentrando el 94 % de radiación térmica entre agosto y octubre.
- ➍ **Alta Capacidad Predictiva:** El modelo Random Forest alcanzó un ROC-AUC de **0,9912** y un Recall de **95,97 %**.
- ➎ **Explotación Interactiva:** Dashboard Streamlit con soporte satelital fotográfico y motor dual de alta disponibilidad.

## Trabajo Futuro

# ¿Preguntas o Comentarios?

**¡Muchas Gracias!**

Proyecto Integrador: FireForest – Arquitectura Híbrida de Datos

Grupo 4 | Maestría en Ciencia de Datos e Inteligencia Artificial | ESPOCH 2026

