

Diseño e Implementación de una Arquitectura Híbrida (SQL, NoSQL, Data Lakehouse y Spark) para Incendios Forestales

Sustentación Final del Pipeline de Ingeniería de Datos, Analítica Espacio-Temporal y Machine Learning

Cantón Loja, Ecuador (Malla 500m × 500m, 7.997 Celdas, 95.964 Filas)

Autores (Grupo 4):

Marco Vinicio Malan Mullo

Viviana Isabel Pujos Culque
Morocho

Carlos Guillermo Chuncho

Escuela Superior Politécnica de Chimborazo (ESPOCH)

Maestría en Estadística con mención en Ciencia de Datos e Inteligencia Artificial

Septiembre, 2026

Estructura de la Sustentación

I. Fundamentación & Datos

- Problema territorial y pregunta de investigación.
- Objetivos del proyecto integrador.
- Fuentes primarias y diccionario de variables.
- Salto de escala: De 2 celdas a la malla cantonal ($7.997 \text{ celdas} \times 12 \text{ meses}$).

II. Arquitectura de Ingeniería

- Arquitectura multimodelo (SQL, NoSQL, Lakehouse).
- Procesamiento distribuido con Apache Spark.

III. Resultados & Evidencias Tabulares

- Resultados en Spark SQL (Lags y Días Secos).
- Resultados en PostgreSQL / PostGIS (Polígonos).
- Resultados en MongoDB 8 (Pipelines BSON).

IV. Explotación, Modelado & Cierre

- Modelo Machine Learning (Random Forest ROC 0,9912).
- Dashboard Streamlit (Mapas Satelitales y Tablas).
- Conclusiones, trazabilidad y gobernanza.

Definición del Problema y Pregunta de Investigación

Contexto Territorial (Cantón Loja)

- Topografía andina contrastante ($< 1,000$ a $> 3,400$ m.s.n.m.).
- Déficit hídrico estacional severo (mayo–noviembre) que incrementa la inflamabilidad vegetal (Balaguer-Beser et al., 2026).
- Impacto directo en fuentes de agua, biodiversidad y poblaciones rurales.

El Desafío de Ingeniería de Datos

- Fuentes dispersas, no alineadas y multiformato (INEC, NASA VIIRS 375m, UCSB CHIRPS).
- Desfase temporal: detecciones a grano diario vs. análisis a grano **celda-mes**.

Pregunta Central de Investigación

¿Cómo estructurar e implementar una arquitectura híbrida (SQL, NoSQL, Data Lakehouse y Spark) que permita integrar, validar y consultar de forma escalable datos heterogéneos de incendios forestales sobre toda la malla cantonal de Loja para alimentar simultáneamente consultas analíticas, un dashboard cartográfico y modelos predictivos?

Beneficiarios: Bomberos Loja, MAATE, GAD Loja y comunidades rurales.

Objetivos del Proyecto Integrador

Objetivo General

Diseñar, implementar y validar un pipeline end-to-end de ingeniería de datos basado en una arquitectura multimodelo (PostgreSQL/PostGIS, MongoDB, Apache Spark y Parquet) para procesar las **7.997 celdas del cantón Loja durante los 12 meses de 2023 (95.964 registros)**, habilitando analítica avanzada, exploración interactiva y predicción de riesgo con Machine Learning.

1. Ingesta & Spark

Captura inmutable con hashes SHA-256; transformaciones de ventana en PySpark (lags y días secos).

2. Bases Híbridas

Esquema relacional estrella en PostgreSQL/PostGIS y repositorio documental semiestructurado en MongoDB 8.

3. ML & Dashboard

Clasificador Random Forest (ROC 0,9912) y Dashboard Streamlit con mapas satelitales y tablas duales.

Inventario de Fuentes y Diccionario de Variables

Variable	Concepto	Fuente	Transformación	Unidad
cell_id	ID único celda 500m	INEC Malla	Malla ortogonal (EPSG:32717)	Texto
longitud/latitud	Coordenadas centroide	INEC Malla	Reproyección a WGS84	Grados (°)
precip_acumulada_mm	Lluvia mensual acumulada	CHIRPS v2.0	Suma diaria mensual	mm
dias_secos_lt1mm	Días con lluvia < 1 mm	CHIRPS v2.0	Conteo mensual	Días
precip_lag_1m	Lluvia mes anterior	Spark Window	lag(precip,1) por celda	mm
dias_secos_acum_3m	Días secos en 3 meses	Spark Window	Suma ventana deslizante 3m	Días
frp_total_mw	Potencia radiativa del fuego	NASA FIRMS	Suma FRP de píxeles térmicos	MW
incendio_observado	Presencia real de fuego	Derivada	detecciones > 0 ∨ FRP > 0	Clase {0, 1}

Restricciones y Limitaciones de los Datos

Restricciones de Origen

- **Desajuste de resolución:** VIIRS (375 m) agregado sobre malla de 500 m → posible sub/sobre-representación en celdas de borde.
- **Cobertura nubosa:** sensores ópticos pueden perder detecciones en época lluviosa (mar-abr).
- **CHIRPS es un producto interpolado**, no estaciones terrestres puras → sesgo posible en topografía andina abrupta.

Restricciones Temporales y de Clase

- **Grano celda-mes:** oculta dinámica intra-mensual (un día seco dentro de un mes lluvioso).
- **Un solo año (2023):** sin variabilidad interanual (fenómenos ENOS).
- **Desbalance de clases:** solo 747 de 95.964 observaciones (0,8 %) con fuego confirmado.

Calidad de Datos y Reglas de Limpieza (ETL)

Problemas de Calidad Detectados

- Celdas con geometría parcial fuera del límite cantonal ($\text{area_dentro_loja_ha} < 25 \text{ ha}$).
- Registros VIIRS duplicados por múltiples pasadas satelitales en el mismo día/celda.
- Valores nulos en `precipitacion_acumulada_mm` por vacíos de cobertura CHIRPS.
- Inconsistencias de proyección: reconciliación de CRS (EPSG:32717 vs. WGS84) entre fuentes.

Reglas de Limpieza Aplicadas

- Deduplicación por (`cell_id`, `anio`, `mes`) con agregación media/suma según variable.
- `coalesce()` para distinguir ausencia verificada de fuego vs. dato faltante.
- Reproyección uniforme a EPSG:32717 antes del join espacial.
- Trazabilidad: hash SHA-256 por archivo fuente en `manifiesto_firelab_loja.json`.

Transformación Principal

Integración malla $\bowtie$ clima (inner join) $\bowtie$ VIIRS (left join) sobre `cell_id`, preservando la totalidad de las 7.997 celdas aun sin evidencia de incendio.

Salto de Escala: De 2 Celdas a la Malla Cantonal Completa

Avance 1 (Fase Prototipo)

- Solo 2 celdas de prueba (LJ_TEST_001 y 002) en El Cisne.
- 2 registros para validar conectividad.
- Sin inferencia territorial ni estacional.

Entrega Final (Malla Cantonal Completa)

- **7.997 celdas espaciales de 500m × 500m.**
- **12 meses** completos del año 2023.
- **95.964 observaciones celda-mes.**
- **747 eventos históricos de fuego activo** registrados y procesados.




Figura: Cobertura cantonal total en CRS EPSG:32717 (Loja, Ecuador).

Arquitectura de Datos Híbrida Multimodelo

Fuentes Inmutables: Malla INEC (GPKG) · NASA VIIRS (CSV) · CHIRPS (Parquet)

Raw Data Lake: Verificación SHA-256 · Ingesta Controlada

Apache Spark 4.2 (PySpark): Window Functions (Lags 1m, 2m, Días Secos 3m)

Parquet
Data Lakehouse
Particionado

MongoDB 8
Telemetría BSON
GeoJSON 2dsphere

PostgreSQL 18
PostGIS GiST
dim / fact

Justificación por Caso de Uso

- **PostgreSQL / PostGIS:** Integridad referencial (PK/FK), topología espacial de celdas con índices GiST.
- **MongoDB 8:** Esquema flexible para telemetría satelital anidada BSON y agregaciones rápidas.
- **Apache Spark:** Procesamiento masivo de series de tiempo sin saturar memoria.
- **Data Lake Parquet:** Compresión Snappy (>90 %) y acceso columnar OLAP.

Procesamiento Distribuido en Apache Spark (PySpark)

Funciones de Ventana Temporal (Window Functions)

Transformaciones computadas en memoria sobre particiones por celda:


- `lag(col("precip"), 1)`: Precipitación mes previo.
- `lag(col("precip"), 2)`: Precipitación 2 meses atrás.
- `avg(col("precip")).rowsBetween(-2, 0)`: Media móvil trimestral.
- `sum(col("dias_secos")).rowsBetween(-2, 0)`: Días secos acumulados en el trimestre.

Exportación Optimizada

Data Lakehouse particionado físicamente por año y mes en formato columnar Parquet.

Descubrimiento Analítico de la Dinámica

El fuego tiene memoria hídrica: La lluvia disminuye en mayo (29 mm), pero los incendios no estallan hasta agosto–octubre (> 15,700 MW acumulados) tras acumular cerca de **86 días secos consecutivos**.



Resultados Tabulares: Balance Cantonal en Apache Spark

Mes	Celdas Activas	Precip. Media (mm)	Lag 1m (mm)	Días Secos 3m	Celdas Fuego	FRP Total (MW)
Enero	7.997	64,80	n/d	21,0 d	7	17,71
Febrero	7.997	92,35	64,80	42,7 d	0	0,00
Marzo	7.997	312,28	92,35	61,7 d	0	0,00
Abril	7.997	325,82	312,28	58,5 d	0	0,00
Mayo	7.997	29,03	325,82	65,5 d	0	0,00
Junio	7.997	16,73	29,03	73,8 d	16	424,52
Julio	7.997	16,73	16,73	85,8 d	26	191,17
Agosto	7.997	24,05	16,73	85,6 d	143	2.512,57
Septiembre	7.997	16,61	24,05	85,8 d	306	6.295,15
Octubre	7.997	78,31	16,61	76,0 d	201	6.910,86
Noviembre	7.997	68,18	78,31	69,5 d	42	347,58
Diciembre	7.997	76,65	68,18	65,9 d	6	24,77

Total acumulado 2023: 747 celdas-mes con fuego | 16.724,33 MW de FRP total liberada en el cantón.

Resultados en PostgreSQL / PostGIS (Modelo Estrella)

Esquema Dimensional

- dim_celda: 7.997 polígonos (ST_MakeEnvelope, SRID 32717, índice GiST).
- dim_fecha: Calendario mensual 2023.
- fact_celda_mes: 95.964 filas con PK/FK.

Consulta de Auditoría SQL

```
SELECT count(*) FROM fact_celda_mes f JOIN dim_celda c ON  
f.cell_id = c.celda_id WHERE f.incendio_observado = true; → 747  
eventos.
```

Top 5 Celdas con Mayor Radiación FRP (PostGIS):

Celda ID	Mes	Precip	FRP	Geom	Área
LJ500_R031_C075	Oct	98,0 mm	327,9 MW	Polygon	25 ha
LJ500_R031_C076	Oct	98,0 mm	246,6 MW	Polygon	25 ha
LJ500_R121_C056	Sep	13,9 mm	242,8 MW	Polygon	25 ha
LJ500_R032_C075	Oct	98,0 mm	224,3 MW	Polygon	25 ha
LJ500_R031_C077	Oct	99,2 mm	205,9 MW	Polygon	25 ha

Resultados NoSQL en MongoDB 8 (Telemetría BSON)

Colección Documental (evidencia_viirs)

- Estructura semiestructurada BSON con coordenadas GeoJSON ("Point").
- Indexación espacial geoespacial 2dsphere sobre coordenadas satelitales.
- Preserva metadatos anidados de calidad satelital y bandas espectrales.

Pipeline de Agregación BSON

```
[{"$group": {"_id": "$periodo.anio_mes", "fuegos": {"$sum": {"$cond": ["$telemetria.evidencia_fuego", 1, 0]}}, "frp": {"$sum": "$telemetria.frp_suma_mw"}}}]
```

Ejecución de la Agregación en MongoDB:


Periodo	Docs BSON	Fuegos Confirmados	FRP Suma (MW)
2023-01	46	7	17,71
2023-06	53	16	424,52
2023-07	61	26	191,17
2023-08	188	143	2.512,57
2023-09	348	306	6.295,15
2023-10	246	201	6.910,86
2023-11	75	42	347,58

Modelo Predictivo de Machine Learning (Random Forest)

Matriz de Confusión (Test: 19,013 Celdas-Mes)
ROC-AUC: 0.9912 | Recall: 95.97%

	Pred: Sin Fuego	Pred: Con Fuego
Real: Sin Fuego	18,091	773
Real: Con Fuego	6	143

Matriz de Confusión (19.013 celdas-mes en Test Set).



Importancia Relativa de Variables (Gini Importance).

Métricas en Evaluación Independiente

- ROC-AUC: 0,9912 (Excelente separabilidad).
- Recall: 95,97 % (143/149 fuegos capturados).
- F1-Score: 0,2685.

Variables Clave

- dias_secos_acumulados_3m (20, 16 %)
- precip_lag_2m (18, 04 %)
- precip_media_movil_3m (13, 10 %)

Capacidades Visuales & Cartográficas

- **Mapeo Satelital HD:** Fondo fotográfico satelital de alta definición (Google Earth / Esri World Imagery).
- **Perímetro Cantonal INEC:** Trazado vectorial del límite oficial de Loja en color cian de alto contraste.
- **Filtros dinámicos:** Selección de mes (1–12) y exploración de las 7.997 celdas.

Módulo de Consultas y Tablas (Sección 3)

- Pestaña SQL: Consultas predefinidas y modo libre.
- Pestaña NoSQL: Agregaciones BSON e inspección JSON.
- Pestaña Spark: Balances temporales con lags.
- Pestaña Curated: Explorador interactivo de las 95.964 filas con descarga en CSV.

Innovación: Motor Dual de Consultas

Funciona en vivo contra **PostgreSQL** y **MongoDB**, pero conmuta automáticamente a un **motor embebido SQLite/JSON** en modo offline o en la nube para garantizar que las tablas siempre se generen sin caídas.

Simulador de Riesgo ML

Predicción en tiempo real al ingresar lluvia y días secos.

Gobernanza, Trazabilidad y Estructura para GitHub

Trazabilidad Criptográfica (SHA-256)

- Cada archivo de entrada posee hash verificado en `manifiesto_firelab_loja.json`.
- Protección total del repositorio fuente FIRELAB_Loja: política estricta de solo lectura sin sobreescrituras.
- Procedencia documentada de la malla INEC y telemetría NASA.

Autonomía de Ejecución

Cero dependencias absolutas: el proyecto utiliza rutas relativas (`Path(__file__)`), permitiendo que el docente o evaluador lo clone y ejecute directamente.

Estructura Limpia del Repositorio

- `datos/`: Raw, Clean y Curated Parquet.
- `bases_datos/`: DDL PostgreSQL, MongoDB y standalone DB.
- `pipeline/`: Scripts ETL y Apache Spark.
- `machine_learning/`: Modelo predictivo y métricas.
- `dashboard/`: Código de la aplicación Streamlit.
- `entrega_final/`: Informe PDF, presentación Beamer y LaTeX fuente.

Conclusiones y Trabajo Futuro

Conclusiones Principales

- ➊ **Pipeline Cantonal End-to-End:** Se procesó con éxito la totalidad de la malla espacial cantonal de Loja ($7.997 \text{ celdas} \times 12 \text{ meses} = 95.964 \text{ observaciones}$), superando plenamente la prueba preliminar del Avance 1.
- ➋ **Eficacia del Modelo Híbrido:** La sinergia entre SQL (PostgreSQL/PostGIS), NoSQL (MongoDB), Data Lakehouse (Parquet) y Apache Spark resolvió eficazmente la heterogeneidad de fuentes y el cálculo masivo de series de tiempo.
- ➌ **Descubrimiento Ambiental:** El estiaje acumulado (~ 86 días secos en 3 meses) es el principal detonante del fuego, concentrando el 94 % de radiación térmica entre agosto y octubre.
- ➍ **Alta Capacidad Predictiva:** El modelo Random Forest alcanzó un ROC-AUC de **0,9912** y un Recall de **95,97 %**.
- ➎ **Explotación Interactiva:** Dashboard Streamlit con soporte satelital fotográfico y motor dual de alta disponibilidad.

Trabajo Futuro

¿Preguntas o Comentarios?

¡Muchas Gracias!

Proyecto Integrador: FireForest – Arquitectura Híbrida de Datos

Grupo 4 | Maestría en Ciencia de Datos e Inteligencia Artificial | ESPOCH 2026

