

GUÍA DE LA TAREA ETL

Calidad e integración de datos

Información	Detalle
Asignatura	Bases de datos para Datos Estructurados, no Estructurados e Introducción a Big Data para Ciencia de Datos
Código y tema	M1721 · Tema 4 · Limpieza, selección y transformación de datos
Presentación	Entrega individual en el aula virtual
Valor	1,50 puntos
Plazo	Consulte la fecha y hora vigentes en la actividad del aula virtual

1 Resultado esperado

Construya un flujo ETL reproducible que transforme datos de origen en un dataset analítico confiable. El trabajo debe mostrar **qué problemas existen, cómo se tratan y qué evidencia permite verificar el resultado**. La limpieza, la integración y las transformaciones deben ejecutarse mediante código.

Organice el flujo en las capas **Raw, Clean y Curated**. Entregue un notebook o un repositorio que pueda ejecutarse desde el inicio, junto con los datos permitidos o las instrucciones para obtenerlos, los controles de calidad y la bitácora de decisiones.

2 Selección del caso y alcance

- Utilice preferentemente el caso del Proyecto Integrador. Como alternativa, trabaje con Chinook u otro conjunto de datos pertinente para Ciencia de Datos.
- Integre al menos dos tablas o conjuntos relacionados. Pueden proceder del mismo sistema; no es obligatorio usar dos plataformas diferentes.
- Defina una pregunta analítica, la población y el periodo de estudio, la unidad de análisis final y las claves de integración.
- Use un volumen manejable que permita comprobar las reglas. Documente el origen, los permisos de uso y cualquier muestreo aplicado; no publique datos personales innecesarios ni credenciales.

Ejemplo de alcance: integrar clientes y facturas de Chinook para construir una fila por cliente con país, número de facturas y total comprado. Adapte el diseño a la pregunta de su proyecto.

3 Parte A Extracción y capa Raw

Separe la adquisición del tratamiento. La capa Raw conserva una copia de los datos tal como se recibieron; las correcciones deben producir nuevas salidas, sin sobrescribir los originales.

Paso	Acción y evidencia esperada
Inventariar fuentes	Identifique cada tabla o archivo, formato, procedencia, fecha de extracción, número de filas y columnas y clave esperada.
Extraer	Lea los datos mediante código desde archivos, SQL, API o la fuente del proyecto. Documente parámetros y dependencias. Puede usar archivos exportados, siempre que indique cómo se obtuvieron.
Conservar Raw	Guarde la copia de entrada o documente una ruta reproducible para obtenerla. Si el origen cambia, registre versión o fecha de corte.
Perfilar	Reporte tipos, faltantes por variable, duplicados por clave, rangos, categorías y relaciones entre fuentes antes de limpiar.

4 Parte B Diagnóstico de calidad

Construya una matriz de calidad con las reglas que aplicará. Evalúe al menos **completitud**, **validez**, **consistencia** y **unicidad**. Incluya el número y porcentaje de registros afectados, el tratamiento y la evidencia posterior.

Dimensión	Pregunta de diagnóstico	Evidencia
Compleitud	¿Faltan valores necesarios para el análisis?	Conteo y porcentaje de nulos por variable.
Validez	¿Se cumplen tipos, dominios y rangos definidos?	Entradas inválidas y regla del dominio.
Consistencia	¿Fechas, unidades y campos relacionados se contradicen?	Conteo de contradicciones antes y después.
Unicidad	¿Se repite la clave que debería identificar el registro?	Duplicados por clave y criterio de conservación.
Integridad referencial	¿Todas las claves foráneas encuentran su entidad?	Registros sin correspondencia y decisión de tratamiento.

Si no encuentra un problema: reporte cero casos y muestre la prueba realizada. No modifique los datos originales para fabricar errores. Puede usar una copia de prueba identificada para demostrar cómo responde el flujo ante un caso inválido.

Formato mínimo de la bitácora: fuente o variable | problema | regla | decisión | justificación | filas afectadas | fecha o versión. Mantenga este registro junto al código.

5 Parte C Limpieza y capa Clean

Implemente reglas explícitas y conserve evidencia de su efecto. La capa Clean debe contener datos tipados y estandarizados, con las excepciones corregidas, justificadas o separadas para revisión.

Aspecto	Qué debe resolver	Decisión que debe justificar
Faltantes	Medirlos e interpretar qué significa su ausencia.	Conservar, imputar o excluir según la variable y el uso; no confundir cero con ausencia.
Duplicados	Distinguir duplicados exactos de repeticiones por clave.	Definir identidad y granularidad; justificar qué fila se conserva.
Formatos y tipos	Unificar texto, fechas, categorías y unidades.	Preservar IDs con ceros iniciales; revisar valores que no puedan convertirse.
Valores atípicos	Detectarlos mediante una regla pertinente, como IQR.	Investigar antes de eliminar; un extremo puede ser real e informativo.
Errores y rechazos	Registrar entradas que incumplen reglas críticas.	Separarlas o detener el flujo con un mensaje claro, sin descartarlas silenciosamente.

6 Selección y transformación

- Explique los filtros de observaciones y su efecto sobre la población final. Si toma una muestra, documente el método y fije una semilla cuando corresponda.
- Seleccione variables por pertinencia, calidad y disponibilidad. Excluya columnas innecesarias y evite información futura si el dataset se usará para predicción.
- Implemente al menos tres transformaciones pertinentes, además de la integración: por ejemplo, conversión de fechas, recodificación de categorías y construcción de una variable derivada o un agregado.
- Aplique escalamiento o codificación solo cuando el uso analítico lo requiera. Si usa entrenamiento y prueba, aprenda los parámetros únicamente con entrenamiento.

Evidencia mínima: una comparación antes y después con conteos de filas, duplicados, faltantes e incumplimientos. Explique toda reducción o aumento de observaciones; no use porcentajes sin indicar su denominador.

7 Parte D Integración y capa Curated

Integre las fuentes mediante claves y cardinalidades verificadas. El resultado debe respetar la unidad de análisis declarada y responder a la pregunta del caso.

Control	Qué debe demostrar
Clave y cardinalidad	Indique los campos de unión y si espera una relación uno a uno, uno a muchos o muchos a uno. Valide esa expectativa antes o durante el JOIN o merge.
Tipo de unión	Justifique el uso de LEFT, INNER u otra unión. Cuente y explique los registros sin correspondencia.
Granularidad	Compruebe qué representa una fila después de integrar. Si necesita agregación, defina las claves de agrupación y evite duplicar totales.
Carga	Guarde el dataset Curated en CSV, Parquet o una tabla. Incluya un diccionario con nombre, significado, tipo, unidad y regla de derivación de cada variable.

Ejemplo orientativo con Chinook: valide clientes y facturas por separado; agrupe las facturas por cliente y una el resumen con clientes para conservar también quienes no tienen compras. Verifique una fila por cliente. Un conteo de compras puede ser cero, pero un promedio sin compras no debe convertirse automáticamente en cero.

8 Controles automatizados y errores

Implemente al menos **seis verificaciones automatizadas** adaptadas al caso. Registre resultado, cantidad de incumplimientos y acción aplicada. Un listado de capturas sin reglas ejecutables no demuestra control de calidad.

Verificación sugerida	Criterio esperado
Clave de salida	Unicidad y ausencia de claves nulas en la unidad final.
Compleitud	Umbral justificado de faltantes en variables críticas.
Validez	Dominios, tipos o rangos válidos según el caso.
Consistencia	Relaciones temporales o reglas entre campos coherentes.
Integración	Cardinalidad esperada y claves sin correspondencia identificadas.
Reconciliación	Conteos y totales antes y después explicados; tolerancias numéricas documentadas cuando apliquen.

9 Parte E Reproducibilidad y evidencias

Organice el código en una secuencia clara de extracción, limpieza, integración, transformación, validación y carga. Puede usar Python/Pandas, SQL o una combinación de herramientas trabajadas en clase. No se exige desplegar infraestructura adicional.

- Incluya un README o una sección inicial con requisitos, dependencias y versiones, rutas de entrada y salida, parámetros y orden de ejecución.
- Ejecute el notebook desde un kernel reiniciado o ejecute el script desde el inicio. No dependa de celdas corridas fuera de orden ni de cambios manuales en archivos.
- Ejecute el flujo dos veces sobre la misma entrada. Verifique que no duplique registros y que las salidas analíticas sean equivalentes; identifique metadatos de ejecución que cambian, como la hora.
- Registre métricas y decisiones. Ante una regla crítica incumplida, detenga el flujo o separe los registros afectados e indique claramente qué salida es apta para análisis.

10 Entregables

Entregue un **notebook o repositorio reproducible**, como establece la actividad. La documentación puede estar en el notebook y el README; no se exige un informe PDF adicional si esos archivos contienen todas las evidencias.

Elemento	Contenido mínimo
Código	Notebook .ipynb o scripts que ejecuten el flujo completo; incluya SQL si lo utiliza.
Datos	Fuentes permitidas o instrucciones de acceso reproducible; dataset Curated y diccionario. No incluya contraseñas, tokens ni datos personales innecesarios.
Calidad	Perfilado inicial, comparación antes y después, matriz de calidad, resultados de las seis pruebas y bitácora de decisiones.
Documentación	Problema, fuentes, población, unidad de análisis, diagrama Raw → Clean → Curated, ejecución, conclusiones y limitaciones.

Presentación sugerida: Apellido_Nombre_Tarea_ETL.zip, con carpetas raw/, clean/, curated/, codigo/ y evidencias/, más README.md. Si entrega un repositorio, indique su enlace y asegure acceso al docente. Utilice los tipos de envío habilitados en el aula; no sustituya código por capturas.

Relación con el Proyecto Integrador: conserve las reglas, scripts y salidas como componente de preparación de datos del proyecto. Si reutiliza materiales de un trabajo grupal, identifique sus autores y explique su aporte individual.

11 Rúbrica de evaluación

Se mantienen los criterios y pesos publicados en la tarea. La nota máxima es **1,50 puntos**; los valores con tres decimales expresan exactamente cada ponderación.

Criterio	Evidencia de logro completo	Peso	Máximo
Pipeline ETL	Capas Raw, Clean y Curated; integración con claves y cardinalidad correctas; transformaciones justificadas y salida coherente con la unidad de análisis.	35 %	0,525
Calidad	Perfilado, reglas de validez, completitud, consistencia y unicidad; tratamiento de errores; seis pruebas ejecutables y comparación antes y después.	30 %	0,450
Reproducibilidad	Ejecución completa desde cero, entradas y dependencias documentadas, rutas y parámetros claros y segunda ejecución sin duplicación.	20 %	0,300
Documentación	Matriz de calidad, bitácora, diccionario, decisiones justificadas, conclusiones y limitaciones vinculadas al caso.	15 %	0,225
TOTAL		100 %	1,500

Aplicación por criterio: logro completo = 100 % del máximo; mayormente logrado, con omisiones menores = 75 %; parcialmente logrado, con fallas relevantes = 50 %; evidencia inicial insuficiente = 25 %; ausente o no verificable = 0 %. La nota es la suma de los cuatro criterios; se redondea al final según el aula.

12 Lista de verificación antes de entregar

- ☐ ¿La pregunta analítica, población y unidad final están definidas?
- ☐ ¿Se integran al menos dos conjuntos relacionados y se justifican claves y cardinalidad?
- ☐ ¿Raw permanece sin alterar y existen salidas Clean y Curated?
- ☐ ¿Se diagnosticaron faltantes, duplicados, formatos, tipos y atípicos?
- ☐ ¿Hay al menos tres transformaciones pertinentes y seis pruebas ejecutables?
- ☐ ¿Los conteos y totales antes y después se pueden explicar?
- ☐ ¿La ejecución desde cero y la segunda ejecución producen resultados verificables?
- ☐ ¿Se incluyen bitácora, diccionario, instrucciones y conclusiones?
- ☐ ¿El docente puede acceder al código y los datos permitidos sin credenciales expuestas?

13 Materiales de apoyo

Presentación del Tema 4 Limpieza, selección y transformación de datos, disponible en Tema 4 Materiales del aula. Consulte especialmente perfilado y calidad, tratamiento de errores, integración, ETL, validaciones y bitácora. Utilice los recursos de Chinook o del Proyecto Integrador trabajados en clase.