

Laboratorio NoSQL — MongoDB

Diseño documental y consultas sobre evidencia VIIRS de fuego (celda-mes)

Asignatura M1721 — Bases de datos para Datos Estructurados, no Estructurados
e Introducción a Big Data para Ciencia de Datos

Grupo 04

Proyecto FireForest (componente NoSQL independiente)

Quito/Loja, 2026

Base de datos independiente	taller_nosql_fireforest
Colección principal	evidencia_viirs_celda_mes
Documentos cargados	105 (datos reales de VIIRS, no simulados)
Fuente	Registros reales de VIIRS procesados previamente (solo lectura), v1.0.3, 2019–2025

1. Descripción del caso y justificación de MongoDB

Los incendios forestales del cantón Loja generan información heterogénea: detecciones satelitales VIIRS agregadas por celda espacial de 500 m y mes, indicadores de calidad de observación, evidencia de fuego bajo distintos criterios de confianza, y metadatos operativos que se agregan *después* de la carga inicial (revisiones, bitácora de procesamiento). Esta heterogeneidad —estructuras anidadas, un arreglo de evidencia de cardinalidad fija, y campos que aparecen solo después de una actualización— es más natural de representar como documentos que como tablas relacionales rígidas: un único `findOne()` recupera toda la unidad celda-mes sin necesidad de JOIN, y los metadatos operativos se incorporan con `\$set/\$push` sin alterar el esquema.

Este laboratorio reutiliza la unidad de análisis celda-mes del Proyecto Integrador FireForest (ver `AGENTS.md`) y constituye su componente NoSQL. Preguntas que responde: (1) ¿qué registros celda-mes superan un umbral de FRP relevante y cuándo ocurrieron? (2) ¿en qué meses y años se concentra la mayor intensidad térmica, y cómo difiere la evidencia de fuego entre el criterio amplio y el criterio nominal/alta de confianza?

2. Colección principal y unidad documental

Colección principal: `evidencia_viirs_celda_mes`, dentro de la base independiente `taller_nosql_fireforest` (distinta de la base `fireforest` del Proyecto Integrador, que no fue modificada).

Unidad documental: cada documento representa **una celda espacial de 500 m observada durante un mes calendario** (celda-mes), identificada de forma única por `celda.cell_index + periodo.anio + periodo.mes` (reforzado por el índice único `ux_celda_anio_mes`).

3. Esquema del documento

```
evidencia_viirs_celda_mes
|- _id string
|- celda { cell_index, unidad_espacial }
|- periodo { anio, mes, anio_mes, fecha_inicio: Date }
|- fuente_satelital { fuente_primaria, asset_gee, procedencia, version_origen }
|- metricas
| |- detecciones { media_todas, media_nominal_alta }
| |- presencia { fraccion_todas, fraccion_nominal_alta }
| \- frp { suma_observada_media_mw, maxima_media_mw }
|- calidad_observacion { dias_validos_media, disponibilidad_pct, ... }
|- evidencias [ { categoria, detecciones_media, presencia_fraccion,
| evidencia_fuego: bool }, ... ] (2 elementos)
|- muestreo { estrato, metodo, semilla }
|- metadatos { unidad_analisis, datos_simulados, uso, estado_revision? }
|- revisado_manualmente? bool
\- bitacora_laboratorio? [ { accion, responsable, fecha_procesamiento: Date } ]
```

4. Decisiones de embebido y referencia

Se **embebieron** `celda`, `periodo`, `fuentes_satelital`, `metricas` y `calidad_observacion` porque tienen cardinalidad 1–1, se leen siempre junto con el documento y no cambian tras la carga. El arreglo `evidencias` se embebió por tener cardinalidad fija y pequeña (2 elementos: `todas` y `nominal_alta`), consultado con `$elemMatch` (consultas 2 y 6) o aplanado puntualmente con `$unwind` (consulta 9). Los metadatos operativos (`metadatos.estado_revision`, `revisado_manualmente`, `bitacora_laboratorio`) también se embebieron pese a evolucionar después de la carga, porque su cardinalidad sigue siendo pequeña y ligada al documento.

No se usaron referencias ni \$lookup: no existe en este caso una entidad de cardinalidad alta e independiente que se consulte por separado del documento celda-mes; las 10 consultas exigidas se resuelven íntegramente sobre esta única colección. Una bitácora de revisión más extensa (con múltiples analistas y comentarios largos) sí ameritaría una colección referenciada aparte; no es el caso de este taller.

5. Documento JSON/BSON completo (ejemplo real)

```
{
  "_id": "VCM_0001",
  "celda": { "cell_index": 1803, "unidad_espacial": "celda_500m" },
  "periodo": { "anio": 2019, "mes": 1, "anio_mes": "2019-01",
    "fecha_inicio": ISODate("2019-01-01T00:00:00Z") },
  "fuente_satelital": { "fuente_primaria": "NASA FIRMS - VIIRS",
    "asset_gee": "VIIRS_PREP_2019_01",
    "procedencia": "registros_previamente_procesados",
    "version_origen": "v1.0.3" },
  "metricas": {
    "detecciones": { "media_todas": 1, "media_nominal_alta": 0 },
    "presencia": { "fraccion_todas": 1, "fraccion_nominal_alta": 0 },
    "frp": { "suma_observada_media_mw": 4.7, "maxima_media_mw": 4.7 }
  },
  "calidad_observacion": { "dias_validos_media": 31,
    "disponibilidad_pct": 100, "observado_media": 1 },
  "evidencias": [
    { "categoria": "todas", "detecciones_media": 1,
      "presencia_fraccion": 1, "evidencia_fuego": true },
    { "categoria": "nominal_alta", "detecciones_media": 0,
      "presencia_fraccion": 0, "evidencia_fuego": false }
  ],
  "muestreo": { "estrato": "con_fuego",
    "metodo": "estratificado_por_anio_y_evidencia", "semilla": 2026 },
  "metadatos": { "unidad_analisis": "celda_mes_500m",
    "datos_simulados": false, "uso": "Laboratorio NoSQL MongoDB - M1721" }
}
```

6. Evidencia de carga de los 105 documentos

Verificado mediante ejecución real de 07_entrega/Grupo04_Laboratorio_NoSQL_MongoDB.js contra taller_nosql_fireforest (detalle completo en 05_resultados/01_validacion_carga.txt):

Verificación	Resultado real
Conteo total de documentos	105
_id únicos	105
Combinaciones celda-año-mes únicas	105
Fechas BSON (periodo.fecha_inicio)	105
Objetos anidados (metricas)	105
Arreglos (evidencias)	105
Booleanos (metadatos.datos_simulados)	105
Con evidencia de fuego (criterio todas)	70
Sin evidencia de fuego	35
Con evidencia nominal/alta	68
FRP máxima de la muestra	122,3162 MW (VCM_0073, 2023-10)

Índices creados: ux_celda_anio_mes (único, sobre celda.cell_index+periodo.anio+periodo.mes), ix_fecha_inicio, ix_frp_maxima (descendente) y ix_evidencias_categoria_fuego (multiclave, sobre evidencias.categoria y evidencias.evidencia_fuego).

7. Consultas MongoDB (Parte C) — resumen de las 10 consultas

Todas las consultas incluyen orden secundario por `_id` (o la clave de agrupación) para evitar ambigüedad ante empates. Código completo, resultado sin recortar e interpretación de cada consulta: 04_consultas/01_consultas_1_a_10.md y 05_resultados/02_resultado_consultas_1_10.txt.

#	Tipo	Pregunta	Resultado real (clave)
1	Filtro \$gt	FRP máxima > 20 MW?	13 registros; máximo VCM_0073 (122,32 MW)
2	Filtro combinado	2023-2024 con FRP ≥ 10 y evid. nominal/alta?	11 registros cumplen ambos criterios
3	Proyección	Campos esenciales de 10 registros con fuego	10 documentos, solo 5 campos c/u
4	Orden y límite	5 registros con mayor FRP máxima	VCM_0073 (122,32), VCM_0009 (90,0), ...
5	Campos anidados	Disponibilidad 100% y ≥ 1 detección media	10 registros cumplen ambas condiciones
6	Arreglos \$elemMatch	Evidencia nominal/alta con detección > 0	10 registros
7	Pipeline mensual	Mes con mayor intensidad térmica	Sep.: 350,83 MW acum.; Oct.: 30,58 MW prom., máx. 122,32 MW
8	Pipeline anual	Variación anual de métricas de fuego	2023: mayor FRP acum. (349,58) y prom. (34,96 MW)
9	\$unwind	Evidencia total vs. nominal/alta	70 vs. 68 documentos con fuego, sobre 105 evaluados
10	Integradora	Dataset plano celda-mes para análisis/ML	15 filas; encabeza VCM_0073 (188,27 MW)

Cuadro 1: Resumen de las 10 consultas exigidas por la guía, con resultado real obtenido.

7.1 Código completo de las 10 consultas

```
// Consulta 1 (filtro $gt)
coleccion.find(
  { "metricas.frp.maxima_media_mw": { $gt: 20 } },
  { _id: 1, "celda.cell_index": 1, "periodo.anio_mes": 1,
    "metricas.frp.maxima_media_mw": 1 }
).sort({ "metricas.frp.maxima_media_mw": -1, _id: 1 }).forEach(printjson);

// Consulta 2 (filtro combinado $in + $gte + $elemMatch)
coleccion.find(
  { "periodo.anio": { $in: [2023, 2024] },
    "metricas.frp.maxima_media_mw": { $gte: 10 },
    evidencias: { $elemMatch: { categoria: "nominal_alta", evidencia_fuego: true } } },
  { _id: 1, "periodo.anio_mes": 1, "celda.cell_index": 1,
    "metricas.frp.maxima_media_mw": 1 }
).sort({ "periodo.fecha_inicio": 1, _id: 1 }).forEach(printjson);

// Consulta 3 (proyeccion)
coleccion.find(
  { "metricas.frp.suma_observada_media_mw": { $gt: 0 } },
  { _id: 1, "celda.cell_index": 1, "periodo.anio_mes": 1,
    "metricas.detecciones.media_todas": 1,
    "metricas.frp.suma_observada_media_mw": 1 }
```

```

).sort({ "periodo.fecha_inicio": 1, _id: 1 }).limit(10).forEach(printjson);

// Consulta 4 (orden y limite)
coleccion.find(
  {}, { _id: 1, "celda.cell_index": 1, "periodo.anio_mes": 1,
        "metricas.frp.maxima_media_mw": 1 }
).sort({ "metricas.frp.maxima_media_mw": -1, _id: 1 }).limit(5).forEach(printjson);

// Consulta 5 (campos anidados)
coleccion.find(
  { "calidad_observacion.disponibilidad_pct": 100,
    "metricas.detecciones.media_todas": { $gte: 1 } },
  { _id: 1, "periodo.anio_mes": 1, "celda.cell_index": 1,
    "calidad_observacion.disponibilidad_pct": 1,
    "metricas.detecciones.media_todas": 1 }
).sort({ "metricas.detecciones.media_todas": -1, _id: 1 }).limit(10).forEach(printjson);

// Consulta 6 (arreglos con $elemMatch)
coleccion.find(
  { evidencias: { $elemMatch: { categoria: "nominal_alta",
    evidencia_fuego: true, detecciones_media: { $gt: 0 } } } },
  { _id: 1, "celda.cell_index": 1, "periodo.anio_mes": 1,
    evidencias: { $elemMatch: { categoria: "nominal_alta" } } }
).sort({ "periodo.fecha_inicio": 1, _id: 1 }).limit(10).forEach(printjson);

// Consulta 7 ($match + $group + $sort, por mes calendario)
coleccion.aggregate([
  { $match: { "metricas.frp.suma_observada_media_mw": { $gt: 0 } } },
  { $group: { _id: "$periodo.mes", registros_con_fuego: { $sum: 1 },
    frp_total_muestra_mw: { $sum: "$metricas.frp.suma_observada_media_mw" },
    frp_promedio_mw: { $avg: "$metricas.frp.suma_observada_media_mw" },
    frp_maxima_mw: { $max: "$metricas.frp.maxima_media_mw" } } },
  { $project: { _id: 0, mes: "$_id", registros_con_fuego: 1,
    frp_total_muestra_mw: { $round: ["$frp_total_muestra_mw", 2] },
    frp_promedio_mw: { $round: ["$frp_promedio_mw", 2] },
    frp_maxima_mw: { $round: ["$frp_maxima_mw", 2] } } },
  { $sort: { frp_total_muestra_mw: -1, mes: 1 } }
]).forEach(printjson);

// Consulta 8 ($match + $group + $sort, por anio)
coleccion.aggregate([
  { $match: { "metricas.frp.suma_observada_media_mw": { $gt: 0 } } },
  { $group: { _id: "$periodo.anio", registros_con_fuego: { $sum: 1 },
    frp_promedio_mw: { $avg: "$metricas.frp.suma_observada_media_mw" },
    frp_total_muestra_mw: { $sum: "$metricas.frp.suma_observada_media_mw" },
    frp_maxima_mw: { $max: "$metricas.frp.maxima_media_mw" } } },
  { $project: { _id: 0, anio: "$_id", registros_con_fuego: 1,
    frp_promedio_mw: { $round: ["$frp_promedio_mw", 2] },
    frp_total_muestra_mw: { $round: ["$frp_total_muestra_mw", 2] },
    frp_maxima_mw: { $round: ["$frp_maxima_mw", 2] } } },
  { $sort: { frp_total_muestra_mw: -1, anio: 1 } }
]).forEach(printjson);

// Consulta 9 ($unwind + $group, evidencia total vs. nominal/alta)
coleccion.aggregate([
  { $unwind: "$evidencias" },
  { $group: { _id: "$evidencias.categoria", documentos_evaluados: { $sum: 1 },
    documentos_con_fuego: { $sum: { $cond: ["$evidencias.evidencia_fuego", 1, 0] } },
    detecciones_promedio: { $avg: "$evidencias.detecciones_media" } } },
  { $project: { _id: 0, categoria: "$_id", documentos_evaluados: 1,
    documentos_con_fuego: 1,
    detecciones_promedio: { $round: ["$detecciones_promedio", 3] } } },
  { $sort: { categoria: 1 } }
]).forEach(printjson);

// Consulta 10 (integradora: dataset plano para analisis/ML)
coleccion.aggregate([
  { $match: { "metricas.frp.suma_observada_media_mw": { $gt: 0 },
    "calidad_observacion.disponibilidad_pct": { $gte: 95 } } },
  { $set: { frp_por_deteccion_mw: { $cond: [
    { $gt: ["$metricas.detecciones.media_todas", 0] },
    { $divide: ["$metricas.frp.suma_observada_media_mw",
      "$metricas.detecciones.media_todas"] }, 0 ] } } },
  { $project: { _id: 0, registro_id: "$_id", anio_mes: "$periodo.anio_mes",
    frp_total_media_mw: { $round: ["$metricas.frp.suma_observada_media_mw", 2] },
    frp_por_deteccion_mw: { $round: ["$frp_por_deteccion_mw", 2] } } },

```

```
{ $sort: { frp_total_media_mw: -1, registro_id: 1 } },
{ $limit: 15 }
}).forEach(printjson);
```

7.2 Interpretación de los dos pipelines analíticos principales

Consulta 7 (por mes calendario): septiembre concentra la mayor FRP acumulada de la muestra (350,83 MW en 22 registros), mientras que octubre presenta la mayor FRP promedio (30,58 MW) y el máximo absoluto (122,32 MW): más eventos en septiembre, pero más intensos en octubre.

Consulta 8 (por año): 2023 combina la mayor FRP acumulada (349,58 MW) y la mayor FRP promedio (34,96 MW) entre los siete años de la muestra; 2022 presenta los valores más bajos (58,74 MW acumulados, 5,87 MW promedio).

8. Operaciones de actualización (Parte D)

Las tres actualizaciones agregan o modifican **únicamente metadatos operativos del laboratorio**; ningún valor satelital real se modifica. Evidencia completa antes/después en 05_resultados/03_actualizaciones_antes_despues.txt.

Operación	Alcance	Efecto real	Resultado
updateOne(), campo simple	1 documento	Agrega <code>revisado_manualmente: true</code> al documento de mayor FRP (VCM_0073)	matched:1, modified:1
updateMany(), campo anidado	70 documentos	Agrega <code>metadatos.estado_revision: "revisado_taller_nosql"</code> a los documentos con fuego	matched:70, modified:70
updateMany() + \$push	105 documentos	Incorpora el arreglo <code>bitacora_laboratorio</code> responsable, fecha)	matched:105, modified:105

9. Unidad de análisis y conexión con Ciencia de Datos

Unidad de análisis: una celda-mes (`celda.cell_index+periodo.anio+periodo.mes`), consistente con la unidad declarada para todo el Proyecto Integrador FireForest.

Variable objetivo: `metricas.frp.maxima_media_mw` (continua, intensidad térmica máxima) o `evidencias[categoria="todas"].evidencia_fuego` (binaria, presencia de fuego).

Variables derivadas (calculadas en la consulta 10 mediante `$set`): `frp_por_deteccion_mw` (FRP total dividido entre detecciones medias) y `proporcion_nominal_alta` (fracción de detecciones de alta confianza).

Extracción para análisis estadístico/ML: la consulta 10 es exactamente el mecanismo de extracción: un pipeline `$match+$set+$project` que produce un dataset plano —una fila por celda-mes con columnas escalares— exportable directamente a `pandas.DataFrame` para entrenar modelos o calcular estadísticas descriptivas.

10. Conclusiones

1. El modelo documental (objetos anidados + arreglo `evidencias` de cardinalidad fija) fue suficiente para responder las 10 consultas y los 2 pipelines analíticos exigidos sin necesidad de colecciones adicionales ni `$lookup`.

2. Los metadatos operativos del laboratorio se incorporaron de forma incremental (`$set`, `$push`) sin afectar ningún valor satelital, demostrando que el esquema soporta evolución posterior a la carga.
3. Los hallazgos analíticos (estacionalidad septiembre-octubre, 2023 como año de mayor intensidad) son válidos **dentro de esta muestra estratificada** y sirven de prueba de concepto para las agregaciones que el Proyecto Integrador ejecutaría sobre la población completa de celdas-mes.

Relación con el Proyecto Integrador: este taller reutiliza la unidad de análisis celda-mes de `AGENTS.md` y demuestra el componente MongoDB de la arquitectura híbrida SQL–NoSQL de FireForest; el mismo patrón de pipeline (consulta 10) alimentaría, en el proyecto completo, el dataset analítico celda-mes junto con las tablas de hechos de PostgreSQL/PostGIS (`fact_incendio`, `fact_clima`).

Limitación del muestreo estratificado: la muestra fija deliberadamente 10 casos con fuego y 5 sin fuego por año (semilla 2026), por lo que la proporción observada (70/35, 66,7 % con fuego) **no estima la prevalencia real de incendios en el cantón Loja** y no debe generalizarse a la población completa de celdas-mes. Ver `03_datos/README.md` para el detalle del método de muestreo.