

ESCUELA SUPERIOR POLITÉCNICA DE CHIMBORAZO (ESPOCH)
Maestría en Estadística con mención en Ciencia de Datos e Inteligencia Artificial

Práctica 2 – Taller SQL

Modelado, normalización y consultas

Caso aplicado

Detecciones de incendio, precipitación y cobertura vegetal por celda espacial
y fecha, en el cantón Loja

Integrantes

MALAN MULLO MARCO VINICIO
PUJOS CULQUE VIVIANA ISABEL
CARLOS GUILLERMO CHUNCHO M.

Grupo 04

Práctica 2 – M1721
2026

1. Caso aplicado

Contexto. Las detecciones satelitales de incendio, los registros de precipitación y la cobertura vegetal de una zona suelen analizarse por separado, sin relacionarlos entre sí por celda espacial y fecha. Este taller usa el mismo dominio temático que el Proyecto Integrador FireForest (incendios forestales, cantón Loja), pero como una práctica **independiente**, con su propio esquema, sus propios datos de ejemplo y su propia base de datos PostgreSQL (`taller_sql_fireforest`).

Problema. Sin una estructura relacional integrada, preguntas como «¿qué celdas con cierto tipo de cobertura vegetal concentran más detecciones?» o «¿hay meses con varias detecciones y poca lluvia?» requieren cruzar manualmente información de distintas fuentes.

Propósito de la base de datos. Diseñar e implementar una base de datos relacional en PostgreSQL que integre, reduciendo redundancias innecesarias, detecciones de incendio, precipitación diaria y cobertura vegetal por celda y fecha, y que pueda consultarse mediante SQL para responder preguntas operativas y analíticas descriptivas. El modelo busca apoyar decisiones de consulta y priorización exploratoria, como identificar celdas con mayor concentración de detecciones, periodos con precipitación baja y registros con información incompleta; no representa una decisión operativa real ni de gestión oficial, dado que los datos utilizados son de ejemplo controlados.

Usuarios potenciales. Estudiantes y docentes del curso, como ejercicio de modelado y SQL; y, como referencia conceptual, personal técnico ambiental que quisiera una primera aproximación relacional (sin que exista convenio real con ninguna institución).

Preguntas operativas.

1. ¿Qué detecciones de incendio existen para una celda y un periodo específicos?
2. ¿Cuál fue la precipitación registrada para una celda y una fecha determinadas?
3. ¿Qué celdas no tienen registro de precipitación para una fecha con incendio observado?

Preguntas analíticas.

1. ¿Cuántas detecciones y qué FRP promedio/máximo presenta cada celda?
2. ¿Qué celdas y meses acumulan precipitación mensual baja?
3. ¿Qué combinaciones celda-mes presentan a la vez detecciones y precipitación baja?
4. ¿Qué tipo de cobertura vegetal concentra más detecciones? (usa la relación N:M)

Nota: todos los datos usados en este taller son de ejemplo, controlados, generados específicamente para esta práctica. No son datos reales de VIIRS ni de CHIRPS.

2. Modelo relacional

Entidades principales: celda espacial (`dim_celda`), fecha (`dim_fecha`), cobertura vegetal (`dim_cobertura_vegetal`), detección de incendio (`fact_incendio`) y registro de precipitación (`fact_clima`).

Relaciones 1:N: `dim_celda` con `fact_incendio` y con `fact_clima`; `dim_fecha` con `fact_incendio` y con `fact_clima`.

Relación N:M: una celda puede tener más de un tipo de cobertura vegetal registrado en un mismo año (mosaico de uso de suelo), y un tipo de cobertura aplica a muchas celdas. Esta relación muchos-a-muchos entre `dim_celda` y `dim_cobertura_vegetal` se resuelve con la tabla intermedia `celda_cobertura(celda_id, cobertura_id, anio)`.

Tabla	Propósito	PK	FK	Cardinalidad
dim_celda	Celda espacial de referencia (500 m × 500 m)	celda_id	—	1 celda – N incendio/clima/cobertura
dim_fecha	Calendario diario del periodo	fecha_id	—	1 fecha – N incendio/clima
dim_cobertura_vegetal	Catálogo de tipos de cobertura	cobertura_id	—	1 cobertura – N celda_cobertura
celda_cobertura	Relación N:M celda ↔ cobertura por año	(celda_id, cobertura_id, anio)	celda_id, cobertura_id	N:M
fact_incendio	Detección diaria de incendio por celda	incendio_id	celda_id, fecha_id	N – 1 celda; N – 1 fecha
fact_clima	Precipitación diaria por celda	clima_id	celda_id, fecha_id	N – 1 celda; N – 1 fecha




Figura 1: Modelo relacional final. La relación N:M entre `dim_celda` y `dim_cobertura_vegetal` queda resuelta por `celda_cobertura`.

3. Normalización

Modelo inicial (desnormalizado). Antes de dividir en tablas, la información cabría en un registro plano por celda-día, con columnas repetidas para cobertura vegetal (`cobertura_1/pct_1`, `cobertura_2/pct_2`, ...) porque una celda puede tener más de un tipo de cobertura.




Figura 2: Modelo inicial (desnormalizado): una única entidad plana, con un grupo repetitivo de cobertura vegetal que impide una PK simple y viola 1FN.

1FN. Se eliminan los grupos repetitivos de cobertura extrayéndolos a `celda_cobertura` (una fila por combinación celda-cobertura-año). Todos los atributos del esquema final son atómicos (sin listas ni valores compuestos) y cada tabla tiene PK explícita.

2FN. En las relaciones cuya única clave candidata es simple no pueden existir dependencias parciales respecto de dicha clave. La única tabla con clave candidata compuesta es `celda_cobertura(celda_id, cobertura_id, anio)`, donde $(celda_id, cobertura_id, anio) \rightarrow porcentaje_cobertura$: el atributo depende de la combinación completa de la clave, no de un subconjunto propio de ella, por lo que no hay dependencia parcial.

3FN. Por tabla: `dim_celda: celda_id  $\rightarrow$  nombre_referencia, longitud, latitud, area_km2`; `fact_incendio: incendio_id  $\rightarrow$  (celda_id, fecha_id, fuente, numero_detecciones, frp_suma_mw, frp_maxima_mw, fire_mask_maximo, incendio_observado)`; `fact_clima: clima_id  $\rightarrow$  (celda_id, fecha_id, precipitacion_diaria_mm)`. En ninguna de estas tablas un atributo no clave determina a otro atributo no clave, por lo que cumplen 3FN.

Excepción deliberada en dim_fecha. En esta tabla, `fecha_id  $\rightarrow$  fecha  $\rightarrow$  anio, mes`: una fecha calendario determina su año y mes, pero `anio/mes` no dependen directamente de la PK sin pasar por `fecha`. Es, en sentido estricto, una dependencia transitiva. Se conserva de forma deliberada porque es el patrón estándar de una dimensión de tiempo (evita recalcular `EXTRACT()` en cada consulta de agregación mensual), y su riesgo de inconsistencia queda controlado por el `CHECK chk_fecha_id_consistente` y por la restricción `UNIQUE` sobre `fecha`.

4. Implementación SQL

El esquema se implementó en PostgreSQL con las 6 tablas descritas (`dim_celda`, `dim_fecha`, `dim_cobertura_vegetal`, `celda_cobertura`, `fact_incendio`, `fact_clima`), todas con clave primaria explícita y claves foráneas donde corresponde. El script completo está en `Grupo04_Practica2_SQL.sql`; a continuación, un fragmento representativo:

```
CREATE TABLE fact_incendio (
  incendio_id      VARCHAR(20) PRIMARY KEY,
  celda_id         VARCHAR(20) NOT NULL REFERENCES dim_celda(celda_id),
  fecha_id         INTEGER NOT NULL REFERENCES dim_fecha(fecha_id),
  numero_detecciones INTEGER NOT NULL DEFAULT 0 CHECK (numero_detecciones >= 0),
  incendio_observado BOOLEAN NOT NULL DEFAULT FALSE,
  CONSTRAINT uq_incendio_celda_fecha UNIQUE (celda_id, fecha_id)
);
```

En conjunto, el esquema usa: `PRIMARY KEY` (simple y compuesta), `FOREIGN KEY (REFERENCES)`, `UNIQUE` (coordenadas de celda, fecha, nombre de cobertura, $(celda_id, fecha_id)$), `CHECK` (rango de mes, valores no negativos, porcentaje de cobertura, coherencia `fecha_id  $\leftrightarrow$  fecha`, coherencia observado/detecciones), `NOT NULL` en los atributos de negocio, y `DEFAULT` (área por defecto, fuente 'VIIRS', `incendio_observado = FALSE`).

Los datos de ejemplo son controlados: **82 registros** distribuidos en las 6 tablas (6 celdas, 12 fechas, 5 tipos de cobertura, 11 filas de `celda_cobertura`, 18 registros de incendio y 30 de clima), con variedad de FRP, precipitación y días con y sin detección.

5. Consultas SQL

Las 8 consultas obligatorias y una adicional, ejecutadas contra `taller_sql_fireforest`. Resultados y consultas completas verificables en `05_resultados/resultados_consultas.md` y en `Grupo04_Practica2_SQL.sql`.

Consulta 1 – SELECT + WHERE

Pregunta: ¿Qué detecciones de incendio existen para LJ_001 entre julio y agosto de 2023?

```
SELECT fi.incendio_id, fi.celda_id, df.fecha, fi.numero_detecciones, fi.frp_maxima_mw
FROM fact_incendio fi JOIN dim_fecha df ON df.fecha_id = fi.fecha_id
WHERE fi.celda_id = 'LJ_001' AND df.fecha BETWEEN '2023-07-01' AND '2023-08-31';
```

incendio_id	celda_id	fecha	detecciones	frp_max (MW)
INC_0001	LJ_001	2023-07-05	2	15.200
INC_0002	LJ_001	2023-08-15	1	10.100

Interpretación: LJ_001 registra dos fechas con incendio observado en el rango consultado; no hay otras fechas con registro para esta celda en ese periodo.

Consulta 2 – SELECT + WHERE

Pregunta: ¿Cuál fue la precipitación diaria en LJ_003 durante septiembre de 2023?

```
SELECT fc.celda_id, df.fecha, fc.precipitacion_diaria_mm
FROM fact_clima fc JOIN dim_fecha df ON df.fecha_id = fc.fecha_id
WHERE fc.celda_id = 'LJ_003' AND df.anio = 2023 AND df.mes = 9;
```

celda_id	fecha	precipitación (mm)
LJ_003	2023-09-20	6.40

Interpretación: para LJ_003 solo existe un registro de precipitación cargado en septiembre de 2023.

Consulta 3 – ORDER BY + LIMIT

Pregunta: ¿Cuáles son las 5 detecciones con mayor FRP máxima del periodo?

```
SELECT fi.incendio_id, fi.celda_id, df.fecha, fi.frp_maxima_mw, fi.numero_detecciones
FROM fact_incendio fi JOIN dim_fecha df ON df.fecha_id = fi.fecha_id
WHERE fi.incendio_observado = TRUE
ORDER BY fi.frp_maxima_mw DESC LIMIT 5;
```

incendio_id	celda_id	fecha	frp_max (MW)	detecciones
INC_0014	LJ_005	2023-08-15	25.600	5
INC_0007	LJ_003	2023-07-25	22.100	4
INC_0005	LJ_002	2023-08-20	20.300	3
INC_0001	LJ_001	2023-07-05	15.200	2
INC_0016	LJ_006	2023-07-15	14.500	2

Interpretación: las cinco detecciones de mayor intensidad provienen de cinco celdas distintas; ninguna concentra más de un evento en este top 5.

Consulta 4 – LEFT JOIN

Pregunta: ¿Qué celdas tienen incendio observado sin registro de precipitación en la misma fecha?

```
SELECT fi.celda_id, df.fecha, fi.numero_detecciones, fc.precipitacion_diaria_mm
FROM fact_incendio fi JOIN dim_fecha df ON df.fecha_id = fi.fecha_id
LEFT JOIN fact_clima fc ON fc.celda_id = fi.celda_id AND fc.fecha_id = fi.fecha_id
WHERE fi.incendio_observado = TRUE AND fc.clima_id IS NULL;
```

celda_id	fecha	detecciones	precipitación (mm)
LJ_001	2023-07-05	2	sin registro

PostgreSQL Query Results				
Results Messages				
localho... taller_sql_f... schema: session default				
	celda_id	fecha	numero_detecciones	precipitacion_diaria_mm
1	LJ_001	2023-07-05	2	NULL

Figura 3: Resultado de la consulta ejecutada en VS Code/PostgreSQL.


Interpretación: existe un único caso sin correspondencia en todo el periodo; en el resto de fechas con incendio observado sí hay un registro de precipitación asociado.

Consulta 5 – INNER JOIN (3 tablas)

Pregunta: listado legible de detecciones observadas, con nombre de celda y fecha calendario.

```
SELECT dc.nombre_referencia, df.fecha, df.mes, fi.numero_detecciones, fi.frp_maxima_mw
FROM fact_incendio fi
JOIN dim_celda dc ON dc.celda_id = fi.celda_id
JOIN dim_fecha df ON df.fecha_id = fi.fecha_id
WHERE fi.incendio_observado = TRUE ORDER BY df.fecha;
```

celda	fecha	mes	detecciones	frp_max (MW)
Sector La Toma	2023-07-05	7	2	15.200
Sector Zamora Huayco	2023-07-15	7	2	14.500
Sector El Pedestal	2023-07-25	7	4	22.100
Sector Amable Maria	2023-08-10	8	1	9.300
Sector La Toma	2023-08-15	8	1	10.100
Sector San Cayetano	2023-08-15	8	5	25.600
Sector Landangui	2023-08-20	8	3	20.300
Sector San Cayetano	2023-09-05	9	1	7.200
Sector Landangui	2023-09-15	9	1	8.700
Sector El Pedestal	2023-09-20	9	2	12.000



The screenshot shows the PostgreSQL Query Results interface in VS Code. The query results are displayed in a table with 10 rows and 7 columns. The columns are: nombre_referencia, fecha, mes, numero_detecciones, frp_maxima_mw, and fire_mask_maximo. The data is sorted by fecha in ascending order.

	nombre_referencia	fecha	mes	numero_detecciones	frp_maxima_mw	fire_mask_maximo
1	Sector La Toma	2023-07-05	7	2	15.200	8
2	Sector Zamora Huayco	2023-07-15	7	2	14.500	7
3	Sector El Pedestal	2023-07-25	7	4	22.100	8
4	Sector Amable Maria	2023-08-10	8	1	9.300	6
5	Sector La Toma	2023-08-15	8	1	10.100	7
6	Sector San Cayetano	2023-08-15	8	5	25.600	9
7	Sector Landangui	2023-08-20	8	3	20.300	9
8	Sector San Cayetano	2023-09-05	9	1	7.200	5
9	Sector Landangui	2023-09-15	9	1	8.700	6
10	Sector El Pedestal	2023-09-20	9	2	12.000	7

Figura 4: Resultado de la consulta ejecutada en VS Code/PostgreSQL.

Interpretación: las 10 fechas con incendio observado se distribuyen en los tres meses del periodo, sin que uno solo concentre la mayoría de los casos.

Consulta 6 – GROUP BY + COUNT/SUM/AVG/MAX

Pregunta: ¿cuántas detecciones totales y qué FRP promedio/máximo presenta cada celda?

```
SELECT dc.celda_id, COUNT(fi.incendio_id) dias, SUM(fi.numero_detecciones) detecciones,
       ROUND(AVG(fi.frp_maxima_mw),2) frp_prom, MAX(fi.frp_maxima_mw) frp_max
FROM dim_celda dc JOIN fact_incendio fi ON fi.celda_id = dc.celda_id
GROUP BY dc.celda_id ORDER BY detecciones DESC;
```

celda_id	días	detecciones	frp_prom (MW)	frp_max (MW)
LJ_003	3	6	17.05	22.100
LJ_005	3	6	16.40	25.600
LJ_002	3	4	14.50	20.300
LJ_001	3	3	12.65	15.200
LJ_006	3	2	14.50	14.500
LJ_004	3	1	9.30	9.300

Interpretación (analítica): LJ_003 y LJ_005 concentran más detecciones que las demás celdas. LJ_005 tiene el pico máximo de FRP, pero LJ_003 mantiene un promedio ligeramente mayor, es decir, una intensidad más consistente entre sus eventos. Es una comparación entre celdas, no una tendencia temporal.

Consulta 7 – GROUP BY + HAVING

Pregunta: ¿qué celdas y meses acumulan precipitación total por debajo de 20 mm?

```
SELECT fc.celda_id, df.anio, df.mes, SUM(fc.precipitacion_diaria_mm) precip_mm,
       MIN(fc.precipitacion_diaria_mm) precip_min
FROM fact_clima fc JOIN dim_fecha df ON df.fecha_id = fc.fecha_id
GROUP BY fc.celda_id, df.anio, df.mes
HAVING SUM(fc.precipitacion_diaria_mm) < 20 ORDER BY precip_mm ASC;
```

celda_id	año	mes	precip. acum. (mm)	precip. mín. (mm)
LJ_002	2023	7	0.00	0.00
LJ_005	2023	7	0.50	0.50
LJ_003	2023	7	2.10	0.00
LJ_005	2023	8	4.50	0.50
LJ_003	2023	9	6.40	6.40
LJ_006	2023	8	10.00	10.00
LJ_004	2023	8	14.40	5.50
LJ_001	2023	9	14.70	0.00
LJ_001	2023	7	18.40	18.40

	celda_id	anio	mes	precipitacion_acumulada_mm	precipitacion_minima_mm	dias_con_registro
1	LJ_002	2023	7	0.00	0.00	1
2	LJ_005	2023	7	0.50	0.50	1
3	LJ_003	2023	7	2.10	0.00	2
4	LJ_005	2023	8	4.50	0.50	2
5	LJ_003	2023	9	6.40	6.40	1
6	LJ_006	2023	8	10.00	10.00	1
7	LJ_004	2023	8	14.40	5.50	2
8	LJ_001	2023	9	14.70	0.00	2
9	LJ_001	2023	7	18.40	18.40	1

Figura 5: Resultado de la consulta ejecutada en VS Code/PostgreSQL.


Interpretación (analítica): 9 combinaciones celda-mes acumulan menos de 20 mm. La mayoría (7 de 9) tienen solo 1 o 2 días con registro en el mes, por lo que el acumulado bajo puede reflejar también cobertura de datos incompleta, no solo ausencia real de lluvia.

Consulta 8 – CTE

Pregunta: ¿qué combinaciones celda-mes presentan a la vez detecciones y precipitación mensual baja (<20 mm)?

```
WITH detecciones_mes AS (
  SELECT fi.celda_id, df.anio, df.mes, SUM(fi.numero_detecciones) det
  FROM fact_incendio fi JOIN dim_fecha df ON df.fecha_id = fi.fecha_id
  GROUP BY fi.celda_id, df.anio, df.mes),
clima_mes AS (
  SELECT fc.celda_id, df.anio, df.mes, SUM(fc.precipitacion_diaria_mm) precip
  FROM fact_clima fc JOIN dim_fecha df ON df.fecha_id = fc.fecha_id
  GROUP BY fc.celda_id, df.anio, df.mes)
SELECT d.celda_id, d.anio, d.mes, d.det, c.precip
FROM detecciones_mes d JOIN clima_mes c USING (celda_id, anio, mes)
WHERE d.det > 0 AND c.precip < 20 ORDER BY c.precip ASC;
```

celda_id	año	mes	detecciones	precip. acum. (mm)
LJ_003	2023	7	4	2.10
LJ_005	2023	8	5	4.50
LJ_003	2023	9	2	6.40
LJ_004	2023	8	1	14.40
LJ_001	2023	7	2	18.40



	celda_id	anio	mes	detecciones_totales	precipitacion_acumulada_mm
1	LJ_003	2023	7	4	2.10
2	LJ_005	2023	8	5	4.50
3	LJ_003	2023	9	2	6.40
4	LJ_004	2023	8	1	14.40
5	LJ_001	2023	7	2	18.40

Figura 6: Resultado de la consulta ejecutada en VS Code/PostgreSQL.


Interpretación (analítica): en 5 combinaciones celda-mes coexisten detecciones y precipitación mensual baja, destacando LJ_003 en julio y LJ_005 en agosto. Es una asociación descriptiva observada en los datos de ejemplo, sin que constituya evidencia de causalidad ni deba extrapolarse a otros periodos o celdas.

Consulta adicional – fuera del mínimo exigido por la guía

Pregunta: ¿qué tipo de cobertura vegetal está asociado con más detecciones? (usa la relación N:M dim_celda ↔ dim_cobertura_vegetal).

```
SELECT cv.nombre, COUNT(DISTINCT cc.celda_id) celdas, SUM(fi.numero_detecciones) detecciones
FROM dim_cobertura_vegetal cv
JOIN celda_cobertura cc ON cc.cobertura_id = cv.cobertura_id
JOIN fact_incendio fi ON fi.celda_id = cc.celda_id
GROUP BY cv.nombre ORDER BY detecciones DESC;
```

cobertura vegetal	celdas asociadas	detecciones asociadas
Matorral	2	10
Pastizal	4	10
Bosque nativo	2	9
Cultivo	2	7
Área urbana	1	2



	cobertura_vegetal	celdas_con_esta_cobertura	detecciones_totales
1	Matorral	2	10
2	Pastizal	4	10
3	Bosque nativo	2	9
4	Cultivo	2	7
5	Area urbana	1	2

Figura 7: Resultado de la consulta ejecutada en VS Code/PostgreSQL.

Interpretación (analítica): las celdas que contienen matorral y las que contienen pastizal son las que acumulan más detecciones asociadas (10 en cada caso), aunque el doble de celdas contiene pastizal (4) que matorral (2), por lo que la asociación promedio por celda es menor para pastizal. Esto es una asociación descriptiva, no una asignación espacial exacta de cada detección a un parche de cobertura: por la relación N:M, una misma celda puede contener más de un tipo de cobertura, y sus detecciones se cuentan en cada categoría de cobertura que esa celda contiene. No implica que el tipo de cobertura sea causa de la ocurrencia de incendios.

6. Validaciones

Ejecutadas contra `taller_sql_fireforest` (detalle completo en `05_resultados/validaciones.md` y en la sección 5 de `Grupo04_Practica2_SQL.sql`):

- **Conteo de filas:** 82 en total (6+12+5+11+18+30 por tabla), como se diseñó.
- **PK únicas:** `fact_incendio.incendio_id` y `fact_clima.clima_id` sin duplicados (verificado comparando conteo total vs. conteo de valores distintos).
- **FK íntegras:** 0 filas de `fact_incendio/fact_clima` con celda o fecha inexistente.
- **Duplicados lógicos:** 0 pares (`celda_id`, `fecha_id`) repetidos en `fact_incendio`.
- **Valores negativos:** 0 precipitaciones y 0 valores de FRP negativos.
- **Cobertura $\leq 100\%$:** 0 celdas superan el 100 % de cobertura acumulada por año.
- **Coherencia de fechas:** de las 12 filas de `dim_fecha`, 0 presentan `fecha_id`, `anio` o `mes` incoherentes con `fecha` (verificado con consulta explícita, no solo por la existencia del `CHECK`).
- **Pruebas de CHECK:** las 3 pruebas realizadas (mes fuera de rango, precipitación negativa, cobertura $>100\%$) fueron rechazadas correctamente por la base de datos.

7. Conclusiones

El modelo relacional diseñado permite integrar detecciones de incendio, precipitación y cobertura vegetal por celda y fecha en una única estructura consistente, con integridad referencial verificada y sin necesidad de cruces manuales entre fuentes. La normalización hasta 3FN (con la excepción justificada de `dim_fecha`) redujo la redundancia identificada en el modelo inicial desnormalizado y facilitó el mantenimiento de los datos. Las 9 consultas implementadas muestran que el esquema responde tanto preguntas operativas (filtrado puntual por celda y fecha) como analíticas (comparaciones entre celdas, meses y tipos de cobertura vegetal) sin ambigüedad, siempre a partir de datos de ejemplo controlados.

Esta práctica puede utilizarse como referencia o punto de partida conceptual para el componente SQL del Proyecto Integrador FireForest, en tanto práctica independiente: no modifica archivos, esquema ni datos del Proyecto Integrador, y su incorporación eventual quedaría sujeta a un trabajo de integración posterior y explícito.