

ESCUELA SUPERIOR POLITÉCNICA DE CHIMBORAZO (ESPOCH)
Maestría en Estadística con mención en Ciencia de Datos e Inteligencia Artificial

Práctica 2 – Taller SQL

Modelado, normalización y consultas

Caso aplicado

Detecciones de incendio, precipitación y cobertura vegetal por celda espacial
y fecha, en el cantón Loja

Integrantes

MALAN MULLO MARCO VINICIO
PUJOS CULQUE VIVIANA ISABEL
CARLOS GUILLERMO CHUNCHO M.

Grupo 04

Práctica 2 – M1721
2026

1. Caso aplicado

Contexto. Las detecciones satelitales de incendio, los registros de precipitación y la cobertura vegetal de una zona suelen analizarse por separado, sin relacionarlos entre sí por celda espacial y fecha. Este taller usa el mismo dominio temático que el Proyecto Integrador FireForest (incendios forestales, cantón Loja), pero como una práctica **independiente**, con su propio esquema, sus propios datos de ejemplo y su propia base de datos PostgreSQL (`taller_sql_fireforest`).

Problema. Sin una estructura relacional integrada, preguntas simples como "¿qué celdas con cierto tipo de cobertura vegetal concentran más detecciones?." o "¿hay meses con varias detecciones y poca lluvia?" requieren cruzar manualmente fuentes distintas.

Propósito de la base de datos. Diseñar e implementar una base de datos relacional en PostgreSQL que integre, sin redundancia, detecciones de incendio, precipitación diaria y cobertura vegetal por celda y fecha, y que pueda consultarse mediante SQL para responder preguntas operativas y analíticas descriptivas.

Usuarios potenciales. Estudiantes y docentes del curso, como ejercicio de modelado y SQL; y, como referencia conceptual, personal técnico ambiental que quisiera una primera aproximación relacional (sin que exista convenio real con ninguna institución).

Preguntas operativas.

1. ¿Qué detecciones de incendio existen para una celda y un periodo específicos?
2. ¿Cuál fue la precipitación registrada para una celda y una fecha determinadas?
3. ¿Qué celdas no tienen registro de precipitación para una fecha con incendio observado?

Preguntas analíticas.

1. ¿Cuántas detecciones y qué FRP promedio/máximo presenta cada celda?
2. ¿Qué celdas y meses acumulan precipitación mensual baja?
3. ¿Qué combinaciones celda-mes presentan a la vez detecciones y precipitación baja?
4. ¿Qué tipo de cobertura vegetal concentra más detecciones? (usa la relación N:M)

Nota: todos los datos usados en este taller son de ejemplo, controlados, generados específicamente para esta práctica. No son datos reales de VIIRS ni de CHIRPS.

2. Modelo relacional

Entidades principales: celda espacial (`dim_celda`), fecha (`dim_fecha`), cobertura vegetal (`dim_cobertura_vegetal`), detección de incendio (`fact_incendio`) y registro de precipitación (`fact_clima`).

Relaciones 1:N: `dim_celda` con `fact_incendio` y con `fact_clima`; `dim_fecha` con `fact_incendio` y con `fact_clima`.

Relación N:M: una celda puede tener más de un tipo de cobertura vegetal registrado en un mismo año (mosaico de uso de suelo), y un tipo de cobertura aplica a muchas celdas. Esta relación muchos-a-muchos entre `dim_celda` y `dim_cobertura_vegetal` se resuelve con la tabla intermedia `celda_cobertura(celda_id, cobertura_id, anio)`.

Tabla	Propósito	PK	FK	Cardinalidad
<code>dim_celda</code>	Celda espacial de referencia (500 m × 500 m)	<code>celda_id</code>	—	1 celda – N incendio/clima/cobertura
<code>dim_fecha</code>	Calendario diario del periodo	<code>fecha_id</code>	—	1 fecha – N incendio/clima
<code>dim_cobertura_vegetal</code>	Catálogo de tipos de cobertura	<code>cobertura_id</code>	—	1 cobertura – N celda_cobertura
<code>celda_cobertura</code>	Relación N:M celda ↔ cobertura por año	(<code>celda_id</code> , <code>cobertura_id</code> , <code>anio</code>)	<code>celda_id</code> , <code>cobertura_id</code>	N:M
<code>fact_incendio</code>	Detección diaria de incendio por celda	<code>incendio_id</code>	<code>celda_id</code> , <code>fecha_id</code>	N – 1 celda; N – 1 fecha
<code>fact_clima</code>	Precipitación diaria por celda	<code>clima_id</code>	<code>celda_id</code> , <code>fecha_id</code>	N – 1 celda; N – 1 fecha




Figura 1: Modelo relacional final. La relación N:M entre `dim_celda` y `dim_cobertura_vegetal` queda resuelta por `celda_cobertura`.

3. Normalización

Modelo inicial (desnormalizado). Antes de dividir en tablas, la información cabría en un registro plano por celda-día, con columnas repetidas para cobertura vegetal (`cobertura_1/pct_1`, `cobertura_2/pct_2`, ...) porque una celda puede tener más de un tipo de cobertura.




Figura 2: Modelo inicial (desnormalizado): una única entidad plana, con un grupo repetitivo de cobertura vegetal que impide una PK simple y viola 1FN.

1FN. Se eliminan los grupos repetitivos de cobertura extrayéndolos a `celda_cobertura` (una fila por combinación celda-cobertura-año). Todos los atributos del esquema final son atómicos (sin listas ni valores compuestos) y cada tabla tiene PK explícita.

2FN. Las tablas con PK simple no pueden tener dependencia parcial. La única tabla con PK compuesta es `celda_cobertura(celda_id, cobertura_id, anio)`, donde $(celda_id, cobertura_id, anio) \rightarrow porcentaje_cobertura$: el porcentaje depende de los tres atributos a la vez (el mismo tipo de cobertura puede tener otro porcentaje en otra celda o en otro año), sin dependencia parcial.

3FN. Por tabla: `dim_celda: celda_id → nombre_referencia, longitud, latitud, area_km2`; `fact_incendio: incendio_id → (celda_id, fecha_id, fuente, numero_detecciones, frp_suma_mw, frp_maxima_mw, fire_mask_maximo, incendio_observado)`; `fact_clima: clima_id → (celda_id, fecha_id, precipitacion_diaria_mm)`. En ninguna de estas tablas un atributo no clave determina a otro atributo no clave, por lo que cumplen 3FN.

Excepción deliberada en dim_fecha. En esta tabla, $fecha_id \rightarrow fecha \rightarrow anio, mes$: una fecha calendario determina su año y mes, pero `anio/mes` no dependen directamente de la PK

sin pasar por `fecha`. Es, en sentido estricto, una dependencia transitiva. Se conserva de forma deliberada porque es el patrón estándar de una dimensión de tiempo (evita recalcular `EXTRACT()` en cada consulta de agregación mensual), y su riesgo de inconsistencia queda controlado por el `CHECK chk_fecha_id_consistente` y por la restricción `UNIQUE` sobre `fecha`.

4. Implementación SQL

El esquema se implementó en PostgreSQL con las 6 tablas descritas (`dim_celda`, `dim_fecha`, `dim_cobertura_vegetal`, `celda_cobertura`, `fact_incendio`, `fact_clima`), todas con clave primaria explícita y claves foráneas donde corresponde. El script completo está en `Grupo04_Practica2_SQL.sql`; a continuación, un fragmento representativo:

```
CREATE TABLE fact_incendio (
    incendio_id          VARCHAR(20) PRIMARY KEY,
    celda_id             VARCHAR(20) NOT NULL REFERENCES dim_celda(celda_id),
    fecha_id             INTEGER NOT NULL REFERENCES dim_fecha(fecha_id),
    numero_detecciones   INTEGER NOT NULL DEFAULT 0 CHECK (numero_detecciones >= 0),
    incendio_observado   BOOLEAN NOT NULL DEFAULT FALSE,
    CONSTRAINT uq_incendio_celda_fecha UNIQUE (celda_id, fecha_id)
);
```

En conjunto, el esquema usa: `PRIMARY KEY` (simple y compuesta), `FOREIGN KEY (REFERENCES)`, `UNIQUE` (coordenadas de celda, fecha, nombre de cobertura, (`celda_id`, `fecha_id`)), `CHECK` (rango de mes, valores no negativos, porcentaje de cobertura, coherencia `fecha_id ↔ fecha`, coherencia observado/detecciones), `NOT NULL` en los atributos de negocio, y `DEFAULT` (área por defecto, fuente 'VIIRS', `incendio_observado = FALSE`).

Los datos de ejemplo son controlados: **82 registros** distribuidos en las 6 tablas (6 celdas, 12 fechas, 5 tipos de cobertura, 11 filas de `celda_cobertura`, 18 registros de incendio y 30 de clima), con variedad de FRP, precipitación y días con y sin detección.

5. Consultas SQL

Las 8 consultas obligatorias y una adicional, ejecutadas contra `taller_sql_fireforest`. Resultados y consultas completas verificables en `05_resultados/resultados_consultas.md` y en `Grupo04_Practica2_SQL.sql`.

Consulta 1 – SELECT + WHERE

Pregunta: ¿Qué detecciones de incendio existen para LJ_001 entre julio y agosto de 2023?

```
SELECT fi.incendio_id, fi.celda_id, df.fecha, fi.numero_detecciones, fi.frp_maxima_mw
FROM fact_incendio fi JOIN dim_fecha df ON df.fecha_id = fi.fecha_id
WHERE fi.celda_id = 'LJ_001' AND df.fecha BETWEEN '2023-07-01' AND '2023-08-31';
```

Resultado (2 filas): INC_0001, 2023-07-05, 2 detecciones, FRP máx. 15.2 MW; INC_0002, 2023-08-15, 1 detección, FRP máx. 10.1 MW.

Interpretación: LJ_001 registra dos fechas con incendio observado en el rango consultado; no hay otras fechas con registro para esta celda en ese periodo.

Consulta 2 – SELECT + WHERE

Pregunta: ¿Cuál fue la precipitación diaria en LJ_003 durante septiembre de 2023?

```
SELECT fc.celda_id, df.fecha, fc.precipitacion_diaria_mm
FROM fact_clima fc JOIN dim_fecha df ON df.fecha_id = fc.fecha_id
WHERE fc.celda_id = 'LJ_003' AND df.anio = 2023 AND df.mes = 9;
```

Resultado (1 fila): 2023-09-20, 6.40 mm.

Interpretación: para LJ_003 solo existe un registro de precipitación cargado en septiembre de 2023.

Consulta 3 – ORDER BY + LIMIT

Pregunta: ¿Cuáles son las 5 detecciones con mayor FRP máxima del periodo?

```
SELECT fi.incendio_id, fi.celda_id, df.fecha, fi.frp_maxima_mw, fi.numero_detecciones
FROM fact_incendio fi JOIN dim_fecha df ON df.fecha_id = fi.fecha_id
WHERE fi.incendio_observado = TRUE
ORDER BY fi.frp_maxima_mw DESC LIMIT 5;
```

Resultado (5 filas): LJ_005 (25.6 MW), LJ_003 (22.1 MW), LJ_002 (20.3 MW), LJ_001 (15.2 MW), LJ_006 (14.5 MW), cada una en una fecha distinta.

Interpretación: las cinco detecciones de mayor intensidad provienen de cinco celdas distintas; ninguna concentra más de un evento en este top 5.

Consulta 4 – LEFT JOIN

Pregunta: ¿Qué celdas tienen incendio observado sin registro de precipitación en la misma fecha?

```
SELECT fi.celda_id, df.fecha, fi.numero_detecciones, fc.precipitacion_diaria_mm
FROM fact_incendio fi JOIN dim_fecha df ON df.fecha_id = fi.fecha_id
LEFT JOIN fact_clima fc ON fc.celda_id = fi.celda_id AND fc.fecha_id = fi.fecha_id
WHERE fi.incendio_observado = TRUE AND fc.clima_id IS NULL;
```

Resultado (1 fila): LJ_001, 2023-07-05, 2 detecciones, precipitación sin registro.

Interpretación: existe un único caso sin correspondencia en todo el periodo; en el resto de fechas con incendio observado sí hay un registro de precipitación asociado.

Consulta 5 – INNER JOIN (3 tablas)

Pregunta: listado legible de detecciones observadas, con nombre de celda y fecha calendario.

```
SELECT dc.nombre_referencia, df.fecha, df.mes, fi.numero_detecciones, fi.frp_maxima_mw
FROM fact_incendio fi
JOIN dim_celda dc ON dc.celda_id = fi.celda_id
JOIN dim_fecha df ON df.fecha_id = fi.fecha_id
WHERE fi.incendio_observado = TRUE ORDER BY df.fecha;
```

Resultado representativo (10 filas en total; primeras 3): Sector La Toma (2023-07-05, 2 det., 15.2 MW); Sector Zamora Huayco (2023-07-15, 2 det., 14.5 MW); Sector El Pedestal (2023-07-25, 4 det., 22.1 MW). Resultado completo en 05_resultados/resultados_consultas.md.

Interpretación: las 10 fechas con incendio observado se distribuyen en los tres meses del periodo, sin que uno solo concentre la mayoría de los casos.

Consulta 6 – GROUP BY + COUNT/SUM/AVG/MAX

Pregunta: ¿cuántas detecciones totales y qué FRP promedio/máximo presenta cada celda?

```
SELECT dc.celda_id, COUNT(fi.incendio_id) dias, SUM(fi.numero_detecciones) detecciones,
       ROUND(AVG(fi.frp_maxima_mw),2) frp_prom, MAX(fi.frp_maxima_mw) frp_max
FROM dim_celda dc JOIN fact_incendio fi ON fi.celda_id = dc.celda_id
GROUP BY dc.celda_id ORDER BY detecciones DESC;
```

Resultado (6 filas): LJ_003 y LJ_005 lideran con 6 detecciones cada una; LJ_004 solo 1. FRP máximo más alto: LJ_005 (25.6 MW); FRP promedio más alto: LJ_003 (17.05 MW).

Interpretación (analítica): LJ_003 y LJ_005 concentran más detecciones que las demás celdas. LJ_005 tiene el pico máximo de FRP, pero LJ_003 mantiene un promedio ligeramente mayor, es decir, una intensidad más consistente entre sus eventos. Es una comparación entre celdas, no una tendencia temporal.

Consulta 7 – GROUP BY + HAVING

Pregunta: ¿qué celdas y meses acumulan precipitación total por debajo de 20 mm?

```
SELECT fc.celda_id, df.anio, df.mes, SUM(fc.precipitacion_diaria_mm) precip_mm,
       MIN(fc.precipitacion_diaria_mm) precip_min
FROM fact_clima fc JOIN dim_fecha df ON df.fecha_id = fc.fecha_id
GROUP BY fc.celda_id, df.anio, df.mes
HAVING SUM(fc.precipitacion_diaria_mm) < 20 ORDER BY precip_mm ASC;
```

Resultado representativo (9 filas en total; extremos): LJ_002/jul (0.00 mm, 1 día); LJ_001/jul (18.40 mm, 1 día, el más cercano al umbral). Resultado completo en 05_resultados/resultados_consultas.md.

Interpretación (analítica): 9 combinaciones celda-mes acumulan menos de 20 mm. La mayoría (7 de 9) tienen solo 1 o 2 días con registro en el mes, por lo que el acumulado bajo puede reflejar también cobertura de datos incompleta, no solo ausencia real de lluvia.

Consulta 8 – CTE

Pregunta: ¿qué combinaciones celda-mes presentan a la vez detecciones y precipitación mensual baja (<20 mm)?

```
WITH detecciones_mes AS (
  SELECT fi.celda_id, df.anio, df.mes, SUM(fi.numero_detecciones) det
  FROM fact_incendio fi JOIN dim_fecha df ON df.fecha_id = fi.fecha_id
  GROUP BY fi.celda_id, df.anio, df.mes),
clima_mes AS (
  SELECT fc.celda_id, df.anio, df.mes, SUM(fc.precipitacion_diaria_mm) precip
  FROM fact_clima fc JOIN dim_fecha df ON df.fecha_id = fc.fecha_id
  GROUP BY fc.celda_id, df.anio, df.mes)
SELECT d.celda_id, d.anio, d.mes, d.det, c.precip
FROM detecciones_mes d JOIN clima_mes c USING (celda_id, anio, mes)
WHERE d.det > 0 AND c.precip < 20 ORDER BY c.precip ASC;
```

Resultado (5 filas): LJ_003/jul (4 det., 2.10 mm); LJ_005/ago (5 det., 4.50 mm); LJ_003/sep (2 det., 6.40 mm); LJ_004/ago (1 det., 14.40 mm); LJ_001/jul (2 det., 18.40 mm).

Interpretación (analítica): en 5 combinaciones celda-mes coexisten detecciones y precipitación mensual baja, destacando LJ_003 en julio y LJ_005 en agosto. Es una asociación descriptiva observada en los datos de ejemplo, sin que constituya evidencia de causalidad ni deba extrapolarse a otros periodos o celdas.

Consulta adicional – fuera del mínimo exigido por la guía

Pregunta: ¿qué tipo de cobertura vegetal concentra más detecciones? (usa la relación N:M dim_celda ↔ dim_cobertura_vegetal).

```
SELECT cv.nombre, COUNT(DISTINCT cc.celda_id) celdas, SUM(fi.numero_detecciones) detecciones
FROM dim_cobertura_vegetal cv
JOIN celda_cobertura cc ON cc.cobertura_id = cv.cobertura_id
JOIN fact_incendio fi ON fi.celda_id = cc.celda_id
GROUP BY cv.nombre ORDER BY detecciones DESC;
```

Resultado (5 filas): Matorral (2 celdas, 10 det.); Pastizal (4 celdas, 10 det.); Bosque nativo (2 celdas, 9 det.); Cultivo (2 celdas, 7 det.); Área urbana (1 celda, 2 det.).

Interpretación (analítica): Matorral y Pastizal concentran el mayor número de detecciones acumuladas, aunque Pastizal aparece en el doble de celdas que Matorral, por lo que su detección promedio por celda es menor. Es una concentración descriptiva observada en los datos de ejemplo; no implica que el tipo de cobertura sea causa de la ocurrencia de incendios.

6. Validaciones

Ejecutadas contra taller_sql_fireforest (detalle completo en 05_resultados/validaciones.md y en la sección 5 de Grupo04_Practica2_SQL.sql):

- **Conteo de filas:** 82 en total (6+12+5+11+18+30 por tabla), como se diseñó.
- **PK únicas:** `fact_incendio.incendio_id` y `fact_clima.clima_id` sin duplicados (verificado comparando conteo total vs. conteo de valores distintos).
- **FK íntegras:** 0 filas de `fact_incendio/fact_clima` con celda o fecha inexistente.
- **Duplicados lógicos:** 0 pares (`celda_id`, `fecha_id`) repetidos en `fact_incendio`.
- **Valores negativos:** 0 precipitaciones y 0 valores de FRP negativos.
- **Cobertura $\leq 100\%$:** 0 celdas superan el 100 % de cobertura acumulada por año.
- **Coherencia de fechas:** de las 12 filas de `dim_fecha`, 0 presentan `fecha_id`, `anio` o `mes` incoherentes con `fecha` (verificado con consulta explícita, no solo por la existencia del `CHECK`).
- **Pruebas de CHECK:** las 3 pruebas realizadas (mes fuera de rango, precipitación negativa, cobertura $>100\%$) fueron rechazadas correctamente por la base de datos.

7. Conclusiones

El modelo relacional diseñado permite integrar detecciones de incendio, precipitación y cobertura vegetal por celda y fecha en una única estructura consistente, con integridad referencial verificada y sin necesidad de cruces manuales entre fuentes. La normalización hasta 3FN (con la excepción justificada de `dim_fecha`) redujo la redundancia identificada en el modelo inicial desnormalizado y facilitó el mantenimiento de los datos. Las 9 consultas implementadas muestran que el esquema responde tanto preguntas operativas (filtrado puntual por celda y fecha) como analíticas (comparaciones entre celdas, meses y tipos de cobertura vegetal) sin ambigüedad, siempre a partir de datos de ejemplo controlados.

Esta práctica puede utilizarse como referencia o punto de partida conceptual para el componente SQL del Proyecto Integrador FireForest, en tanto práctica independiente: no modifica archivos, esquema ni datos del Proyecto Integrador, y su incorporación eventual quedaría sujeta a un trabajo de integración posterior y explícito.